

國立屏東科技大學資訊管理系

碩士學位論文

以深度學習及影像處理技術應用於
糖尿病視網膜病變之不平衡樣本分級

Imbalanced Diabetic Retinopathy Data Classification using
Deep Learning and Image Processing Technologies

指導教授：蔡正發 博士

研究生：李佳容

中華民國 112 年 07 月 24 日

摘要

學號：M11056006

論文名稱：以深度學習及影像處理技術應用於糖尿病視網膜病變之不平衡樣本分級

總頁數：85 頁

學校名稱：國立屏東科技大學

系別：資訊管理系

畢業時間及摘要別：111 年度第 2 學期碩士學位論文摘要

研究生：李佳容

指導教授：蔡正發 博士

論文摘要內容：

糖尿病視網膜病變的檢測需要專業的醫療人士判斷，而傳統的人工檢測有耗時和耗人力等問題，為了解決人工檢測的缺點，近年也有許多研究提出自動化檢測方法。本論文著重在研究深度學習和影像處理方法上的應用，並克服糖尿病視網膜病變資料集之數據不平衡特性而導致分類模型效能下降的問題，訓練一個可供臨床醫師或是醫療團隊有效率的診斷糖尿病視網膜病變的深度學習模型。

本研究將糖尿病視網膜病變之眼底照片使用影像增強、亮度校正、對比度調整等影像處理方法作為數據集前處理步驟，應用一個基於色彩空間轉換、CLAHE、Retinex 影像增強算法 MSRCCR (Multi-Scale Retinex with Color Restoration)、伽瑪校正等方法之融合技術，用於突顯視網膜病理特徵。再使用 ResNet50v2、DenseNet121、InceptionV3、Xception、MobileNetV2、InceptionResNetV2 等深度學習模型進行訓練後，將糖尿病視網膜病變的數據集依據疾病嚴重程度分成五個級別：無視網膜病變 (No DR)、輕度非增殖性視網膜病變 (Mild DR)、中等非增殖性視網膜病變 (Moderate DR)、嚴重非增殖性視網膜病變 (Severe DR)、增殖性視網膜病變 (Proliferative DR)。最後比較不同影像預處理方法和深度學習模型的搭配組合之系統性能評估指標。

本研究使用的影像增強之融合技術最終在 APTOS 2019 數據集上得到的最佳靈敏度 (Sensitivity) 及特異度 (Specificity) 的評分穩定落在 0.97 ~ 0.99 區間內，二次加權 Kappa 係數 (Quadratic Weighted Kappa) 為 0.897。與其他研究相比也證明了本研究使用的影像增強之融合技術在糖尿病視網膜分級任務上有著優良的系統性能，且 MSRCR 轉換方法在該影像增強之融合技術架構中是跟其它相關研究不同的貢獻。也證實了透過類別權重方法使模型即使是在數據分佈失衡的情況下可以精準的區分不同嚴重程度視網膜病變特徵。

關鍵字：糖尿病視網膜病變、深度學習、影像處理、不平衡樣本



Abstract

Student ID : M11056006

Title of Thesis : Imbalanced Diabetic Retinopathy Data Classification using Deep Learning and Image Processing Technologies

Total page : 85

Name of Institute : National Pingtung University of Science and Technology
Graduate Institute of Management Information Systems

Graduate Date : July, 2023

Degree Conferred : Master

Name of Student : Li, Jia Rong

Advisor : Dr. Tsai, Cheng-Fa

The contents of abstract in this thesis :

The detection of diabetic retinopathy requires the judgment of medical professionals, and traditional manual detection has time-consuming and manpower-consuming problems. In order to solve the shortcomings of manual detection, many studies have proposed automatic detection methods for diabetic retinopathy in recent years. This thesis focuses on the application of deep learning and image processing methods, and overcomes the problem of the performance degradation of the classification model caused by imbalanced diabetic retinopathy dataset. Trains an efficient deep learning model for clinicians or medical teams to efficiently diagnose diabetic retinopathy.

In this study, image processing methods such as image enhancement, brightness correction, and contrast adjustment use for the pre-processing steps of the datasets for fundus images of diabetic retinopathy, and a fusion technology based on color space conversion, Contrast Limited Adaptive Histogram Equalization, Multi-Scale Retinex with Color Restoration, and gamma correction is applied to highlighting Retinal pathological features. After training with deep learning models such as ResNet50v2, DenseNet121, InceptionV3, Xception, MobileNetV2, InceptionResNetV2, the dataset of

diabetic retinopathy is divided into five levels according to the severity of the disease: no retinopathy (No DR) , mild non-proliferative Retinopathy (Mild DR) , moderate non-proliferative retinopathy (Moderate DR) , severe non-proliferative retinopathy (Severe DR) , proliferative retinopathy (Proliferative DR). Finally, compare the performance evaluation indicators of different image preprocessing methods and deep learning models.

The image enhancement fusion technology proposed in this study finally obtained the best sensitivity and specificity scores on the APTOS 2019 data set, and the Quadratic Weighted Kappa coefficient is 0.897. Compared with other studies, it also proves that the method proposed in this study has excellent performance on the diabetic retinal grading task. Furthermore, the utilization of the MSRCR conversion method represents a unique contribution in the image enhancement fusion technology framework, setting it apart from other related research. It is also confirmed that through the class weights techniques, the model can accurately distinguish the features of retinopathy with different severities even in the case of imbalanced data distribution.

Keywords : Diabetic Retinopathy, Deep Learning, Image Processing Technologies, Imbalanced Data

謝誌

碩士班兩年很快就過去了，要放下學生的身份前往下一個人生目標。讀研究所這段期間雖然不長，是我最難忘的回憶，感謝每一位師長、家人、研究室是同儕及親朋好友的陪伴和鼓勵。

首先感謝謝蔡正發教授指導我，不論是論文研究方向或是分享人生經歷，都感悟我許多。於課堂上鼓勵學生們思考研究的創新和表達，提供論文研究的靈感，讓不同年級甚至不同科系的學生們可以互相交流研究心得，互相激盪更多想法來解決不同領域的問題；也致力帶領實驗室參與各項計畫，提供研究生們增強實力和拓展視野的機會；在研究上提供優質的研究設備和器材資源，供實驗室的研究生們方便進行研究實驗，蔡正發教授給予的種種幫助說不盡，感謝老師給予的指導，教誨如春風，師恩似海深。

感謝口試委員蔡正發教授、劉寧漢教授、王朱福教授及陳耀輝副教授，於百忙之中抽空替研究生們口試，給予論文上的意見和指導。

最後感謝實驗室的同儕、家人、親友給予關心和祝福，有你們在情感上給我的支持，才能讓我突破自己的難題，完成學業成就。

李佳容 謹誌於
國立屏東科技大學資訊管理系
中華民國一百一十二年七月

目錄

摘要	I
Abstract	III
謝誌	V
目錄	VI
圖目錄	IX
表目錄	XII
第壹章 緒論	1
第一節 研究的背景	1
第二節 研究動機與目的	3
第三節 研究範圍與限制	8
第四節 研究流程	9
第貳章 文獻探討	11
第一節 糖尿病視網膜病變公開數據集	11
第二節 影像預處理	20
一、 影像裁剪和大小調整	20
二、 色彩空間轉換	22
三、 影像增強方法	24
四、 資料增強處理	27
第三節 深度學習之卷積神經網路預訓練模型	28
一、 ResNet50v2	28

二、 DenseNet.....	30
三、 InceptionV3.....	30
四、 Xception.....	32
五、 MobileNet	34
六、 InceptionResNet.....	35
第四節 數據不平衡特性解決方案.....	36
一、 樣本重新採樣與資料增強	37
二、 Focal Loss 損失函數	37
三、 類別權重 (Class Weights)	38
第參章 研究之方法與步驟	40
第一節 糖尿病視網膜病變之影像收集	42
第二節 糖尿病視網膜病變之影像預處理方法	42
第三節 糖尿病視網膜病變之深度學習模型分級辨識	45
第四節 系統性能評估指標.....	46
一、 準確率 (Accuracy)	47
二、 精確率 (Precision)	48
三、 接收者操作特徵曲線 (ROC Curve)	48
四、 靈敏度 (Sensitivity)	49
五、 特異度 (Specificity)	49
六、 二次加權 Kappa 係數	50
七、 混淆矩陣 (Confusion Matrix)	51
第肆章 實驗結果	52

第一節 實驗環境.....	52
第二節 糖尿病視網膜病變實驗數據集分析	53
第三節 模型參數設定.....	55
第四節 實驗結果.....	56
第伍章 結論與未來展望	75
第一節 結論.....	75
第二節 未來展望.....	78
參考文獻.....	80



圖目錄

圖 1-1：糖尿病視網膜病變五種等級分類	5
圖 1-2：糖尿病視網膜病變的臨床症狀特徵	6
圖 1-3：研究流程圖	10
圖 2-1：APTOS 2019 訓練集各評級圖像數量佔比.....	14
圖 2-2：Messidor 2 訓練集各評級圖像數量佔比	15
圖 2-3：IDRiD 訓練集各評級圖像數量佔比	16
圖 2-4：IDRiD 測試集各評級圖像數量佔比	17
圖 2-5：EyePACS 訓練集各評級圖像數量佔比	18
圖 2-6：DDR 數據集各評級圖像數量佔比.....	19
圖 2-7：Kaggle APTOS 2019 數據集原始圖像	21
圖 2-8：Kaggle APTOS 2019 數據集處理過後圖像	22
圖 2-9：CIELAB、HSV、HSI 等色彩空間轉換與原始圖像之視網膜 血管特徵差異圖解說明.....	23
圖 2-10：原始圖像及相對應的 CLAHE 處理過後的圖像.....	24
圖 2-11：伽瑪校正影像的像素值變換曲線	25
圖 2-12：資料增強（Data Augmentation）技術	28
圖 2-13：ResNet50-v1 與 ResNet50-v2 的基本殘差單元架構差異圖..	29
圖 2-14：Dense Block 示意圖	30
圖 2-15：Inception Block 示意圖	31
圖 2-16：Inception Module 結構簡易版本之示意圖.....	32

圖 2-17：Depthwise Separable Convolution 示意圖	33
圖 2-18：Xception 網路結構圖	33
圖 2-19：MobileNet 的 Depthwise Convolution 和 Pointwise Convolution 卷積運算流程圖	35
圖 2-20：結合 Residual Connection 的 Inception Block 架構圖	36
圖 3-1：糖尿病視網膜病變分級系統流程圖	41
圖 3-2：影像增強之融合技術架構圖	44
圖 3-3：影像增強之融合技術應用於視網膜眼底影像前後對比	45
圖 3-4：模型訓練架構	46
圖 3-5：ROC 曲線示意圖	48
圖 4-1：本研究使用方法使用 APTOS 2019 數據集訓練 DenseNet121 模 型的混淆矩陣	60
圖 4-2：本研究使用方法使用 APTOS 2019 數據集訓練 InceptionResNetV2 模型的混淆矩陣	60
圖 4-3：本研究使用方法使用 Messidor 2 數據集訓練 DenseNet121 模型 的混淆矩陣	61
圖 4-4：本研究使用方法使用 Messidor 2 數據集訓練 InceptionResNetV2 模型的混淆矩陣	61
圖 4-5：本研究使用方法使用 APTOS 2019 數據集訓練 DenseNet121 模 型的 ROC Curve 圖	62
圖 4-6：本研究使用方法使用 APTOS 2019 數據集訓練 InceptionResNetV2 模型的 ROC Curve 圖	63
圖 4-7：本研究使用方法使用 Messidor 2 數據集訓練 DenseNet121 模型 的 ROC Curve 圖	64

圖 4-8：本研究使用方法使用 Messidor 2 數據集訓練 InceptionResNetV2 模型的 ROC Curve 圖	65
圖 4-9：未設定類別權重方法的 ROC Curve 圖	68
圖 4-10：未設定類別權重方法的混淆矩陣	68
圖 4-11：僅設定 Categorical Focal Loss 的 ROC Curve 圖	69
圖 4-12：僅設定 Categorical Focal Loss 的混淆矩陣	69
圖 4-13：僅設定 Class Weights 的 ROC Curve 圖	70
圖 4-14：僅設定 Class Weights 的混淆矩陣	70
圖 4-15：已設定類別權重方法的 ROC Curve 圖	71
圖 4-16：已設定類別權重方法的混淆矩陣	71
圖 4-17：本研究使用的圖 3-2 架構去除 MSRCR 轉換使用 DenseNet121 訓練結果的混淆矩陣	73

表目錄

表 1-1：各分類之臨床症狀整理表格	7
表 2-1：常見的公開數據集的詳細資料	12
表 2-2：各疾病分類圖片數量分佈的統計資料	13
表 3-1：TP、TN、FP、FN 所代表的含意表	47
表 3-2：ROC 曲線下面積判斷預測模型優劣之標準	49
表 3-3：Kappa 係數對模型預測一致性程度的五個評級	51
表 3-4：混淆矩陣示例	51
表 4-1：本論文實驗硬體與軟體環境	52
表 4-2：本論文實驗 APTOS 2019 數據集劃分統計	54
表 4-3：本論文實驗 Messidor 2 數據集劃分統計	54
表 4-4：本研究使用的影像增強之融合技術與六種深度學習模型組 合在 APTOS 2019 數據集上的系統評估結果	57
表 4-5：本研究使用的影像增強之融合技術與六種深度學習模型組 合在 Messidor 2 數據集上的系統評估結果	58
表 4-6：使用 APTOS 2019 數據集與其他研究進行比較	74
表 4-7：使用 Messidor 2 數據集與其他研究進行比較	74

第壹章 緒論

第一節 研究的背景

糖尿病為長期慢性病，糖尿病視網膜病變為其併發症狀之一，罹患糖尿病的時間越久，引起糖尿病視網膜病變的機率就會越高。糖尿病患者長期處於高血糖狀態會造成眼部微血管阻塞、缺氧，導致視網膜出血、微血管異常增殖，並且所增生的血管會很脆弱、容易破裂，引發更嚴重的出血狀況，最嚴重情況患者會失明。

初期可以看到視網膜上有小出血點、滲出物、微血管瘤等症狀，上述初期症狀也稱為非增殖性糖尿病視網膜病變（non-proliferative diabetic retinopathy, NPDR），依其嚴重程度又可以分類輕、中、重度，在疾病初期病人可能不會明顯的感受到視力異常，因而容易輕忽其病症的危害性。若患者為在初期階段未接受治療則可能會使其發展為更嚴重的增殖性糖尿病視網膜病變（proliferative diabetic retinopathy, PDR），其症狀為長期的視網膜嚴重堵塞、缺氧，誘發大量異常血管增生，增生的血管很脆弱容易破裂引發出血，若血塊掉入玻璃體則會影響視力，最嚴重的情形會導致失明，因此越早發現並治療可以大幅降低對視力的損害[1][2][3]。

根據中華民國糖尿病學會網站上發布的 2021 年的台灣糖尿病宣言

[4]所示，全世界的糖尿病人口近年來已增加將近三成，達到 4.63 億，預估未來約 20 年後將成長至 7 億人。依衛生福利部統計顯示，第一型糖尿病患者患病 15 到 20 年後，幾乎所有人都会產生視網膜病變；第二型糖尿病也有超過六成患者會有視網膜病變，其中 20%到 30%的患者會導致失明。雖然糖尿病視網膜病變早期發現並盡早治療的治癒率很高，但早期的視網膜病變症狀不明顯，多數難以發覺，可能因此錯過最佳治療時機[5]。眾多國家的醫療資源和眼科專家也有限，多數農村或偏鄉地區的病患會因為城鄉醫療資源分配不均勻及不足的問題無法得到即時的診斷與治療。傳統人工專家的診斷也存在一些問題，可能需要花費大量的時間去診斷，尤其在早期階段，該病徵通常不太明顯，只依靠單一專家仍有可能誤判。因此對於糖尿病視網膜病變的追蹤治療，會耗費大量的時間與人力資源，並且培訓一位專業的眼科醫生也需要訓練上的成本。

由於上述的人工診斷問題，近年來有許多研究[6] [7] [8]提出自動化的檢測方法，用來輔助醫療團隊和眼科專家更有效率的進行糖尿病視網膜病變的診斷，自動化的診斷方法也解決了醫療資源不足地區導致的眼睛健康的篩檢效率低落問題。

第二節 研究動機與目的

關於糖尿病視網膜病變自動化檢測的最近相關研究包含醫療影像的增強處理、機器學習或深度學習方法影像辨識，還有一些學者整理上述研究，探討這些方法的優缺點和影響辨識結果可能因素。

糖尿病視網膜病變眼底圖像的品質通常不一致，影像的預處理在眾多研究中顯示為必要的步驟，各個研究會根據任務目標去篩選適合的預處理方法，與本論文的實驗相關的影像預處理方法大致分類如下面三種[9]：

- **對比度增強：**某些研究會使用對比度增強的方法和去噪技術以提升眼底影像的品質，以及突顯圖像中細微的疾病特徵，其中對比度方法包括自適應直方圖均衡化（CLAHE）、均值濾波器、中值濾波器和高斯濾波器等方法。
- **色彩空間轉換：**除了對比度增強、影像歸一化（normalization）和降噪以外有些研究關於色彩空間變換（Color space transformation）可以提高模型訓練的效能，較常見的為提取 RGB 色彩空間的綠色通道並結合其他影像前處理方法上。
- **圖像裁剪和大小調整：**圖像中多餘的背景或與研究任務無關的背景訊息可能會影響到系統效能，也有可能包含了不同影像分辨率及縱橫比的圖片，因此某些實驗對影像數據集進行裁剪和大小調整。

本研究主要使用幾種影像前處理方法和多種深度學習的模型進行訓練，並且使用相關學者們的研究[9]中提到的糖尿病視網膜病變數據集來進行五種等級分類（圖 1-1、表 1-1）：無視網膜病變（No DR）、輕度非增殖性視網膜病變（Mild DR）、中等非增殖性視網膜病變（Moderate DR）、嚴重非增殖性視網膜病變（Severe DR）、增殖性視網膜病變（Proliferative DR），上述的糖尿病視網膜病變五種類別臨床症狀如表 1-1 所示。圖 1-2 為糖尿病視網膜病變的臨床症狀特徵，圖中的 Microaneurysm 標示的區域為微動脈瘤，是糖尿病視網膜病變早期的臨床症狀，其外觀呈現圓形的小出血點，通常難以用肉眼觀察到，甚至可能因眼底照片亮度不足而忽略；Exudates 標示的區域為滲出物，在糖尿病視網膜病變中期出現的症狀，會呈現黃色的塊斑狀；Haemorrhage 指的是視網膜或玻璃體出血，在糖尿病視網膜病變晚期出現的症狀，且通常已經演變為增殖性糖尿病視網膜病變（Proliferative DR），成為視網膜上有多處異常血管增生導致，這些血管很脆弱很容易破裂導致出血，比起微動脈瘤，會很明顯的看到視網膜有血塊的特徵。




圖 1-1：糖尿病視網膜病變五種等級分類

資料來源：本研究整理




圖 1-2：糖尿病視網膜病變的臨床症狀特徵

資料來源：[9]

表 1-1：各分類之臨床症狀整理表格

疾病的嚴重程度分類	可觀察到的臨床症狀
Class 0 = No DR	無視網膜病變
Class 1 = Mild DR	有少數的微動脈瘤
Class 2 = Moderate DR	更多的微動脈瘤存在
Class 3 = Severe DR	具有以下任何條件且無 PDR 病徵： 1. 四個象限內有二十多處視網膜出血 狀況發生 2. 兩個象限以上的靜脈串珠（VB） 3. 一個象限以上的嚴重視網膜內微血管異常（IRMA）
Class 4 = Proliferative DR	有以下任一項或三項症狀皆有： 1. 新生血管 2. 玻璃體或視網膜出血 3. 視網膜脫落

除此之外，糖尿病視網膜病變數據集有著數據分類不平衡的問題。

數據不平衡（Imbalanced Data）的問題往往會影響到系統效能，資料集中某個類別數量特別多或是特別少，導致數量多的分類容易被預測；相反情況則少的分類不容易預測，而且少數量的分類容易被模型誤判為

較多數量的類別。本論文會探討此問題並實驗改善方案，並且比較未改善前後的差異，同時也期望本論文可以對相關領域的研究或實際應用有所貢獻。

第三節 研究範圍與限制

糖尿病視網膜病變有很多種自動檢測的任務項目，例如：微動脈瘤的檢測、視網膜的血管分割、糖尿病增殖性視網膜病變導致的視網膜滲出物檢測、視盤分割、二元分類、三分類、多分類… …等檢測、分割或分類的任務。本論文只針對糖尿病視網膜病變五類分級相關範圍現有研究中的方法進行探討。本文實驗主要使用常見的公開分級任務數據集進行模型的訓練和評估，其他研究中所使用的私有數據集不在本研究的討論範圍內。

第四節 研究流程

本論文研究流程如圖 1-3 所示。首先網羅大量的關於糖尿病視網膜病變的研究背景知識及議題，其中重點在於探討傳統人工檢測和自動化檢測的研究議題，接下來找出糖尿病視網膜病變檢測的研究領域中需要解決或改善的問題。根據上述研究問題擬定之過程來制定論文的研究動機與欲達成的研究目的。於初步文獻探討部分，將現有的自動化檢測方法相關研究文獻整理後，探討這些研究中所提出的技術，最後在整理的研究文獻範圍內篩選並確認明確研究的主題。完成上述確定研究主題步驟後，要更精確的去尋找跟主題相關的文獻，詳細探討研究文獻中所使用的影像前處理方法、模型架構方法、實驗的數據集、系統評估標準等技術內容，找出可能的突破點並進行改善或提出新方法。接下來建立研究的架構，流程包含影像預處理、演算法設計、實驗模型評估、實驗模型的參數調整、實驗成果驗證。最後總結和解釋本論文的研究貢獻及未來研究發展方向。




圖 1-3：研究流程圖

資料來源：本研究繪製

第貳章 文獻探討

第一節 糖尿病視網膜病變公開數據集

本節將介紹過去學者在糖尿病視網膜病變分級任務上常使用的數據集[9][10][11]。在分級任務實驗中，這些數據會切分為訓練、測試和驗證集等子集，測試集或驗證集通常用於評估系統效能，更進一步用來跟其他研究進行系統效能上的比較。這些數據集包含影像分辨率、光學影像視角（FoV）、眼底照片取得方式、數據集的分類及任務類型等不同的資訊。其中分類任務會將數據集依據疾病嚴重程度大致分為二至五類，本論文只探討及研究表 2-1 中的五等級分類之糖尿病視網膜病變數據集。

關於各種糖尿病視網膜病變的數據集的詳細資料如表 2-1 所呈現，內容包含分級任務之數據集的圖片數量、光學影像視角、是否為多個眼科專家所標記的圖片等資訊。表 2-2 則為各分級任務之數據集的疾病各分類圖片數量分佈等資訊。其他有關表 2-1、表 2-2 提及的數據集之詳細資訊：除了 IDRID 數據集為固定的分辨率（4288*2848），其他四種數據集內的眼底照片皆為不固定的影像分辨率；APTOS 2019 數據集的總圖片數量為 5,590 張，其中包含帶分類標記 3,662 張，剩餘的為不帶分類標記，表 2-1 僅標示該數據集中帶分類標記 3,662 張；在本

論文實驗中全部的數據集皆設置為五等級的疾病分類（分級依據如表 1-1）。

表 2-1：常見的公開數據集的詳細資料

數據集 名稱	總數量	FoV	分類 數量	是否為多個專 家標記
APTOS 2019	3,662	-	5	是
Messidor 2	1,748	45°	5 (也可自訂)	是
IDRiD	516	50°	5	是
EyePACS	88,702	-	5	否
DDR	13,673	45°	5	是

表 2-2：各疾病分類圖片數量分佈的統計資料

數據集 名稱	訓練或 測試子集	分級					數量 總計
		0	1	2	3	4	
APTOS 2019	訓練集	1,805	370	999	193	295	3,662
Messidor 2	訓練集	1,020	264	347	77	36	1,744
IDRiD	訓練集	134	20	136	74	49	413
	測試集	34	5	32	19	13	103
EyePACS	訓練集	25,802	2,438	5,288	872	708	35,126
DDR	全數據集	6,266	630	4,477	236	913	12,522

(一) APTOS 2019

APTOS 2019 [12]為亞太遠程眼科學會（APTOS）在 2019 年於 Kaggle 上發佈的競賽數據集。數據集包含印度 Aravind 眼科醫院從印度農村收集的 3,662 張眼底圖像（訓練集總數）。數據集的評級和標記是由一群專業醫生根據國際臨床糖尿病視網膜病變嚴重程度量表（ICDRSS）的標準對上述所提到的樣本進行標記。APTOS 2019 的數據集分為五類（No DR、Mild、Moderate、Severe、Proliferative DR）。APTOS 2019 數據集的訓練子集五個評級及其圖像數量佔比分佈之圓餅圖，如圖 2-1 所呈現。

APTOS 2019 各評級佔訓練集總數量之比例




圖 2-1：APTOS 2019 訓練集各評級圖像數量佔比

資料來源：本研究繪製

(二) Messidor 2

Messidor 2 [13]為公開的糖尿病視網膜病變分割和分級數據集，為法國布雷斯特大學醫院眼科在 2009 年至 2010 年收集的視網膜圖像數據集。Messidor 2 數據內的圖像有分左右兩眼，圖像的品質非常優良，無明顯的雜訊。且數據的評級與廣泛使用的 ICDRSS 標準不同，此數據集是使用自定義的分級系統。Messidor 2 數據集的訓練集五個評級及其圖像數量佔比分佈之圓餅圖，如圖 2-2 顯示。

Messidor 2 各評級佔訓練集總圖像數量之比例




圖 2-2：Messidor 2 訓練集各評級圖像數量佔比

資料來源：本研究繪製

(三) IDRiD

印度糖尿病視網膜病變圖像數據集 (IDRiD) [14]，於 2018 年 4 月份開始的糖尿病視網膜病變分割和分級挑戰所使用的數據集。IDRiD 數據集共有 516 張，包含訓練集 413 張和測試集 103 張，有 81 張 DR 的眼底圖像和 164 張沒有 DR 的眼底圖像。數據集的評級是由多名視網膜醫學專家根據 ICDRSS 進行評定，評級的等級範圍從 0 到 4。IDRiD 數據集的訓練集和測試集五個評級及其圖像數量佔比分佈之圓餅圖，

如圖 2-3 及圖 2-4 分別顯示。

IDRiD訓練集各評級佔訓練集總數量之比例




圖 2-3：IDRiD 訓練集各評級圖像數量佔比

資料來源：本研究繪製

IDRiD測試集各評級佔訓練集總數量之比例




圖 2-4：IDRiD 測試集各評級圖像數量佔比

資料來源：本研究繪製

(四) EyePACS

EyePACS 數據集[15]可在 Kaggle 網站上取得，數據集由 EyePACS 團隊提供，這些眼底照片是在美國的加利福尼亞州和其他地方的初級保健站點取得的，對於每位受檢測者各採集左右兩眼的圖像，而數據集的標記是由臨床醫生根據早期治療糖尿病性視網膜病變研究（Early Treatment Diabetic Retinopathy Study, ETDRS）視力量表對每張眼底圖像依據是否存在視網膜病變和視網膜病變嚴重程度進行評級，評分範

圍為 Class 0 至 Class 4，共五種等級。EyePACS 數據集是最大的糖尿病視網膜病變分級任務公共數據集，數據集中包含 88,702 張眼底照片，訓練集的樣本會有臨床醫生的分級標記，測試集則無分級標記，EyePACS 數據集的訓練子集五個評級及其圖像數量佔比分佈之圓餅圖，如圖 2-5 所示。

EyePACS各評級佔訓練集總圖像數量之比例




圖 2-5：EyePACS 訓練集各評級圖像數量佔比

資料來源：本研究繪製

(五) DDR

DDR 數據集[16]的 13,673 張眼底圖像為來自 147 醫院所收集，來源地區範圍涵括中國的 23 個省。這些圖像分為五類（none、mild、moderate、severe、proliferative DR），以及因質量較差而沒有歸類至前五類的圖像（第六類）。DDR 數據集的五個評級及其圖像數量佔比分佈之圓餅圖，如圖 2-6 所示。

DDR各評級佔訓練集總圖像數量之比例




圖 2-6：DDR 數據集各評級圖像數量佔比

資料來源：本研究繪製

第二節 影像預處理

一、 影像裁剪和大小調整

糖尿病視網膜病變的數據集可能含有影像分辨率、縱橫比例不同的視網膜眼底圖像。除此之外，也可能存在跟視網膜病變無相關或多餘的背景及影像訊息。在這些綜述型的研究[9] [11]裡有提及許多篇糖尿病視網膜病變自動檢測的文章在影像數據集的預處理上會將原始圖像進行裁剪、圖片大小調整、分辨率調整等初步處理，目的是減少上述提及的干擾問題，以利於模型的訓練成效，某些研究[17][18]也證明這樣做有助於改善系統的評估結果。圖 2-7 為 Kaggle APTOS 2019 數據集原始影像，可以看到視網膜眼底圖像的背景和視網膜輪廓形狀皆呈現不一致。圖 2-8 為將圖 2-7 的 Kaggle APTOS 2019 數據集原始影像進行裁剪、分辨率一致化、視網膜輪廓一致化後，再應用影像融合增強的方法之結果。圖 2-7 (原始圖像) 與圖 2-8 (處理過後圖像) 相比過後，明顯後者的圖像較有一致性的情況。




圖 2-7：Kaggle APTOS 2019 數據集原始圖像

資料來源：本研究整理




圖 2-8：Kaggle APTOS 2019 數據集處理過後圖像

資料來源：本研究整理

二、色彩空間轉換

該關於糖尿病視網膜病變分級檢測的綜述型研究整理了一些色彩空間轉換的應用[9]。該研究的內容表述，將彩色的眼底圖像轉換為另一種色彩空間，甚至在 RGB 色彩空間的影像上只提取紅、綠、藍其中一個通道，都可以提高模型的系統效能。在 RGB 色彩空間的影像預處理技術方面，提取綠色通道是比較常見的方法。在該研究中[19]證明了將視網膜圖像進行多種色彩空間的轉換後，再將其應用 CLAHE 的方

法後，觀察到不同的色彩空間轉換會凸顯不同的視網膜病變特徵。在該實驗的結果顯示 CIELAB 色彩空間提高影像對比度和突出視網膜血管特徵方面較優於 HSV 及 HSI 色彩空間。不過該研究中僅提及作者是使用 Messidor 數據集的 1,200 張視網膜圖像進行上述實驗測試，沒有使用其他公開數據集來進行驗證，圖 2-9 為該研究將眼底圖像應用 CIELAB、HSI、HSV 等色彩空間轉換方法後得到其視網膜對比度增強圖像，並放大顯示各個視網膜血管特徵差異。




圖 2-9：CIELAB、HSV、HSI 等色彩空間轉換與原始圖像之視網膜血管特徵差異圖解說明 (a) 原始圖像；經 (b) CIELAB、(c) HSI、(d) HSV 色彩空間轉換的圖像。

資料來源：[19]

三、影像增強方法

1. CLAHE

限制對比度自適應直方圖均衡化 (Contrast Limited AHE, CLAHE) 是自適應直方圖均衡化 (Adaptive Histogram Equalization, AHE) 方法的延伸，在醫學影像的研究方面廣泛被應用。糖尿病視網膜病變自動化檢測相關的各種研究中也常被使用，且有些研究[19][20][21]會將 CLAHE 結合其他的影像預處理方法 (伽瑪校正、濾波器、色彩空間轉換) 來突顯醫學影像中疾病的細節特徵，圖 2-10 為原始圖像和應用 CLAHE 方法後的相對應的圖像。




圖 2-10：原始圖像及相對應的 CLAHE 處理過後的圖像

資料來源：[22]

2. 伽瑪校正

伽瑪校正 (Gamma Correction) 是一種被廣泛使用的影像亮度增強技術。許多研究[19][20][23][24]會將 CLAHE 和伽瑪校正結合使用，

通常應用在夜間圖像、醫療圖像或亮度較低的圖像上。伽瑪校正使用圖 2-11 的絕對遞增函數針對影像中的像素 (pixel) 進行調整，對影像進行歸一化、預補償、反向歸一化等步驟，使圖像的細節更加清晰。若像素值靠近極限值 0 或 255，像素值的增加或減少的幅度比較小，跟一般像素值加法或減法比起來可以避免圖像丟失太多細節資訊。




圖 2-11：伽瑪校正影像的像素值變換曲線

資料來源：[19]

3. 高斯濾波器

高斯濾波器 (Gaussian Blur) 也可稱作高斯模糊，常被用在醫療影像的降噪 (Image Denoising)、模糊化處理上。圖像大多數的雜訊均屬於高斯噪聲，因此高斯濾波器也較被廣泛應用。高斯濾波器的處理過程為將圖像與常態分佈 (可稱高斯分佈) 做卷積運算，故這項技術才會叫做高斯濾波器。高斯濾波器在做卷積運算時，會將整個圖像的像素值進行加權平均運算，每個像素值都是由本身值與周圍像素值經過加權平均計算後得到的，而在進行加權運算前會按照 Sigma 值的設定去決定分配權重。

4. 具色彩恢復的多尺度 MSR (Multi-Scale Retinex with Color Restoration, MSRCR)

Retinex 演算法於 1963 年由 Edwin.H.Land 所提出。40 多年來有很多種從 Retinex 影像增強演算法發展出來的演算法，單尺度 Retinex 演算法 (Single Scale Retinex, SSR)、多尺度 Retinex 演算法 (Multi-Scale Retinex, MSR)，以及具色彩恢復的多尺度 Retinex 演算法 (Multi-Scale Retinex with Color Restoration, MSRCR)。Retinex 演算法的主要理論基礎包含：物體的顏色是由物體對紅、綠、藍色 (對應長、中、短波) 光線的反射能力來決定，並非由反射光的強度的絕對值來決定的，物體的顏色不受光照的非均勻性影響具一致性的特性，即 Retinex 演算法是以

色感的一致性為基礎。MSRCR 的方法在 Retinex 演算法基礎上，加入色彩恢復因子來調節因圖像部分區域對比度增強而導致的顏色失真問題。這篇研究[25]提出 MSRCR 演算法，用來解決上述提及的顏色失真的缺陷。

四、 資料增強處理

資料增強 (Data Augmentation) 為從原本的數據集中合成影像來增加資料量的一種技術。資料增強也有其他好處，當輸入到模型進行訓練時，可以較有效率的利用電腦記憶體空間，並且有正則化的特性，可以減少過度擬合 (overfitting) 的情況。將圖像進行水平翻轉、垂直翻轉、調整大小、調整尺寸、偏移、縮放像素值等等方法，人類可以辨別跟原來的圖像為同一張照片，而對模型來說則是不同的圖像，像這樣把原始圖像用上述方法變形成多張圖像的方式就是資料增強的原理，圖 2-12 為使用資料增強後的結果，紅框內為原始圖像，其他的圖像為使用資料增強後所合成的圖像。




圖 2-12：資料增強（Data Augmentation）技術

資料來源：本研究整理

第三節 深度學習之卷積神經網路預訓練模型

一、 ResNet50v2

ResNet50v2 顧名思義為 ResNet50 的改良版本[26]，在 ImageNet 大型視覺資料庫上的系統效能優於 ResNet101 與 ResNet50。ResNet50-v2 主要的改良是將殘差網路（Residual Network, ResNet）的基本單元區塊中的傳播公式修改。ResNet50-v1 與 ResNet50-v2 的基本殘差單元架構之差異如圖 2-13 所示（左邊為 ResNet50-v1，右邊為 ResNet50-v2），ResNet50-v2 將原本版本中的 Batch Normalization 層和激活函數 ReLU 移至權重層的前面，這是一種預激活的結構（pre-activation）。ResNet50-

v2 的這種結構的優勢在於沒有改變模型深度的條件下，模型訓練的收斂速度會更快，並且 Batch Normalization 層放在激活函數 ReLU 和權重層之前可以強化對模型的正則化效果。




圖 2-13：ResNet50-v1 與 ResNet50-v2 的基本殘差單元架構差異圖

資料來源：[26]

二、 DenseNet

DenseNet(Densely Connected Convolutional Network)相較於 ResNet 有幾個優點：降低了網路的複雜度、減少模型的參數數量、減緩梯度消失的問題、加強特徵的傳播[27]。DenseNet 由於 Densely Connected 的特性，有效的提高特徵利用效率，達到降低梯度消失以有助於模型收斂；因特徵重複使用特性，使舊的特徵圖無須再重新學習，達到減少模型參數量。圖 2-14 為 DenseNet 中 Dense Block 的架構圖。




圖 2-14：Dense Block 示意圖

資料來源：[27]

三、 InceptionV3

InceptionV3 發表於 2015 年 12 月。Inception 的原理是將不同尺寸

的卷積層以並聯方式連結在一起，經由這些不同的卷積層運算過後作為下個 Inception Block 的輸入，基於不同尺寸的卷積層提取的特徵訊息可以獲得更好的特徵圖。Inception 避免使用 bottlenecks，bottlenecks 雖可降低模型的參數量，但可能會失去一些重要特徵，須緩慢的降低維度計算量，避免丟失太多訊息[28]。圖 2-15 為 Inception Block 的示意圖，一個 Inception Block 中會擁有不同的卷積尺寸。




圖 2-15：Inception Block 示意圖

資料來源：[28]

四、 Xception

Xception 英文全名 Extreme Inception，以 InceptionV3 為基礎的網路[29]。採用 Depthwise Separable Convolution 架構來取代原本 InceptionV3 中的 Inception Module 架構。Depthwise Separable Convolution 以維持原本 InceptionV3 網路的參數量為前提，可達到降低模型的複雜度、增加網路的寬度，並且使模型有更高的準確度。圖 2-16 和圖 2-17 分別為 Inception Module 和 Depthwise Separable Convolution 架構的簡化版本的示意圖，圖 2-16 使用尺寸為 1×1 卷積層運算後，再將輸出給三個尺寸為 3×3 的卷積層作為輸入值，圖 2-17 為將每個維度分開來進行運算，達到通道及空間分離。圖 2-18 為 Xception 的網路架構圖。




圖 2-16：Inception Module 結構簡易版本之示意圖

資料來源：[29]




圖 2-17：Depthwise Separable Convolution 示意圖

資料來源：[29]




圖 2-18：Xception 網路結構圖

資料來源：[29]

五、 MobileNet

MobileNet 為 Google 公司所提出來的輕量化 CNN 網路模型，主要目的是為了兼顧模型大小和系統運算速度，應用於移動型裝置或設備上[30]。MobileNet 採用 Depthwise Separable Convolution 結構，可以大幅降低運算資源又可以達到不錯的準確度，雖然與 Xception 同樣都採用 Depthwise Separable Convolution，但兩種網路欲達成的目的並不相同，MobileNet 主要使用目的為壓縮模型並提升系統的運算速度，而 Xception 的目標則是在與 InceptionV3 差不多的參數量情況下提高系統效能。Depthwise Separable Convolution 結構分為兩部分：Depthwise Convolution 和 Pointwise Convolution。首先 Depthwise Convolution 會對輸入值的每一個通道建立一個尺寸為 $k \times k$ 的卷積層並各自分開進行運算，接下來 Pointwise Convolution 會將上個步驟運算的結果之乘以一個尺寸為 1×1 的卷積層進行運算，融合後會得到特徵圖，以上的運算流程如圖 2-19 所示。




圖 2-19：MobileNet 的 Depthwise Convolution 和 Pointwise Convolution 卷積運算流程圖
資料來源：[31]

六、 InceptionResNet

InceptionResNet 為結合 InceptionV3 與 ResNet 發展出來的模型 [32]。作者將 Residual Connection 加入到 Inception 的架構中，經實驗證明有 Residual Connection 的 Inception 網路雖然只比沒有 Residual Connection 的 Inception 網路的系統效能表現好一點點而已，但是 Residual Connection 是有利於 Inception 網路訓練速度加快，圖 2-20 為結合 Residual Connection 的 Inception Block 架構圖。




圖 2-20：結合 Residual Connection 的 Inception Block 架構圖

資料來源：[32]

第四節 數據不平衡特性解決方案

由第貳章第一節內的圖 2-1 至圖 2-6 的各種糖尿病視網膜病變之公開數據集的圓餅圖中能明顯觀察到，糖尿病視網膜病變的數據集有

著數據不平衡的特性，某個分類的數量會特別多（如 Class 0 或 Class 2），而某些類別的數量則相較來說非常稀少（如 Class 3 或 Class 4）。這樣的數據不平衡特性會導致模型把少數的分類誤判為多數的分類可能性大幅增加，這樣一來模型的評估指標會失去可靠性。本論文會用於解決數據不平衡問題的方法如以下幾種：

一、 樣本重新採樣與資料增強

一些醫療影像辨識的研究[33] [34] [35]使用樣本重採樣的方法搭配資料增強技術、設計損失函數，或者提出一個新的深度學習網路架構來對數據進行合成來解決樣本不足或不平衡的問題。

二、 Focal Loss 損失函數

於 2017 年發表的一篇研究[36]，該名學者提出一個新穎的損失函數（loss function）的方法 Focal Loss，該損失函數的目標是解決在物件偵測任務中，前景類別和背景類別之間的極端樣本失衡的問題，在訓練的過程中讓模型能盡可能的去訓練比較難的樣本，而忽略那些比較簡單的樣本。Focal Loss 一般定義如公式 2-1[36][37]所示，其中 p_t 的數學表達式如公式 2-2[36] [37]。在本研究使用多分類計算損失的方法 CategoricalCE FL（Categorical Cross Entropy Focal Loss）其定義如公式 2-3[36] [37]所示。 γ 為聚焦參數（focusing parameter），當 γ 大於等於 1 時，會使簡單的樣本（樣本數多的類別）比困難的樣本（樣本數少的類

別) 權重降低更多；當 γ 值為 0 時，Focal Loss 相當於使用 Cross Entropy 方法，Cross Entropy 通常不能區別簡單及困難的樣本，它可能無法在模型訓練過程中更加關注困難的樣本，也就是不會根據樣本比例的多或少調整權重。 α_t 是類別的權重因子，其參數的數值範圍在 0 至 1 區間，若 α_t 設定為 1，則 Focal Loss 將無法正確處理類別不平衡問題，因為這相當於把所有的類別設定為具有相同的權重。本研究實驗中設置的 Focal Loss 參數有 γ 及 α_t ，本研究設置 γ 等於 2， α_t 的數值設置為 0.25，此參數組合為最佳實驗測試結果。

$$\text{Focal Loss } (p_t) = (1 - p_t)^\gamma \times \log(p_t) \quad (\text{公式 2-1})$$

$$p_t = \begin{cases} p & \text{if } y = 1 \\ 1 - p & \text{otherwise} \end{cases} \quad (\text{公式 2-2})$$

$$\text{CategoricalCE FL } (p_t) = \alpha_t (1 - p_t)^\gamma \times \log(p_t) \quad (\text{公式 2-3})$$

三、 類別權重 (Class Weights)

除了上述方法可以解決數據不平衡問題之外，在模型的訓練參數中調整類別權重參數 Class Weights 也是一種基本的方法。該方法的理論在於將資料多的類別的權重降低，反之資料量較少的那類權重就提升。較大的權重則會在損失函數的計算上有較大的懲罰，模型對這類別的損失 (loss) 也會被放大，並將學習的重點放在該分類上；相對的，較小的權重會有較小的懲罰，該類別的損失計算會相對於大權重的類別較小。公式 2-4 [38] 為一般計算均方誤差 (Mean-Square Error, MSE)

的方式，均方誤差是預測值和實際值之間距離的平方和，均方誤差越小說明模型預測有更好的精準度。類別權重參數 Class Weights 計算模型的均方誤差方式有別於一般均方誤差方法，加入權重值調整均方誤差，其定義如公式 2-5 [38]所示， i 代表每筆資料，其中 $\hat{y}_i$ 為預測值， y_i 為實際值， W_c 為權重設定值。在本研究實驗中，將權重參數 Class Weights 以平衡（balanced）模式設置，該模式下會依據類別的樣本多寡以反比方式自動調整權重。某一類別 j 的類別權重 W_j 定義如公式 2-6[39]所示， K 表示該數據集分成幾個等級（本研究分成五類， K 等於 5）， N 為所有類別的總樣本數量， N_j 為該類別的樣本總數量。

$$MSE = \sum_{i=1}^N (\hat{y}_i - y_i)^2 \quad (\text{公式 2-4})$$

$$\text{類別權重的 MSE} = \sum_{i=1}^N W_c (\hat{y}_i - y_i)^2 \quad (\text{公式 2-5})$$

$$W_j = N / (K \times N_j) \quad (\text{公式 2-6})$$

第參章 研究之方法與步驟

本研究將實驗步驟分為影像收集、影像預處理、深度學習模型訓練、系統性能評估，下面四個小節將詳細介紹上述步驟的流程與方法，第五節將說明糖尿病視網膜病變之數據集樣本不平衡的特效的解決方案。糖尿病視網膜病變分級的模型訓練流程圖如圖 3-1 所示。






圖 3-1：糖尿病視網膜病變分級系統流程圖

資料來源：本研究繪製

第一節 糖尿病視網膜病變之影像收集

第一步驟需先確認自身實驗條件可獲取的數據集。由於糖尿病視網膜病變數據集有可能會涉及醫療隱私相關議題，而且數據集通常需要眼科專家協助標記和分級，故能解決上述問題的資料來源蒐集方式為使用現有的公開數據集來做實驗。使用公開數據集也有一些優點，大多過去的研究學者們都會使用公開數據集來對系統進行評估，若使用跟過去研究相同的公開數據集比較能夠得知自己的方法貢獻程度與過去研究差異，另一方面也使自己的研究較具可比較性和可信度。本論文實驗會使用到第貳章第一節提到的糖尿病視網膜病變分級任務之數據集作為實驗過程的模型訓練及系統評估數據集。

第二節 糖尿病視網膜病變之影像預處理方法

第二步驟將 BGR 和 CIELAB 色彩空間轉換、CLAHE、MSRCR、伽瑪校正、Retinex 影像增強算法 MSRCR、Ben Graham 所提出的影像加法融合技術等影像預處理應用在眼底圖像上，突顯影像特徵以利於神經網路進行有效率的特徵學習。再將整個數據集分為訓練集、驗證集、測試集，訓練集和測試集的資料比例為 8:2，而驗證集則是從訓練集中隨機選出 20% 比例的資料。上述分割數據集步驟完成後，將訓練集使用水平翻轉、垂直翻轉、像素值縮放等資料增強 (Data Augmentation) 技術進行處理。在輸入至卷積神經網路模型進行訓練前，

須將每張影像輸入尺寸調整至卷積神經網路要求的最佳尺寸。圖 3-2 為根據上述所使用的影像增強之融合技術架構圖，此架構參考該篇研究，該研究[40]表明 CLAHE 算法搭配 CIELAB 色彩通道增益效果會優於 HSI、HSV 等色彩通道，故本研究使用的架構圖中，CLAHE 作用於 CIELAB 色彩通道中的 L 通道。圖 3-3 為本研究使用的影像增強之融合技術（圖 3-2）應用於視網膜眼底影像前後對比圖。

在圖 3-2 架構圖中，除了 MSRCR 轉換方法之外，其它影像增強方法皆是在糖尿病視網膜病變分級任務中常用的影像前處理方法，換句話說 MSRCR 轉換方法為本研究使用的影像增強之融合技術的主要貢獻之一，會在第肆章實驗結果探討 MSRCR 轉換方法在本研究使用的影像增強之融合技術架構（圖 3-2）中的貢獻程度。MSRCR 在這些研究[41][42][43][44]中，用於視網膜血管分割、視神經盤分割、動靜脈分類等醫學相關的分割或分類任務上。




圖 3-2：影像增強之融合技術架構圖

資料來源：本研究繪製




圖 3-3：影像增強之融合技術應用於視網膜眼底影像前後對比

資料來源：本研究繪製

第三節 糖尿病視網膜病變之深度學習模型分級辨識

第三步驟為使用第貳章第三節提及的 ResNet50v2、DenseNet121、InceptionV3、Xception、MobileNetV2、InceptionResNetV2 等深度學習模型對第二步驟處理過後的糖尿病視網膜病變影像資料集進行訓練，將各種卷積神經網路模型結合影像預處理方法，找出最佳組合並且比較各組合優勢。圖 3-4 為本論文的模型架構，上述提到的每個深度學習的預訓練模型作為本研究的基底模型，且每個基底模型載入 ImageNet 視覺資料庫做為預訓練權重，基底模型下層連接自定義的密集神經網路，卷積神經網路的最後一層設定激活函數為 softmax 函數，輸出五個分類。




圖 3-4：模型訓練架構

資料來源：本研究繪製

第四節 系統性能評估指標

最後的步驟對各種影像增強預處理方法與深度學習模型組合比較這些方法的系統評估指標，確認模型訓練有達到預期的分類效果，過程

需不斷的測試及調整模型參數，最後使用其他的公開數據集以驗證其系統效能及模型可信度。額外的任務為比較現有研究跟本論文實驗最佳組合的系統效能差異，並說明本論文在相關領域研究上的貢獻和實際可行性應用。

下述將說明本研究會採用的系統評估指標，下列的評估指標皆為從相關的糖尿病視網膜病變分級檢測研究[9] [45] [46]中整理，表 3-1 為真陽性(True Positive, TP)、真陰性(True Negative, TN)、偽陽性(Flase Positive, FP)、偽陰性(Flase Negative, FN)所代表的含意。

表 3-1：TP、TN、FP、FN 所代表的含意表

指標名稱	描述
真陽性 (TP)	預測值為陽，且預測正確
真陰性 (TN)	預測值為陰，且預測正確
偽陽性 (FP)	預測值為陽，但預測錯誤
偽陰性 (FN)	預測值為陰，但預測錯誤

一、 準確率 (Accuracy)

準確率用於計算分類任務中，模型預測正確的樣本數量占總樣本數量的比例。計算方式如公式 3-1 所示：

$$\text{Accuracy} = (TP + TN) / \text{Total} \quad (\text{公式 3-1})$$

二、精確率 (Precision)

精確度為被模型識別為正確類別的樣本中占真正正確樣本的比例。

計算方式如公式 3-2 所示：

$$\text{Precision} = TP / (TP + FP) \quad (\text{公式 3-2})$$

三、接收者操作特徵曲線 (ROC Curve)

ROC 曲線下方的面積 (AUC) 越大，可表示分類模型的性能評價越好，ROC 曲線的橫坐標軸為偽陽性率 (False Positive Rate)，而縱座標軸代表真陽性率 (True Positive Rate)。圖 3-5 為 AUC 曲線的示意圖。表 3-2 為 ROC 曲線下面積判斷分類器系統性能的標準。




圖 3-5：ROC 曲線示意圖

資料來源：本研究繪製

表 3-2：ROC 曲線下面積判斷預測模型優劣之標準

ROC 曲線下面積 (AUC)	系統效能
1	完美的分類器，完全預測正確
0.80 以上	效能較高的分類器，少許預測錯誤
0.7 ~ 0.80	效能中等的分類器，預測效果一般水準
0.5 ~ 0.7	效能偏低的分類器，還算有預測價值
0.5 以下	模型沒有預測價值，甚至比隨機猜測的還差

四、靈敏度 (Sensitivity)

靈敏度 (Sensitivity) 也可稱為真陽性率 (True Positive Rate)、召回率 (Recall)。指真正的正確樣本中，被模型預測為正確樣本的比例。計算方式如公式 3-3 所示：

$$\text{Sensitivity} = TP / (TP + FN) \quad (\text{公式 3-3})$$

五、特異度 (Specificity)

特異度 (Specificity) 也稱為真陰性率 (True Negative Rate)。指的是真正的錯誤樣本中，被模型預測為錯誤樣本的比例。計算方式如公式 3-4 所示：

$$\text{Specificity} = TN / (FP + TN) \quad (\text{公式 3-4})$$

六、二次加權 Kappa 係數

Kappa 係數在統計學中是度量一致性的檢測指標，對於機器學習或深度學習方面的分類問題，即為檢驗模型的預測結果和真實數值是否為一致。Kappa 係數計算是根據混淆矩陣（Confusion Matrix），該係數的範圍介於-1 至 1 區間內，通常會大於 0。

二次加權 Kappa 係數則是在機器學習或深度學習中多分類檢測任務的評價中經常使用，尤其是醫療影像的多分類檢測任務。Kappa 係數可分為五個評分等級來表示一致性程度，Kappa 係數越高相對的模型預測的一致程度越高，也代表模型的可靠程度，而一般研究的模型方法會期許達到高度的一致性（substantial）以上的水準，如表 3-3 所呈現。Kappa 係數的數學表達式如公式 3-5 所示， $O_{i,j}$ 代表第 i 類判斷為第 j 類的數量， $\omega_{i,j}$ 的數學表達式如公式 3-6 所示：

$$\text{Kappa} = 1 - \frac{\sum_{i,j} \omega_{i,j} O_{i,j}}{\sum_{i,j} \omega_{i,j} E_{i,j}} \quad (\text{公式 3-5})$$

$$\omega_{i,j} = \frac{(i-j)^2}{(N-1)^2} \quad (\text{公式 3-6})$$

表 3-3：Kappa 係數對模型預測一致性程度的五個評級

Kappa 係數	一致性程度
0 ~ 0.20	極低的一致性 (slight)
0.21 ~ 0.40	一般的一致性 (fair)
0.41 ~ 0.60	中等的一致性 (moderate)
0.61 ~ 0.80	高度的一致性 (substantial)
0.81 ~ 1.00	幾乎完全一致 (almost perfect)

七、 混淆矩陣 (Confusion Matrix)

混淆矩陣也是常用來評估分類模型好壞的評估方法。混淆矩陣是具有實際值和預測值兩個維度的矩陣，矩陣中的每一列代表著一個類別的實際預測，每一行則是表示實際的類別的實例。混淆矩陣的示例如表 3-4 所示：

表 3-4：混淆矩陣示例

		實際為真	實際為假
		Positive	Negative
預測為真	Positive	TP	FP (Type II)
預測為假	Negative	FN (Type I)	TN

第肆章 實驗結果

第一節 實驗環境

本論文實驗環境配置如表 4-1。電腦硬體所使用的運算處理器為 Intel (R) Core (TM) i9-9900K CPU @ 3.60GHz、圖形處理器為 NVIDIA GeForce RTX 2080 Ti 11G、記憶體容量有 64GB；軟體配置方面，作業系統環境是 Windows 10 專業版 64 位元；程式撰寫所使用的平台為 Jupyter Notebook 6.4.6；所使用的程式語言為 Python 3.7.11；深度學習框架使用 Tensorflow-gpu 2.8.0、Keras 2.8.0。

表 4-1：本論文實驗硬體與軟體環境

實驗環境配置	規格
作業系統	Windows 10 專業版 64 位元
處理器	Intel (R) Core (TM) i9-9900K CPU @ 3.60GHz
圖形處理器	NVIDIA GeForce RTX 2080 Ti 11G
記憶體	64GB
程式撰寫平台	Jupyter Notebook 6.4.6
程式語言	Python 3.7.11
深度學習框架	Tensorflow-gpu 2.8.0、Keras 2.8.0

第二節 糖尿病視網膜病變實驗數據集分析

本研究實驗使用 APTOS 2019 和 Messidor 2 兩種數據集來驗證本研究之方法系統效能，上述數據集皆於第貳章文獻探討中常見的公開數據集提及。APTOS 2019 和 Messidor 2 皆由多個眼科專家依據 ICDRSS 標準來標記的五分類數據集，其提供的類別標籤會作為本論文實驗數據集的分類方式。在與 IDRiD、EyePACS、DDR 等數據集比較後，可得知 APTOS 2019 與 Messidor 2 的五種分類於訓練集的總圖像數量的佔比上結構較接近，如圖 2-1 和圖 2-2 所示。

本研究所使用的 APTOS 2019 和 Messidor 2 數據集劃分方式：首先把整個資料集分為訓練集約 80%和測試集約 20%，再將上述的訓練集分割 20%出來作為驗證集。依據上述數據集劃分方法得到如表 4-2、表 4-3 所示訓練集、驗證集、測試集劃分統計表格，數據集的類別沿用圖 1-1 的分類依該順序劃分成 Class 0 至 Class 4。

表 4-2：本論文實驗 APTOS 2019 數據集劃分統計

類別	數量 (佔比)	資料集劃分		
		訓練集	驗證集	測試集
Class 0	1,805 (49.29%)	1,157	289	359
Class 1	999 (27.28%)	631	157	211
Class 2	370 (10.10%)	238	59	73
Class 3	295 (8.06%)	195	49	51
Class 4	193 (5.27%)	123	31	39

表 4-3：本論文實驗 Messidor 2 數據集劃分統計

類別	數量 (佔比)	資料集劃分		
		訓練集	驗證集	測試集
Class 0	1,017 (58.31%)	645	161	211
Class 1	346 (19.84%)	229	57	60
Class 2	270 (15.48%)	169	42	59
Class 3	75 (4.30%)	48	12	15
Class 4	36 (2.06%)	25	7	4

第三節 模型參數設定

本研究使用第貳章第三節的六種深度學習分類模型，每種模型的皆作為圖 3-4 本論文訓練架構的基底預訓練模型，模型的訓練次數以 100 個 epochs 為上限，設置 callbacks 函數採用 early stopping 方法監控最小驗證集損失值的方式，保存該次模型最佳訓練效能。本研究實驗 callbacks 函數除了使用 early stopping 之外，還有使用 ModelCheckpoint 方法來監控最佳的驗證集特異性（Specificity）的數值保存最佳模型權重，再搭配 ReduceLROnPlateau 方法自動監控驗證集特異性（Specificity）的數值降低到適合的學習率（Learning Rate）以利模型加速收斂。所有訓練過程的 Batch Size 參數設定為 8，模型均採用 456 * 456 作為影像輸入的尺寸大小。本研究模型使用 RectifiedAdam[40]作為優化器（optimizer）的函數，它是一種自動暖身版本的 Adam 方法，依據自適應學習率（Adaptive Learning Rate）的方差值（Variance）來修正學習率（Learning Rate），增加模型訓練的穩定性。類別權重參數 Class Weights 設定依據 Class 0 至 Class 4 的比例調整每一個類別各自的訓練權重，若該類別的樣本數較多，該類別的訓練權重就會較低，反之樣本數較少的訓練權重就會較高，模型會重點學習那些權重較高的樣本，以解決第貳章第四節提到的數據不平衡導致模型分類效能差問題。模型的損失函數與傳統的分類模型不同，並非使用 Categorical Cross Entropy

Loss，而是採用 Categorical Focal Loss，該方法於第貳章第四節提到過，用於樣本失衡的數據集訓練時，原理類似設置類別權重參數 Class Weights，主要目的為讓模型訓練時專注於樣本數較少的類別上。

第四節 實驗結果

本研究實驗會以第參章第四節提到七種系統效能評估方法來評價本研究使用的影像增強之融合技術與六種深度學習模型組合，首先評估本研究方法在 APTOS 2019 數據集上的表現後，再把訓練過 APTOS 2019 數據集的模型權重遷移學習的方式訓練 Messidor 2 數據集，檢視本研究方法於兩種數據集訓練後的系統效能差異。再來比較有無使用類別權重參數 Class Weights 和損失函數 Categorical Focal Loss 的模型評估結果差異。最後使用相同數據集的條件下，跟其他研究比較系統效能。

表 4-4、表 4-5 分別為在 APTOS 2019 和 Messidor 2 數據集上，本研究使用的影像增強之融合技術和六種深度學習模型組合的系統評估結果。

可以看到 DenseNet121 在 APTOS 2019 數據集表現上是最佳的，除了精確率 (Precision) 比 Xception 略差之外，其他大部分的評估指標皆為最優分數，其中二次加權 Kappa 係數 (Quadratic Weighted Kappa) 接近於 0.9，第參章第四節提到過，這樣的評分達到了最佳的 Kappa 評

級幾乎完全一致 (almost perfect)。六種深度學習分類模型的靈敏度

(Sensitivity) 及特異度 (Specificity) 都超過 0.99 接近 1 的程度，整體

來看本研究的影像增強方法在每種模型的表現都很好無相差甚大的。

表 4-4：本研究使用的影像增強之融合技術與六種深度學習模型組合

在 APTOS 2019 數據集上的系統評估結果

評估指標 模型	Accuracy	Precision	Sensitivity	Specificity	Quadratic Weighted Kappa
ResNet50v2	0.924	0.861	0.991	0.995	0.863
DenseNet121	0.930	0.867	0.998	0.997	0.897
InceptionV3	0.897	0.856	0.997	0.990	0.820
Xception	0.919	0.870	0.995	0.996	0.876
MobileNetV2	0.912	0.830	0.997	0.995	0.863
Inception ResNetV2	0.918	0.825	0.991	0.995	0.862

在 Messidor 2 數據集的表現上，InceptionResNetV2 的二次加權 Kappa 係數會明顯略高於其他模型，達到模型預測高度的一致性 (substantial) 的評級。六種模型的靈敏度 (Sensitivity) 除了 MobileNetV2 落在 0.96 之外，其他模型皆達到 0.98~0.99 的評分，特異度 (Specificity) 最高分只有 0.96，準確率 (Accuracy) 明顯差了 4%~9%，精確率 (Precision) 最高只有 0.8，相較於 APTOS 2019 數據集的表現上，判斷錯誤情況較多。

表 4-5：本研究使用的影像增強之融合技術與六種深度學習模型組合在 Messidor 2 數據集上的系統評估結果

評估指標 模型	Accuracy	Precision	Sensitivity	Specificity	Quadratic Weighted Kappa
ResNet50v2	0.840	0.800	0.991	0.906	0.640
DenseNet121	0.859	0.729	0.997	0.947	0.678
InceptionV3	0.814	0.572	0.989	0.873	0.565
Xception	0.869	0.795	0.991	0.962	0.661
MobileNetV2	0.840	0.641	0.969	0.916	0.580
Inception ResNetV2	0.879	0.757	0.994	0.970	0.738

更近一步的分析本研究的方法在 APTOS 2019、Messidor 2 數據集訓練上的差異，下述舉 DenseNet121、InceptionResNetV2 模型來比較混淆矩陣的評估效果，如圖 4-1、圖 4-2、圖 4-3、圖 4-4 所示，在 APTOS 2019 數據集的分類效能上，DenseNet121 和 InceptionResNetV2 對於 Class 4 會有較高的錯誤分類，Class 0 幾乎沒有分類錯誤的情況。在 Messidor 2 數據集上的表現，除了 Class 0 的分類效果還不錯外，其他分類效果都不甚理想，Class 1、Class 2 和 Class 4 很明顯的模型無法有效的正確分類，其中 Class 4 誤判為 Class 3 的情況非常多。

DenseNet121、InceptionResNetV2 模型的 ROC 曲線圖如圖 4-5、圖 4-6、圖 4-7、圖 4-8 所示，可得知在 APTOS 2019 數據集上，對於樣本數較少數的 Class 3 和 Class 4 模型的分類結果稍微較差。Messidor 2 數據集的很明顯的表示 DenseNet121 和 InceptionResNetV2 模型在 Class 1 和 Class 4 的表現會較差，其中 Class 4 分類效率很不理想。

對於上述結果的分析，初步的推測為 Messidor 2 相較於 APTOS 2019 數據集的樣本數為較少數（Messidor 2 總樣本數 1,774 張；APTOS 2019 總樣本數 3,662 張）的關係，Class 0 以外的類別總樣本數偏少，其中 Class 3 和 Class 4 加起來只有將近百張的樣本數而已，其他可能原因為相片品質不一、眼科專家的標註評估方式有所差異，總結上述可能為導致兩種數據集的系統評估結果有所不同的因素。




圖 4-1：本研究方法使用 APTOS 2019 數據集

訓練 DenseNet121 模型的混淆矩陣

資料來源：本研究繪製




圖 4-2：本研究方法使用 APTOS 2019 數據集

訓練 InceptionResNetV2 模型的混淆矩陣

資料來源：本研究繪製




圖 4-3：本研究使用方法使用 Messidor 2 數據集

訓練 DenseNet121 模型的混淆矩陣

資料來源：本研究繪製




圖 4-4：本研究使用方法使用 Messidor 2 數據集

訓練 InceptionResNetV2 模型的混淆矩陣

資料來源：本研究繪製




圖 4-5：本研究使用 APTOS 2019 數據集

訓練 DenseNet121 模型的 ROC Curve 圖

資料來源：本研究繪製




圖 4-6：本研究使用 APTOS 2019 數據集
訓練 InceptionResNetV2 模型的 ROC Curve 圖

資料來源：本研究繪製




圖 4-7：本研究使用 Messidor 2 數據集

訓練 DenseNet121 模型的 ROC Curve 圖

資料來源：本研究繪製




圖 4-8：本研究使用方法使用 Messidor 2 數據集
訓練 InceptionResNetV2 模型的 ROC Curve 圖

資料來源：本研究繪製

下面比較使用深度學習模型 DenseNet121 訓練 APTOS 2019 數據集條件下，有無設置類別權重參數 Class Weights 和損失函數 Categorical Focal Loss（簡稱類別權重方法）的模型評估結果差異。圖 4-9、圖 4-10 為未設定類別權重方法（Class Weights 及 Categorical Focal Loss 皆未設置）之結果；圖 4-11、圖 4-12 為僅設置損失函數 Categorical Focal Loss，且無設置類別權重參數 Class Weights 之結果；圖 4-13、圖 4-14

為僅設置類別權重參數 Class Weights，且無設置損失函數 Categorical Focal Loss 之結果；圖 4-15、圖 4-16 則為有設定類別權重方法（Class Weights 及 Categorical Focal Loss 皆有設置）之結果。

圖 4-11、圖 4-12、圖 4-13 及圖 4-14，這四張圖為僅設置其中一種類別權重方法的結果。可以得知任一種類別權重方法的設置，不太會影響到 Class 0 的分類效能，此實驗結果的關鍵在於 Class 1 至 Class 4 分類效能上。僅設置類別權重參數 Class Weights 很明顯的可以改善 Class 1 至 Class 4 分類低落的問題（與圖 4-9 和圖 4-10 結果比較），明顯的改善模型將大多數圖像誤判為 Class 2 的問題，大幅提高 Class 1、Class 3 的分類效能，雖然 Class 4 的分類效能還是略遜於其他分類。僅設置損失函數 Categorical Focal Loss，跟圖 4-9 和圖 4-10 比較單看結果，會認為設置 Focal Loss 是無意義的，因為效果比兩種類別權重方法都未設置的情況更糟糕，模型的分類效能偏重都傾向 Class 2，圖像誤判為 Class 2 的比例增加。但再來看圖 4-16 兩種類別權重方法皆有設置的混淆矩陣結果，很明顯的發現模型在 Class 1 至 Class 4 的分類性能變得更好了，與圖 4-14 僅設定 Class Weights 相比，在 Class 1 及 Class 3 誤判為 Class 2 的情況趨緩了許多，也就是說單獨設置損失函數 Categorical Focal Loss 可能對模型沒有貢獻，但他可以輔助有設置類別權重參數 Class Weights 的模型提高總體的分類性能。

最後比較兩種類別權重方法皆設置和皆未設置的結果，由圖 4-9 和圖 4-15 比較結果顯示，Class 3、Class 4 在未設置類別權重方法的情況下分類效率降低非常明顯，Class 3、Class 4 的樣本數也是最低的兩個類別，並且由圖 4-10 及圖 4-16 混淆矩陣得知，大多錯誤的分類都誤判為 Class 2，模型在未設置類別權重方法的情況下，除 Class 0 以外的樣本，會誤判 Class 2 跟其他三種分類的特徵差異。且模型訓練過程中是否設置類別權重方法，雖然基本上不影響最多樣本數的 Class 0 分類性能，但隨著該類別樣本的佔比越低，模型對此的分類效率會越低，模型沒有辦法有效率地去學習那些佔比較低的樣本。






圖 4-9：未設定類別權重方法的 ROC Curve 圖

資料來源：本研究繪製




圖 4-10：未設定類別權重方法的混淆矩陣

資料來源：本研究繪製




圖 4-11：僅設定 Categorical Focal Loss 的 ROC Curve 圖

資料來源：本研究繪製




圖 4-12：僅設定 Categorical Focal Loss 的混淆矩陣

資料來源：本研究繪製




圖 4-13：僅設定 Class Weights 的 ROC Curve 圖

資料來源：本研究繪製




圖 4-14：僅設定 Class Weights 的混淆矩陣

資料來源：本研究繪製




圖 4-15：已設定類別權重方法的 ROC Curve 圖

資料來源：本研究繪製




圖 4-16：已設定類別權重方法的混淆矩陣

資料來源：本研究繪製

本研究使用的影像增強之融合技術架構（圖 3-2）在第參章第二節有提到，該架構比較特殊的地方為加入了 Retinex 影像增強算法 MSRCR，它較常用於視神經盤分割、視網膜血管分割、血管分類的任務上，這是本研究跟其他相關分級研究比較，在影像增強技術的前處理步驟上有差異的地方，以下探討本研究使用影像增強之融合技術架構有無加入 MSRCR 轉換方法的差異，以證明 MSRCR 轉換方法在圖 3-2 的架構上的貢獻程度。

圖 4-17 為使用圖 3-2 的影像增強之融合架構不加入 MSRCR 轉換方法作為影像前處理步驟，並在 APTOS 2019 數據集上訓練 DenseNet121 模型。圖 4-17 與圖 4-1（圖 3-2 架構未去除 MSRCR 轉換步驟）相比，可以得知加入 MSRCR 轉換方法可以使模型將影像誤判為 Class 2 的情況降低，在圖 4-17 當中，模型會很明顯的將部分的影像誤判為 Class 2，因此加入 MSRCR 轉換方法確實能使模型總體分類性能更穩定。




圖 4-17：本研究使用的圖 3-2 架構去除 MSRCR 轉換使用

DenseNet121 訓練結果的混淆矩陣

資料來源：本研究繪製

為了驗證本研究方法貢獻程度，表 4-6、表 4-7 為本研究方法最佳模型與其他使用相同數據集（APTOS 2019 和 Messidor 2）的研究系統效能的評估比較結果表格，表 4-6、表 4-7 的數據因不是每篇研究都會附上系統原始碼供讀者再現實驗，故表格中所整理的皆為直接引用該研究中最優的研究數據。在 APTOS 2019 數據集比較上，本研究方法在靈敏度（Sensitivity）及特異度（Specificity）的表現上，都接近 0.99 至 1 範圍內，且在五種評估指標中，評分皆有不錯的表現。Messidor 2 數據集的表現上，除了精確率（Precision）的表現比較不理想，在靈敏度（Sensitivity）及特異度（Specificity）的表現上，比起其他研究很明顯較於穩定。

表 4-6：使用 APTOS 2019 數據集與其他研究進行比較

研究來源	Accuracy	Precision	Sensitivity	Specificity	Quadratic Weighted Kappa
[47]	0.86	0.85	-	-	-
[48]	0.92	0.85	0.99	0.99	-
[22]	0.84	0.74	-	-	-
[49] VGG19	0.97	0.97	0.96	0.98	-
[49] DenseNet121	0.90	0.88	0.87	0.92	-
[50]	0.84	-	0.99	0.99	0.89
[51]	0.83	0.69	0.67	-	0.74
本研究方法	0.93	0.86	0.99	0.99	0.89

表 4-7：使用 Messidor 2 數據集與其他研究進行比較

研究來源	Accuracy	Precision	Sensitivity	Specificity
[49] Inception ResNetV2	0.72	0.58	0.47	0.81
[49] InceptionV3	0.77	0.70	0.30	0.93
[52]	-	-	0.81	0.86
[48]	0.80	0.85	0.89	0.90
[53]	0.94	-	0.97	0.98
本研究方法	0.87	0.75	0.99	0.97

第伍章 結論與未來展望

第一節 結論

根據世界衛生組織（WHO）的預測，在 2030 年糖尿病視網膜病變將會是全球第四大失明的原因，在印度有將近七千萬的糖尿病人口，視網膜病變的發生率有 18%，在七千萬的病患中，有接受過篩查的佔比不到 9%。糖尿病視網膜病變的患者數逐年成長中，眼科專家的培育可能需要 8 至 10 年，醫療的人力資源遠跟不上病患人口的成長，傳統的人工眼睛疾病篩檢方式效率低落，而且在醫療資源落後的鄉村或國家會有更多無法得到及時治療的視網膜病變患者。

近年來已經有許多結合人工智慧的視網膜病變篩查技術被提出，且已經實際應用在醫療領域上，自動篩查的方法有效解決傳統人工診斷的問題，協助眼科專家更快的進行疾病的診斷，也解決了偏鄉地區醫療資源不足導致的篩查效率差的問題，讓糖尿病視網膜病變的患者早期治療的機會大幅增加。

本研究使用的影像增強之融合技術用於提高六種深度學習模型（ResNet50v2、DenseNet121、InceptionV3、Xception、MobileNetV2、InceptionResNetV2）的特徵提取效率，分類出健康的視網膜以及四種不同嚴重程度的視網膜病變，並搭配設置類別權重參數 Class Weights 和

損失函數 Categorical Focal Loss 等類別權重方法來提高模型辨別各類別視網膜影像的準確率，即使數據集的某一項類別的樣本數稀少也可以有效的進行分類。

本研究實驗第一步使用的影像增強之融合技術和六種深度學習模型組合，於 APTOS 2019 和 Messidor 2 數據集（影像的總數量分別為 3,662 張、17,44 張）上訓練並評估後，依據其評估指標比較系統性能。APTOS 2019 數據集的訓練結果，最佳的模型為 DenseNet121，靈敏度（Sensitivity）為 0.998，特異度（Specificity）則為 0.997，二次加權 Kappa 係數（Quadratic Weighted Kappa）為 0.897，於 Kappa 係數對模型預測的評級達到幾乎完全一致（almost perfect），本實驗的結果也證明跟其他研究比較也有著優良的表現水準。

於 APTOS 2019 數據集訓練得到的模型權重，對 Messidor 2 數據集進行遷移學習的方式訓練，所得到的結果雖然較差，系統性能最佳的模型組合為 InceptionResNetV2，其靈敏度為 0.994，特異度為 0.969，二次加權 Kappa 係數為 0.738，於 Kappa 係數對模型預測的評級達到高度的一致性（substantial），其系統性能的表現比在 APTOS 數據集上訓練的最佳成果再降一個評級。但在靈敏度及特異度最高的評分還是有穩定落在 0.97 ~ 0.99 區間內，模型還是能夠有效的將有無糖尿病視網膜病變特徵區分出來，並且跟其他研究的方法相比，結果還是較優異

的，本研究的方法在遷移學習的成效還是有一定的水準上。

本研究使用的影像增強之融合技術在 APTOS 2019 和 Messidor 2 數據集的訓練成果總結如以下：

1. 兩種數據集的最佳組合在 APTOS 2019 數據集上最佳的前三名模型是 DenseNet121、Xception、ResNet50v2；Messidor 2 數據集則是 InceptionResNetV2、Xception、DenseNet121。可以發現 DenseNet121、Xception 系統效能能在兩種數據集的表現比較穩定。
2. 兩種數據集的準確率（Accuracy）相差了 4~9%左右；靈敏度大部分都在 0.99 左右，沒有太大的差距；特異度差了 3~10%左右；最佳模型的二次加權 Kappa 係數差了 15%，相距一個評級。
3. DenseNet121 在 APTOS 2019 數據集的訓練結果上，很明顯的 Class 2 和 Class 4 誤判的情況較多；DenseNet121 在 Messidor2 數據集的訓練結果上，則是 Class 1 和 Class 4 誤判的情況較多，雖然樣本數多寡會影響模型分類的準確率，但在兩種數據集的訓練上，誤判最多的分類並不盡然是樣本數最少（Class 3 和 Class 4）的類別。
4. 本研究最大的優勢在靈敏度和特異度的表現上跟其它研究相比有較優秀的成績，靈敏度和特異度指標在 DR 相關的綜述研究[9][45][46]中皆有提到是 DR 研究常用的評估指標，且在綜述研究[45]中整理的研究數據可以看出大多研究都會使用靈敏度和特異度來評

估系統的可信度。

最後在本研究的數據不平衡實驗中，有無設置類別權重參數 Class Weights 和損失函數 Categorical Focal Loss 對模型還是有明顯的貢獻。單純區分有無糖尿病視網膜病變特徵時效果不明顯，會影響的是那些樣本數佔比較低的類別在模型分類上的效能，各分類的樣本佔比越懸殊差距也越明顯，這證明若使用類別權重方法去訓練模型，則模型的可信度會較佳。總結類別權重參數 Class Weights 和損失函數 Categorical Focal Loss 在模型的個別貢獻上，可以得知單一的去設置損失函數 Categorical Focal Loss 對模型並無貢獻，但是它可以在已經設置類別權重參數 Class Weights 情況下做到輔助的效果，有效的提升模型整體的分類效能，尤其是在 Class 1 和 Class 3 的分類效率上有所貢獻。

第二節 未來展望

本研究實驗最佳結果的系統評估分數與其他論文比較上，有的評估指標分數會略高，大部分的評估指標的分數則是差不多高。未來的研究方向可朝以下幾項去嘗試：

1. 本實驗的深度學習模型在特徵提取效果上各有優缺點，或許可以建構一個更適合提取多分類的視網膜病變特徵的模型。
2. 對於視網膜病變數據集可以依據其分類的病變特徵去增強細節或

分割特徵，例如微動脈瘤、血塊、滲出物的特徵細節。

3. 除了使用影像增強技術，也可以搭配其他顏色特徵或紋理特徵來進行特徵提取。
4. 關於數據不平衡的解決方案，也許有更好的方法可以提高各類別的分類效能，尤其是小樣本類別分類效率低落的問題。



參考文獻

英文文獻

- [6] V. Bellemao *et al.*, "Artificial intelligence screening for diabetic retinopathy: the real-world emerging application," *Current Diabetes Reports*, vol. 19, pp. 1-12, 2019.
- [7] V. Bellemao *et al.*, "Artificial intelligence using deep learning to screen for referable and vision-threatening diabetic retinopathy in Africa: a clinical validation study," *The Lancet Digital Health*, vol. 1, no. 1, pp. e35-e44, 2019.
- [8] A. Grzybowski, P. Brana, G. Lim, P. Ruamviboonsuk, G. S. Tan, M. Abramoff, and D. S. Ting, "Artificial intelligence for diabetic retinopathy screening: a review," *Eye*, vol. 34, no. 3, pp. 451-460, 2020.
- [9] N. Tsiknakis *et al.*, "Deep learning for diabetic retinopathy detection and classification based on fundus images: A review," *Computers in Biology and Medicine*, vol. 135, pp. 104599, 2021/08/01/ 2021.
- [10] R. S. Biyani and B. M. Patre, "Algorithms for red lesion detection in Diabetic Retinopathy: A review," *Biomedicine & Pharmacotherapy*, vol. 107, pp. 681-688, 2018/11/01/ 2018.
- [11] W. L. Alyoubi, W. M. Shalash, and M. F. Abulkhair, "Diabetic retinopathy detection through deep learning techniques: A review," *Informatics in Medicine Unlocked*, vol. 20, pp. 100377, 2020/01/01/ 2020.
- [14] P. Porwal, S. Pachade, R. Kamble, M. Kokare, G. Deshmukh, V. Sahasrabuddhe, and F. Meriaudeau, "Indian Diabetic Retinopathy Image Dataset (IDRiD): A Database for Diabetic Retinopathy Screening Research," *Data*, vol. 3, no. 3, pp. 25, 2018.
- [17] B. Graham, "Kaggle diabetic retinopathy detection competition report," *University of Warwick*, pp. 24-26, 2015.
- [18] J. de La Torre, A. Valls, and D. Puig, "Diabetic retinopathy detection through image analysis using deep convolutional neural networks," in *Artificial Intelligence Research and Development*: IOS press, pp. 58-63, 2016.
- [19] M. Zhou, K. Jin, S. Wang, J. Ye, and D. Qian, "Color Retinal Image

- Enhancement Based on Luminosity and Contrast Adjustment," *IEEE Transactions on Biomedical Engineering*, vol. 65, no. 3, pp. 521-527, 2018.
- [20] Y. Chang, C. Jung, P. Ke, H. Song, and J. Hwang, "Automatic Contrast-Limited Adaptive Histogram Equalization With Dual Gamma Correction," *IEEE Access*, vol. 6, pp. 11782-11792, 2018.
 - [21] Sonali, S. Sahu, A. K. Singh, S. P. Ghrera, and M. Elhoseny, "An approach for de-noising and contrast enhancement of retinal fundus image using CLAHE," *Optics & Laser Technology*, vol. 110, pp. 87-98, 2019/02/01/ 2019.
 - [22] M. R. Islam *et al.*, "Applying supervised contrastive learning for the detection of diabetic retinopathy and its severity levels from fundus images," *Computers in Biology and Medicine*, vol. 146, pp. 105602, 2022/07/01/ 2022.
 - [23] G. Cao, L. Huang, H. Tian, X. Huang, Y. Wang, and R. Zhi, "Contrast enhancement of brightness-distorted images by improved adaptive gamma correction," *Computers & Electrical Engineering*, vol. 66, pp. 569-582, 2018/02/01/ 2018.
 - [24] M. Veluchamy and B. Subramani, "Image contrast and color enhancement using adaptive gamma correction and histogram equalization," *Optik*, vol. 183, pp. 329-337, 2019/04/01/ 2019.
 - [25] D. J. Jobson, Z. Rahman, and G. A. Woodell, "A multiscale retinex for bridging the gap between color images and the human observation of scenes," *IEEE Transactions on Image Processing*, vol. 6, no. 7, pp. 965-976, 1997.
 - [26] K. He, X. Zhang, S. Ren, and J. Sun, "Identity mappings in deep residual networks," in *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14*: Springer, pp. 630-645, 2016.
 - [27] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 4700-4708, 2017.
 - [28] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2818-2826, 2016.
 - [29] F. Chollet, "Xception: Deep learning with depthwise separable

- convolutions," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 1251-1258, 2017.
- [30] A. G. Howard *et al.*, "Mobilenets: Efficient convolutional neural networks for mobile vision applications," *arXiv preprint arXiv:1704.04861*, 2017.
 - [32] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. A. Alemi, "Inception-v4, inception-resnet and the impact of residual connections on learning," in *Thirty-first AAAI conference on artificial intelligence*, 2017.
 - [33] M. Saini and S. Susan, "Deep transfer with minority data augmentation for imbalanced breast cancer dataset," *Applied Soft Computing*, vol. 97, pp. 106759, 2020/12/01/ 2020.
 - [34] M. Saini and S. Susan, "Diabetic retinopathy screening using deep learning for multi-class imbalanced datasets," *Computers in Biology and Medicine*, vol. 149, pp. 105989, 2022/10/01/ 2022.
 - [35] H. Li, X. Dong, W. Shen, F. Ge, and H. Li, "Resampling-based cost loss attention network for explainable imbalanced diabetic retinopathy grading," *Computers in Biology and Medicine*, vol. 149, pp. 105970, 2022/10/01/ 2022.
 - [36] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE international conference on computer vision*, pp. 2980-2988, 2017.
 - [40] L. Liu, H. Jiang, P. He, W. Chen, X. Liu, J. Gao, and J. Han, "On the variance of the adaptive learning rate and beyond. arXiv 2019," *arXiv preprint arXiv:1908.03265*, 2019.
 - [41] M. R. K. Mookiah *et al.*, "A review of machine learning methods for retinal blood vessel segmentation and artery/vein classification," *Medical Image Analysis*, vol. 68, pp. 101905, 2021.
 - [42] Y. E. Almalki *et al.*, "Enhancement of Medical Images through an Iterative McCann Retinex Algorithm: A Case of Detecting Brain Tumor and Retinal Vessel Segmentation," *Applied Sciences*, vol. 12, no. 16, pp. 8243, 2022.
 - [43] Y. Jiang, Z. Ma, C. Wu, Z. Zhang, and W. Yan, "RSAP-Net: joint optic disc and cup segmentation with a residual spatial attention path module and MSRCR-PT pre-processing algorithm," *BMC bioinformatics*, vol. 23, no. 1, pp. 523, 2022.
 - [44] Q. Mirsharif, F. Tajeripour, and H. Pourreza, "Automated characterization of blood vessels as arteries and veins in retinal images," *Computerized Medical Imaging and Graphics*, vol. 37, no.

- 7-8, pp. 607-617, 2013.
- [45] D. Nagpal, S. N. Panda, M. Malarvel, P. A. Pattanaik, and M. Zubair Khan, "A review of diabetic retinopathy: Datasets, approaches, evaluation metrics and future trends," *Journal of King Saud University - Computer and Information Sciences*, vol. 34, no. 9, pp. 7138-7152, 2022/10/01/ 2022.
 - [46] N. Salamat, M. M. S. Missen, and A. Rashid, "Diabetic retinopathy techniques in retinal images: A review," *Artificial Intelligence in Medicine*, vol. 97, pp. 168-188, 2019/06/01/ 2019.
 - [47] M. Tian, H. Wang, Y. Sun, S. Wu, Q. Tang, and M. Zhang, "Fine-grained attention & knowledge-based collaborative network for diabetic retinopathy grading," *Heliyon*, vol. 9, no. 7, pp. e17217, 2023/07/01/ 2023.
 - [48] Fatima, M. Imran, A. Ullah, M. Arif, and R. Noor, "A unified technique for entropy enhancement based diabetic retinopathy detection using hybrid neural network," *Computers in Biology and Medicine*, vol. 145, pp. 105424, 2022/06/01/ 2022.
 - [49] S. El-Ateif and A. Idri, "Single-modality and joint fusion deep learning for diabetic retinopathy diagnosis," *Scientific African*, vol. 17, pp. e01280, 2022/09/01/ 2022.
 - [50] A. Sugeno, Y. Ishikawa, T. Ohshima, and R. Muramatsu, "Simple methods for the lesion detection and severity grading of diabetic retinopathy by image processing and transfer learning," *Computers in Biology and Medicine*, vol. 137, pp. 104795, 2021/10/01/ 2021.
 - [51] G. Yue, Y. Li, T. Zhou, X. Zhou, Y. Liu, and T. Wang, "Attention-Driven Cascaded Network for Diabetic Retinopathy Grading from Fundus Images," *Biomedical Signal Processing and Control*, vol. 80, pp. 104370, 2023/02/01/ 2023.
 - [52] G. Saxena, D. K. Verma, A. Paraye, A. Rajan, and A. Rawat, "Improved and robust deep learning agent for preliminary detection of diabetic retinopathy using public datasets," *Intelligence-Based Medicine*, vol. 3-4, pp. 100022, 2020/12/01/ 2020.
 - [53] P. Modi and Y. Kumar, "Smart detection and diagnosis of diabetic retinopathy using bat based feature selection algorithm and deep forest technique," *Computers & Industrial Engineering*, vol. 182, pp. 109364, 2023/08/01/ 2023.

網站文獻

- [1] 高雄榮民總醫院眼科部-糖尿病視網膜病變介紹
https://org.vghks.gov.tw/oph/News_Content.aspx?n=08ADECCA86537C23&sms=5D2CDAEC8F5F19BB&s=49589CE1E2730CC8
- [2] 衛生福利部雙和醫院-糖尿病視網膜病變
<https://shh.tmu.edu.tw/page/HealthDetail.aspx?deptCode=10&seqNo=20180124190503284482>
- [3] 新竹台大分院眼科部-糖尿病性視網膜病變(Diabetic retinopathy)
https://www.hch.gov.tw/?aid=626&pid=36&page_name=detail&iid=265
- [4] 中華民國糖尿病學會-台灣糖尿病宣言 http://www.endo-dm.org.tw/DB/book/85/1101016_%E7%B3%96%E5%B0%BF%E7%97%85%E5%AE%A3%E8%A8%80_v5-2.pdf
- [5] 工業技術研究院-工業技術與資訊月刊 328 期精準偵測糖尿病視網膜病變
https://www.itri.org.tw/ListStyle.aspx?DisplayStyle=18_content&SiteID=1&MmmID=1036452026061075714&MGID=1035141037542361335
- [12] APTOS-2019 dataset
<https://www.kaggle.com/datasets/mariaherrerot/aptos2019>
- [13] Messidor-2 Dataset <https://www.adcis.net/en/third-party/messidor2/>
- [15] Kaggle DR dataset (EyePACS)
<https://www.kaggle.com/datasets/mariaherrerot/eyepacspreprocess>
- [16] DDR dataset
<https://www.kaggle.com/datasets/mariaherrerot/ddrdataset>
- [31] 輕量級模型-MobileNets
<https://ithelp.ithome.com.tw/articles/10263847>
- [37] Tensorflow CategoricalFocalCrossentropy
https://www.tensorflow.org/api_docs/python/tf/keras/losses/CategoricalFocalCrossentropy

[38] AI Facial Expression Recognition: Data, Model, Application 系列第

17 篇 class weights 類別權重

<https://ithelp.ithome.com.tw/articles/10269361?sc=iThomeR>

[39] scikit-learn compute class weights https://scikit-learn.org/stable/modules/generated/sklearn.utils.class_weight.compute_class_weight.html

