

文章编号:1007-2780(2022)12-1626-10

基于代价敏感正则化和 EfficientNet 的糖尿病 视网膜病变分类方法

王明智, 马志强*, 赵锋锋, 王永杰, 郭继峰

(东北林业大学 信息与计算机工程学院, 黑龙江 哈尔滨 150040)

摘要:糖尿病视网膜病变(DR)是糖尿病的常见并发症,是目前世界范围内导致失明的主要疾病之一。临床的早期阶段很难检测到DR。本文提出一种基于卷积神经网络的计算机辅助诊断方法,根据眼底图像自动分类DR的严重程度。采用多种预处理方法提高输入图像的质量,并且采用多种数据增强的方法来提高数据集的均衡性。使用代价敏感正则化扩展标准分类损失函数,根据预测等级和真实等级相差程度的不同,对其施加不同的惩罚。在 ImageNet 数据集上进行预训练,从而引入迁移学习,并且使用 Softmax 激活函数的全连接层使模型获得更好的性能。基于两个数据集的实验结果表明,相较于近期学者的研究结果,该模型能够实现二次加权 kappa 分数约 5% 的改善, AUC 约 3% 的改善。将代价敏感正则化引入到 EfficientNet 网络模型可以提高糖尿病视网膜病变分类任务的准确率,能够得到很好的模型性能。

关键词:糖尿病视网膜病变;深度学习;代价敏感正则化;卷积神经网络;图像分类

中图分类号:TP391 **文献标识码:**A **doi:**10.37188/CJLCD.2022-0161

Diabetic retinopathy classification method based on cost sensitive regularization and EfficientNet

WANG Ming-zhi, MA Zhi-qiang*, ZHAO Feng-feng, WANG Yong-jie, GUO Ji-feng

(College of Information and Computer Engineering, Northeast Forestry University,
Harbin 150040, China)

Abstract: Diabetic retinopathy (DR) is a common complication of diabetes and one of the major diseases leading to blindness in the world. It is difficult to detect DR in the early clinical stage. A computer aided diagnosis method based on convolution neural network is proposed, which can automatically classify the severity of DR according to the fundus images. Various preprocessing methods are used to improve the quality of the input images and various data enhancement methods are used to improve the balance of datasets. Cost-sensitive regularization is used to expand the standard classification loss function based on EfficientNet network architecture. Depending on the degree of difference between the predicted label and

收稿日期:2022-05-11;修订日期:2022-06-07.

基金项目:国家自然科学基金(No. 61300098);黑龙江省自然科学基金(No. LH2019C003);中央高校基本科研业务费专项资金(No. 2572019BH03)

Supported by National Natural Science Foundation of China(No. 61300098); Natural Science Foundation of Heilongjiang Province(No. LH2019C003); Fundamental Research Funds for the Central Universities of China(No. 2572019BH03)

*通信联系人, E-mail:1791105996@qq.com

the ground truth label, they are applied different penalties. In addition, pre-training on ImageNet dataset is carried on to introduce transfer learning, and the full connection layer of Softmax activation functions are used to achieve better performance of the model. According to the experimental results of two datasets, compared with the recent research results, the model can achieve an improvement of about 5% in quadratic weighted kappa score and 3% in AUC. The introduction of cost-sensitive regularization into the EfficientNet network model can improve the accuracy of diabetic retinopathy classification task and obtain a good model performance.

Key words: diabetic retinopathy; deep learning; cost-sensitive regularization; convolution neural network; image classification

1 引言

糖尿病视网膜病变(Diabetic Retinopathy, DR)是最常见的视网膜疾病之一^[1],这种疾病主要是由糖尿病性微血管病引起的,它会对糖尿病患者眼睛后部视网膜的小血管造成损伤,导致视网膜组织肿胀和视力模糊。根据2021年世界卫生组织(WHO)的报告显示,全球超过4.2亿人患糖尿病,预计到2030年将上升到5.78亿^[2]。在全球的糖尿病人群中,约40%~50%可能会患有视网膜病变^[3]。值得注意的是,DR病人失明的风险性是一般健康人群的25倍,所以,在全球范围内DR是20~65岁人群失明的主要因素之一。

事实上,如果及时发现和治疗,糖尿病视网膜病变对于视力的损害是可以控制甚至避免的。由于DR的早期几乎没有明显的症状,这使得及时诊断变得非常困难。传统的检查方案效率较低,经验丰富的临床医生可以手动检查和通过眼底数字图像进行诊断。这种诊断由于不同地区医疗水平的不一致,有时会需要很长的时间。此外,诊断的结果也因不同医生的主观性会产生一定的区别,其准确性在很大程度上取决于临床医生的专业知识^[4]。通过定期眼底检查可以预防DR引起的失明。对于DR筛查的好处,部分西方国家已经形成了广泛的共识。大多数DR研究根据早期治疗糖尿病视网膜病变研究(Early Treatment Diabetic Retinopathy Study, ETDRS),使用国际临床疾病严重程度量表对DR进行分类。

在过去的10年里,研究人员已经开发了多个自动诊断系统。Pan等人^[5]设计了眼底自适应成像系统的辅助工具并取得了良好的效果。Quelleg等^[6]提出了一个模型,通过使用卷积神

经网络(Convolution Neural Network, CNN)检测DR,利用敏感度标准^[7]的修改产生热图,可视化每个像素在输出预测中的贡献。Lam等人^[8]开发了几个关于二分类、三分类和五分类任务的模型,对于“无DR”或“严重DR”的病例在敏感性和特异性方面取得了较好的表现。Khojasteh等人^[9]为了避免分割后的标识周围存在冗余边界和杂乱像素,采用关闭、打开和最后侵蚀3种形态进行了实验。然而,由于他们生成了3个输出概率映射,每种情况对应一个,因此很可能有些像素属于多种情况。Saha等人^[10]利用一种Encoder-Decoder CNN来分割病灶,他们还采用一个额外的类对应视盘,以便网络能够更好地区分它与渗出物。Zhou等人^[11]提出了一种融合多尺度特征及注意力机制的医学图像检索方法,引入注意力模块,对网络输出的特征图进行通道加权求和,提高关键特征通道的特征表达能力,使网络更能关注到图像中具有辨识性的病理特征区域。

Pang等人^[12]构建两级深度卷积神经网络,完成了原始照片的特征提取、特征组合和结果分类,提出利用弱监督学习进行细粒度图像分类的改进方法在验证集上获得了0.85的kappa分数。Galdran等人^[13]在2020年的一项研究中使用基于ResNeXt50网络的模型对DR进行分类,得到二次加权kappa分数为0.78。同年Google Health^[14]训练了一个深度学习模型,从眼底照片预测ciDME,模型受试者工作特征曲线(Receiver operating characteristic curve, ROC)下面积(AUC)值为0.89。2020年, Sun等人^[15]通过修改Inception模块的组成减少模型参数从而提升收敛速度,引入残差模块,解决了模型深度增加带来的梯度消

失和梯度爆炸等问题,提出的 DetectionNet 深度卷积神经网络对糖尿病视网膜病变患病程度等级分类任务的识别率达到 91%。Lands 等人^[16]在 2020 年利用 DenseNet 网络训练模型,该模型能够定位物体、检测物体和分割视网膜图像中的毛细血管,毛细血管异常可用于检测糖尿病患者的失明。他在 EyePACS 数据上得到了二次加权 kappa 0.81 的分数。

代价敏感正则化 (Cost Sensitive Regularization, CSR) 可应用于多种疾病的分类模型中,但很少出现在糖尿病视网膜病变检测模型中。基于上述分析,为了提高糖尿病视网膜病变分类模型的性能,本文提出基于 EfficientNet 网络的改进模型用于糖尿病视网膜病变的检测,有针对性地对眼底图像进行预处理和数据增强^[17],然后输入到模型中,模型自动提取特征、训练参数、产生分级,引入代价敏感正则化对错误的分级施加不同程度的惩罚,尽可能地纠正模型中的分级错误。同时,从 ImageNet 训练得到的迁移学习^[18]结果有利于提升模型的性能。

我们所提出的模型在 DR 主流数据集上表现出了很好的分类性能,对医生辅助诊断 DR 严重程度具有重要的参考意义。现在已有很多系统在实际生活中获得了很好的应用。EyeArt 是美国食品和药物管理局批准的商业 AI 软件,该软件在检测 DR 时的敏感度为 92%,特异性为 94%。我们所提出的模型应用于临床当中,将会

大幅减轻眼科医生的负担,同时也可以减少由于医生主观性所导致的误诊,具有非常广阔的临床应用前景。

2 改进的 EfficientNet 模型

EfficientNet 是 Google 在 ICML 2019 提出的一个神经网络模型^[19]。该模型提供了一种更有效的计算方式,并改善了最新的研究结果。通常,如果模型设计得太宽、太深或者分辨率太高,刚进行训练时,增加这些特性是有益的,但是训练很快就会达到饱和,模型的参数也会随之增加很多。通过人工去调整网络深度、网络宽度和输入图像的分辨率这 3 个参数使网络达到最佳性能是非常困难的,由于组合空间太大,人力无法穷举并验证所有可能组合的性能,因而效率不高。而在 EfficientNet 中,这些特性是按更优原则的方式扩展的,不会像传统的方法那样任意地缩放网络的维度,一切都是逐渐增加的。EfficientNet 使用了组合缩放系数,用单一的组合缩放系数 ϕ ,同时缩放网络宽度 w 、网络深度 d 和输入图像的分辨率 r ,其缩放系数分别为 α 、 β 和 γ 。在约束条件下,在 EfficientNet-B0 中最好的参数是 $\alpha = 1.2$ 、 $\beta = 1.1$ 、 $\gamma = 1.15$ 。根据算力的不同,我们提出了 B0~B7 的缩放尺度。EfficientNet-B0 模型结构如图 1 所示。




图 1 EfficientNet-B0 模型结构

Fig. 1 Model structure of EfficientNet-B0

2.1 标准损失函数改进

首先考虑模型 R 会产生预测 $R(x) = \hat{y} \in [0, 1] \times \dots \times [0, 1]$, 此预测与相应的真实标签 y 进行比较。用 y 概括地指代整体标签 $y \in L = \{0, 1, 2, 3, 4\}$, 对应的独热编码为 $y \in \{0, 1\} \times \dots \times \{0, 1\}$, 其在相应的分级下取 1, 其他分级下取 0。我们使用两种标准分类损失函数作为基本损失函数。

第一种是交叉熵损失函数 (Cross Entropy Loss Function, CE), 其定义为:

$$L_{CE}(\hat{y}, y) = - \sum_i^n y_i \log(\hat{y}_i), \quad (1)$$

式中对于一个特定的例子 (x_i, y_i) , 无论预测结果如何, 最后产生的误差将保持不变^[20]。

第二种基本损失函数是焦点损失函数 (Focal Loss Function, FL), 其定义为:

$$L_{Focal Loss}(\hat{y}, y) = - \sum_i^n y_i \alpha (1 - \hat{y}_i)^\gamma \log(\hat{y}_i), \quad (2)$$

式中 α 是加权因子, γ 是聚焦参数^[21]。Focal Loss 函数在多分类任务中已经得到广泛的应用, 它是在标准交叉熵损失函数的基础上改进得到的, 目标是克服样本类型不均匀和样本分类难度不均匀等问题。这个函数能够通过降低容易分类样本的权重, 使模型在训练的过程中更专注于难于分类的样本上。相较于正确分类中的误差, Focal Loss 对错误分类中的误差惩罚会更大。

2.2 代价敏感正则化改进

为了使模型能够在多分类任务的训练过程中惩罚不同类型的错误, 进一步改进式 (1) 的结果, 考虑使用一个惩罚代价矩阵 M , 将需要的惩罚设置到代价矩阵当中, 并且随着预测标签 $\hat{y}$ 与真实标签 y 之间的距离 $\|y - \hat{y}\|$ 的增大, 惩罚也会更大。

要想实现这种根据预测标签 $\hat{y}$ 与真实标签 y 相差的不同程度来设置不同的惩罚, 可以通过在代价矩阵 M 中的每一行编码这些惩罚, 然后计算 $\hat{y}$ 与 M 中对应行的标量积, 如式 (3) 所示:

$$H(\hat{y}, y) = \langle M(y, \cdot), \hat{y} \rangle, \quad (3)$$

给出一个带有标签 $y = k$ 和一个独热编码预测 $R(x) = [x_1, x_2, x_3]$, 代价敏感损失将通过简单的计算 $R(x)$ 与惩罚代价矩阵 M 中第 k 行的标量积实现惩罚。值得注意的是, 在不同的分类任务中, 对于不同的错误分类情况, 我们对它们的惩

罚程度也不相同。本文对糖尿病视网膜病变严重程度进行 5 分类, 根据 Krause 等人^[22]收集的关于视网膜专家之间对于受试者严重程度的分歧以及在数据集的分级过程中裁定共识信息的研究, 我们设计了具体的代价惩罚矩阵 M_d 如式 (4) 所示, 其中矩阵中数值越高, 惩罚越低; 数值越低, 惩罚越高。

$$M_d = \begin{bmatrix} 0.994 & 0.003 & 0.003 & 0 & 0 \\ 0.464 & 0.496 & 0.040 & 0 & 0 \\ 0.153 & 0.021 & 0.819 & 0.007 & 0 \\ 0 & 0 & 0.260 & 0.720 & 0.020 \\ 0 & 0 & 0 & 0.062 & 0.938 \end{bmatrix}, \quad (4)$$

然而由于目前糖尿病视网膜病变数据集各分类间的高度不平衡, 在实验中发现, 如果只使用 CSR 的损失会导致复杂的卷积神经网络陷入局部最小值, 因此, 把 CSR 作为其他标准损失函数 (CE, FL) 的正则化结合起来, 得到公式 (5):

$$\begin{cases} L(\hat{y}, y) = L_{base}(\hat{y}, y) + \theta \langle M^{(2)}(y, \cdot), \hat{y} \rangle \\ M_{ij}^{(2)} = \|i - j\|^2 \end{cases}, \quad (5)$$

式中选择了基于 L_2 规范化的代价矩阵 $M^{(2)}$, 它能最大化二次加权 kappa 分数, θ 是正则化参数。

2.3 迁移学习方法引入

迁移学习是机器学习中的一种方式, 也就是将源领域的知识转移到目标领域之中, 让目标领域可以达到更好的学习效果。一般来说, 源领域的的数据量很充足, 而目标领域数据量较小。如本文所研究的 DR 分类问题, 当涉及医疗问题时, 训练稳定且准确的模型是相当困难的, 可用的数据也非常有限。考虑到这些分类任务之间是具有关联性的, 利用迁移学习我们能够曾经获得的模型参数共享给最新的网络模型, 使模型可以更加方便地检测图像的低水平特征, 进而提高并优化模型的训练效率, 不再需要从零开始训练。

选择 EfficientNet-B3 网络作为分类任务的主要模型, 在此模型上进行具体的调整。将模型在 ImageNet 数据集上训练, 得到可以识别图像低水平特征的模型参数。随着特征图分辨率的降低, 模型通道的数量将成倍增长, 从而尽可能地提取和保留图像的语义信息, 逐渐地将图像的纹理特征组合成类别特征。在 ImageNet 上得到一个预训练好的 EfficientNet 网络模型后, 删除该网络模型顶部的全连接层, 将网络的剩余部分作为

EyePACS 和 Messidor-2 两个数据集的特征提取层。

加载 EfficientNet 网络模型,模型底层使用从 ImageNet 预先训练好的特征提取层参数。同时对顶层网络进行微调,在模型顶部添加平均池化和 dropout 为 0.2 的随机失活层,并使用 Softmax 激活函数的全连接层。将 EfficientNet-B3 输出的 1 536 张大小为 13×13 的特征图像作为顶层的输入。根据本文研究的 DR 分类问题,整个 EfficientNet 网络结构的输出具有与每个 DR 严重程度相对应的 5 个可能性值。

3 数据集及数据处理

3.1 实验数据集

本文采用 Kaggle EyePACS 作为主要数据集,它是糖尿病视网膜病变分类任务中使用最多、规模最大的公共数据集^[23]。加州医疗保健基金会提出一个比赛,创建一个自动检测糖尿病视网膜病变的程序,包含在各种成像条件下拍摄的 35 126 张高分辨率的眼底训练图像。图像由一名经验丰富的专业人员根据 ICDRDSS 评分标准^[24]进行标注。根据 DR 严重程度将图像分为 5 个等级(0,1,2,3,4),0 级图像表示没有视网膜病变的迹象,而 4 级图像则表示增生性视网膜病变。图 2 展示了眼底图像上指示性 DR 病变,图 3 展示了不同等级糖尿病视网膜病变的眼底图像。Kaggle EyePACS 训练集是非常不平衡的,0 级图像有 25 810 张,1 级图像有 2 443 张,2 级图像有 5 292 张,3 级图像有 873 张,4 级图像有 708 张,如表 1 所示。我们对数据集进行了详细的划分,将不同等级标签的图像分别分为两部分,其中 90% 用于训练网络,10% 用于测试模型性能,即数据集的 80% 作为训练集,10% 作为验证集,剩下的 10% 作为测试集。

值得注意的是,这些图像是由不同类型的成像设备在各种环境下拍摄的。由于这种可变性,数据存在模糊、聚焦、曝光、倒置、人为干扰等问题,因此在 Kaggle EyePACS 的数据集中,图像和真实标签都存在不可避免的噪声,这对任何模型的鲁棒性都有很高的要求。

我们使用 Messidor-2 作为第二测试集,该数据集包含了 874 名患者的 1 748 张图像,全部用于




图 2 眼底图像上指示性 DR 病变
Fig. 2 Indicative DR lesions on a fundus image




图 3 不同病变等级的 DR 图像。(a)正常无明显病变;(b)轻度非增生性 DR;(c)中度非增生性 DR;(d)重度非增生性 DR;(e)增生性 DR。
Fig. 3 Different levels of DR images. (a) Normal without obvious lesions; (b) Mild non-proliferative DR; (c) Moderate non-proliferative DR; (d) Severe non-proliferative DR; (e) Proliferative DR.

表 1 Kaggle EyePACS 数据集的数据分布

Tab. 1 Data distribution of the Kaggle EyePACS

等级	名称	图片数	占比/%
0	No DR	25 810	73. 48
1	Mild DR	2 443	6. 95
2	Moderate DR	5 292	15. 07
3	Severe DR	873	2. 49
4	Proliferative DR	708	2. 01

测试。与 Kaggle EyePACS 不同的是该数据集没有任何形式的明显噪声,包含了每幅图像关于糖尿病视网膜病变严重程度的图像级医疗诊断。由于它本身的自定义分级系统与 ICDRDSS 评分标准不同,我们采用 Krause 等人^[22]发布的真实标签,这些标签是由 3 个视网膜专家共同表决得出的,因此,它们的质量比 EyePACS 的真实标签更加可靠。

无论是 Kaggle EyePACS 还是 Messidor-2 都是糖尿病视网膜病变等级分类相关研究中主流且具有代表性的数据集,数据集规模大、数据质量高等特点使其在训练实验和对比实验中可以有效地训练模型并真实地反映出模型性能的变化^[25-26]。

3.2 数据预处理和数据增强

由于原始数据存在噪声和严重的数据不平衡问题,我们对数据集进行了有针对性的预处理和数据增强处理操作:

(1)随机缩放每幅图像 10%;

(2)将图像从中心裁剪到 416×416 像素,以提高模型的训练速度;

(3)对图像进行对比度受限的自适应直方图均衡化(CLAHE)^[27]处理,使视网膜的微妙结构变得更加清晰可见,更容易被检测;

(4)采用非局部均值去噪(NLMD)^[27-28]方法去除图像中的部分噪声;

(5)将图像的色调、亮度统一到一定的范围内,将其归一化以提高模型的训练效果^[29];

(6)将所有图像由原来的方形图像裁剪为以中心为圆点,以 208 像素为半径的圆形图像。

为了平衡训练集并增加用于训练的图像数量,处理数据集的类别不平衡问题,我们使用 $0^\circ \sim 360^\circ$ 的旋转、 $0 \sim 15$ 像素的放大和缩小以及水平和垂直的翻转进行数据增强,对训练集中所有的图像进行随机的增强,对类 1、类 2、类 3 和类 4 设置不同的增强参数重复图像^[30-31]。改进 EfficientNet 的糖尿病视网膜病变分类模型如图 4 所示。




图 4 改进 EfficientNet 的糖尿病视网膜病变分类模型

Fig. 4 Diabetic retinopathy classification model of improved EfficientNet

4 实验结果与分析

4.1 实验设置

本实验在 Intel(R) Xeon(R) CPU E5-2407、32G 内存、Geforce RTX 3060 12G 显卡的 Ubuntu18.04 服务器上调试运行。本文所提出模型的训练过程是基于 Pytorch 模型框架实现的。我们选择 EfficientNet-B3 体系结构,首先使用在 ImageNet 数据集中预先训练的权重文件进行训练,然后传输到 EyePACS 数据集并执行微调。设置式(4)中的参数 $\theta = 10$ 来训练网络,使用随机梯度下降(Stochastic gradient descent, SGD)算法, Momentum 设置为 0.9, batch-size 设置为 8, 学习率初始化为 0.000 1。性能二次加权 kappa 分数在验证集中停滞时,学习率会降低 10 倍。本文设置了早停机制(Early Stopping),在 10 个 epoch 后性能没有提升时,训练就会停止。

损失函数会影响模型的性能,在相同网络条件下不同的损失函数会导致不同的实验结果。为了验证交叉熵损失函数和焦点损失函数在 EfficientNet 网络中的影响,设计了 2 组对比实验。实验 1 使用交叉熵损失函数的 EfficientNet 网络,实验 2 使用焦点损失的 EfficientNet 网络,2 组实验均引入代价敏感正则化。

目前,糖尿病视网膜病变的分类通常采用 Inception V3 网络^[32-34]进行数据训练。为了验证所引入的代价敏感正则化对模型的影响,本文设计了 4 组实验更加全面地对比实验结果。实验 3 使用 Inception V3 网络,实验 4 使用 EfficientNet 网络,实验 5 使用引入代价敏感正则化的 Inception V3 网络,实验 6 使用引入代价敏感正则化的 EfficientNet 网络,4 组实验均使用在实验 1 和实验 2 中表现更好的损失函数。

4.2 实验结果

本文采用准确率(Accuracy, ACC)、二次加权 kappa 分数和 ROC 曲线下面积 AUC 等指标来评价模型的性能。TP、FP、FN、TN 分别表示真阳性、假阳性、假阴性、真阴性,ACC 的计算公式为:

$$ACC = \frac{TP + TN}{TP + FP + FN + TN} \quad (6)$$

二次加权 kappa 分数的计算公式为:

$$\kappa=1-\frac{\sum_{i,j}\omega_{i,j}O_{i,j}}{\sum_{i,j}\omega_{i,j}E_{i,j}},\tag{7}$$

式中 $O_{i,j}$ 表示将第 i 类判别为第 j 类的个数, $\omega_{i,j}$ 为加权系数, $\omega_{i,j}$ 和 $E_{i,j}$ 的公式分别如式(8)和式(9)所示:

$$\omega_{i,j}=\frac{(i-j)^2}{(N-1)^2},\tag{8}$$

$$E_{i,j}=\frac{\sum_i o_{i,j}\times\sum_j o_{i,j}}{n},\tag{9}$$

式(8)中 N 为分类的总类数, 式(9)中 n 为样本的总数量。

4.3 实验对比分析

4.3.1 损失函数的影响

从表 2 可以看出, 在引入代价敏感正则化的 EfficientNet 网络中使用交叉熵损失函数时, 模型的准确率为 0.88, 二次加权 kappa 分数为 0.85, ROC 曲线下面积 AUC 的值为 0.91; 使用焦点损失函数时, 模型的准确率为 0.90, 二次加权 kappa 分数为 0.86, ROC 曲线下面积 AUC 的值为 0.93, 各项指标都有约 2% 的提升。交叉熵损失函数已经广泛应用于多分类任务中, 而本实验结果验证了焦点损失函数在样本类别不均匀的多分类任务中能够通过对分类错误施加不同程度的惩罚来提升模型的结果, 对性能产生更好的影响。

表 2 使用交叉熵损失函数和焦点损失函数的 Efficient-Net 网络性能

Tab. 2 EfficientNet network performance with cross entropy loss function and focal loss function

损失函数	ACC	kappa 分数	AUC
交叉熵损失函数	0.88	0.85	0.91
焦点损失函数	0.90	0.86	0.93

4.3.2 引入代价敏感正则化的影响

从表 3 可以看出, EfficientNet 网络在使用焦

表 3 实验结果对比

Tab. 3 Comparison of experimental results

网络结构	ACC	kappa 分数	AUC
Inception V3	0.82	0.78	0.86
Inception V3-CSR	0.84	0.82	0.88
EfficientNet	0.86	0.81	0.90
EfficientNet-CSR	0.90	0.86	0.93

点损失时引入代价敏感正则化所得到二次加权 kappa 分数为 0.86, AUC 值为 0.93, 表明该模型具有很好的性能, 相较于不引入代价敏感正则化的 EfficientNet 网络各项性能指标提高了 3%~5%。

为进一步验证引入代价敏感正则化对分类网络模型的影响, 在 Inception V3 网络中引入代价敏感正则化。由表 3 的实验结果可以看出, 作为 DR 分类常用的 Inception V3 网络在引入代价敏感正则化后准确率、二次加权 kappa 分数和 AUC 有 2%~4% 的提升。从上述结果可以看出, 两种分类模型的各项性能指标均有所提高, 特别是 EfficientNet 网络准确率提升到 0.90 以上, 证明引入代价敏感正则化能够有效提高分类网络的性能。

4.3.3 与其他网络模型的比较

我们将本文方法与 Lands 等人^[16]在 2020 年利用 DenseNet169 网络所提出的方法进行对比, 该方法在利用 CNN 对糖尿病视网膜病变进行分类的任务中具有较高的性能结果。使用二次加权 kappa 分数和 ROC 曲线下面积 AUC 作为评估模型性能的指标。同时为了进一步验证本文方法的先进性, 另外选择了 Galdran 等人^[13]在 2020 年使用的 ResNeXt50 网络模型和 Inception V3 网络模型, 分别在 EyePACS 和 Messidor-2 两大分类数据集上进行实验, 实验结果如表 4 所示。同时使用集平均方式计算了模型 5 分类的平均真阳性率和假阳性率, 并绘制了模型在 EyePACS 测试集上的 ROC 曲线以及混淆矩阵, 如图 5 所示。

表 4 4 种网络模型在两个数据集上的性能

Tab. 4 Performance of four Network models on two data sets

数据集	ResNeXt50	Inception V3	Lands 等人结果 ^[16]	EfficientNet-CSR
EyePACS	0.77/0.84	0.78/0.86	0.81/0.91	0.86/0.93
Messidor-2	0.80/0.85	0.79/0.88	0.83/0.92	0.88/0.95

注: 表中“/”前后两个数值分别表示二次加权 kappa 分数和 AUC 值




图5 EfficientNet-CSR模型在EyePACS测试集上的性能。(a) ROC曲线;(b)混淆矩阵。

Fig.5 Performance of EfficientNet-CSR in the EyePACS test set. (a) ROC curves; (b) Confusion matrix.

从表4可以看出, ResNeXt50网络和Inception V3网络在两个数据集上的二次加权 kappa 分数未超过0.80, AUC值未超过0.90, 分类器性能一般。Lands等人^[16]所提出的模型二次加权 kappa 分数为0.81~0.83, AUC超过0.90, 分类器性能较好。本文所提方法在EyePACS数据集上的二次加权 kappa 分数为0.86, AUC值为0.93; 在Messidor-2数据集上的二次加权 kappa 分数为0.88, AUC值为0.95, 分类器性能很好, 特别是二次加权 kappa 分数超出Lands等人^[16]所提出模型的5%。

参 考 文 献:

- [1] DAS S, MALATHY C. Survey on diagnosis of diseases from retinal images [J]. *Journal of Physics: Conference Series*, 2018, 1000: 012053.
- [2] WHO. Seventy-fourth world health assembly report on diabetes [EB/OL]. World Health Organization. (2021-05-27) [2022-01-12]. <https://www.who.int/zh/news/item/27-05-2021-update-from-the-seventy-fourth-world-health-assembly-27-may-2021>.

从图5的混淆矩阵可以看出, 数据大部分分布在对角线上, 说明模型的准确率很高。模型把第0类预测成第2类, 把第1类预测成第0类, 把第2类预测成第0类, 3种错误所占比例较高, 我们可以在后续的实验通过修改惩罚矩阵中的值加大对这3种错误的惩罚。ROC曲线位于偏左上角位置, 表明我们的分类器性能较好, AUC值为0.93表明模型综合性能很好。

Lands等人^[16]所提出的模型复杂, 无法优化网络, 模型参数数量和计算量较大。利用EfficientNet网络在网络宽度、网络深度等方面进行特征提取, 同时引入代价敏感正则化加大对难分类别的惩罚, 提高了模型对DR的分类效果, 弥补了EfficientNet网络模型分类准确率不高的缺点。上述结果与分析表明, EfficientNet网络模型在该分类任务中比其他CNN模型具有更好的性能。与目前主流分类模型相比, 本文所提出的引入代价敏感正则化的EfficientNet网络模型在糖尿病视网膜病变分类任务中具有更好的结果。

5 结 论

本文提出了一种引入代价敏感正则化的EfficientNet网络模型对糖尿病视网膜病变进行分类的方法。将代价敏感正则化引入到焦点损失函数中, 使模型能够惩罚错误的分类结果, 更好地区分不同类别之间的差异。通过代价敏感正则化和EfficientNet的结合, 使DR分类任务的综合性能得到了提升。在EyePACS和Messidor-2上得到0.86和0.88的二次加权 kappa 分数, 实验结果充分证明了所提方法的优越性。与其他模型相同, EfficientNet网络模型也无法给出分类的具体原因, 这也是糖尿病视网膜病变分类模型无法有效应用于临床当中的主要原因之一, 未来可以在模型的结构上进一步优化完善。

- [3] MACHO J S, LÓPEZ J Á F V, REY J A D, *et al.* Prevalencia de retinopatía diabética en una población diabética no seleccionada [J]. *Archivos de la Sociedad Española de Oftalmología*, 1990, 59(3): 277-284.
- [4] 陈筱,朱向冰,吴昌凡,等. 基于迁移学习与特征融合的眼底图像分类[J]. *光学精密工程*, 2021, 29(2): 388-399.
CHEN X, ZHU X B, WU C F, *et al.* Research on fundus image classification based on transfer learning and feature fusion [J]. *Optics and Precision Engineering*, 2021, 29(2): 388-399. (in Chinese)
- [5] 潘宇骏,韩玉琢,解洪升,等. 眼底自适应成像系统中的二自由度头托设计[J]. *液晶与显示*, 2015, 30(4): 590-595.
PAN Y J, HAN Y Z, XIE H S, *et al.* Design of two degree-of-freedom head prop in adaptive optics retinal imaging system [J]. *Chinese Journal of Liquid Crystals and Displays*, 2015, 30(4): 590-595. (in Chinese)
- [6] QUELLEC G, CHARRIÈRE K, BOUDI Y, *et al.* Deep image mining for diabetic retinopathy screening [J]. *Medical Image Analysis*, 2017, 39: 178-193.
- [7] SIMONYAN K, VEDALDI A, ZISSERMAN A. Deep inside convolutional networks: Visualising image classification models and saliency maps [C]//*Proceedings of the 2nd International Conference on Learning Representations*. Banff: ICLR, 2014.
- [8] LAM C, YI D, GUO M, *et al.* Automated detection of diabetic retinopathy using deep learning [J]. *AMIA Joint Summits on Translational Science*, 2018, 2017: 147-155.
- [9] KHOJASTEH P, ALIAHMAD B, KUMAR D K. Fundus images analysis using deep features for detection of exudates, hemorrhages and microaneurysms [J]. *BMC Ophthalmology*, 2018, 18(1): 288.
- [10] SAHA O, SATHISH R, SHEET D. Fully convolutional neural network for semantic segmentation of anatomical structure and pathologies in colour fundus images associated with diabetic retinopathy [J]. *arXiv*, 2019: 1902.03122.
- [11] 周林鹏,姚剑敏,严群,等. 融合多尺度特征及注意力机制的医学图像检索[J]. *液晶与显示*, 2021, 36(8): 1174-1185.
ZHOU L P, YAO J M, YAN Q, *et al.* Medical image retrieval with multiscale features and attention mechanisms [J]. *Chinese Journal of Liquid Crystals and Displays*, 2021, 36(8): 1174-1185. (in Chinese)
- [12] 庞浩,王枳. 用于糖尿病视网膜病变检测的深度学习模型[J]. *软件学报*, 2017, 28(11): 3018-3029.
PANG H, WANG C. Deep learning model for diabetic retinopathy detection [J]. *Journal of Software*, 2017, 28(11): 3018-3029. (in Chinese)
- [13] GALDRAN A, DOLZ J, CHAKOR H, *et al.* Cost-sensitive regularization for diabetic retinopathy grading from eye fundus images [C]//*Proceedings of the 23rd International Conference on Medical Image Computing and Computer-Assisted Intervention*. Lima: Springer, 2020: 665-674.
- [14] VARADARAJAN A V, BAVISHI P, RUAMVIBOONSUK P, *et al.* Predicting optical coherence tomography-derived diabetic macular edema grades from fundus photographs using deep learning [J]. *Nature Communications*, 2020, 11(1): 130.
- [15] 孙雨琛,刘宇红,张达峰,等. 基于深度学习的糖尿病视网膜病变诊断方法[J]. *激光与光电子学进展*, 2020, 57(24): 241701.
SUN Y C, LIU Y H, ZHANG D F, *et al.* Diagnosis method of diabetic retinopathy based on deep learning [J]. *Laser & Optoelectronics Progress*, 2020, 57(24): 241701. (in Chinese)
- [16] LANDS A, KOTTARATHIL A J, BIJU A, *et al.* Implementation of deep learning based algorithms for diabetic retinopathy classification from fundus images [C]//*2020 4th International Conference on Trends in Electronics and Informatics (ICOEI)*. Tirunelveli: IEEE, 2020: 1028-1032.
- [17] 蔡怀宇,韩晓艳,姜世良,等. 扫频光学相干层析视网膜图像配准去噪算法[J]. *中国光学*, 2021, 14(2): 289-297.
CAI H Y, HAN X Y, LOU S L, *et al.* Speckle noise reduction in swept-source optical coherence tomography by retinal image registration [J]. *Chinese Optics*, 2021, 14(2): 289-297. (in Chinese)
- [18] 吴海滨,魏喜盈,刘美红,等. 结合空洞卷积和迁移学习改进YOLOv4的X光安检危险品检测[J]. *中国光学*, 2021, 14(6): 1417-1425.
WU H B, WEI X Y, LIU M H, *et al.* Improved YOLOv4 for dangerous goods detection in X-ray inspection combined with atrous convolution and transfer learning [J]. *Chinese Optics*, 2021, 14(6): 1417-1425. (in Chinese)
- [19] TAN M X, LE Q V. Efficientnet: Rethinking model scaling for convolutional neural networks [C]//*Proceedings of the 36th International Conference on Machine Learning*. Long Beach: PMLR, 2019: 6105-6114.
- [20] KIM Y, LEE Y, JEON M. Imbalanced image classification with complement cross entropy [J]. *Pattern Recogni-*

- tion Letters, 2021, 151: 33-40.
- [21] LU Y, JIANG M F, WEI L Y, *et al.* Automated arrhythmia classification using depthwise separable convolutional neural network with focal loss [J]. *Biomedical Signal Processing and Control*, 2021, 69: 102843.
- [22] KRAUSE J, GULSHAN V, RAHIMY E, *et al.* Grader variability and the importance of reference standards for evaluating machine learning models for diabetic retinopathy [J]. *Ophthalmology*, 2018, 125(8): 1264-1272.
- [23] TSIKNAKIS N, THEODOROPOULOS D, MANIKIS G, *et al.* Deep learning for diabetic retinopathy detection and classification based on fundus images: a review [J]. *Computers in Biology and Medicine*, 2021, 135: 104599.
- [24] WILKINSON C P, FERRIS III F L, KLEIN R E, *et al.* Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales [J]. *Ophthalmology*, 2003, 110(9): 1677-1682.
- [25] 范家伟,张如如,陆萌,等.深度学习方法在糖尿病视网膜病变诊断中的应用[J].自动化学报,2021,47(5):985-1004. FAN J W, ZHANG R R, LU M, *et al.* Applications of deep learning techniques for diabetic retinal diagnosis [J]. *Acta Automatica Sinica*, 2021, 47(5): 985-1004. (in Chinese)
- [26] MATEEN M, WEN J H, HASSAN M, *et al.* Automatic detection of diabetic retinopathy: a review on datasets, methods and evaluation metrics [J]. *IEEE Access*, 2020, 8: 48784-48811.
- [27] XIAO Q Q, ZOU J X, YANG M Q, *et al.* Improving lesion segmentation for diabetic retinopathy using adversarial learning [C]//*Proceedings of the 16th International Conference on Image Analysis and Recognition*. Waterloo: Springer, 2019: 333-344.
- [28] GHOSH R, GHOSH K, MAITRA S. Automatic detection and classification of diabetic retinopathy stages using CNN [C]//*2017 4th International Conference on Signal Processing and Integrated Networks (SPIN)*. Noida: IEEE, 2017: 550-554.
- [29] 郭继峰,李星,庞志奇,等.自定义模糊逻辑与 GAN 在图像高光处理中的研究[J].小型微型计算机系统,2021, 42(8):1715-1719. GUO J F, LI X, PANG Z Q, *et al.* Research on custom fuzzy logic and generative adversarial networks in image highlight processing [J]. *Journal of Chinese Computer Systems*, 2021, 42(8): 1715-1719. (in Chinese)
- [30] BRAVO M A, ARBELÁEZ P A. Automatic diabetic retinopathy classification [C]//*13th International Symposium on Medical Information Processing and Analysis*. San Andres Island: SIPAIM, 2017.
- [31] GUO J F, PANG Z Q, YANG F, *et al.* Study on the Method of fundus image generation based on improved GAN [J]. *Mathematical Problems in Engineering*, 2020, 2020: 6309596.
- [32] TSAI C Y, CHEN C T, CHEN G A, *et al.* Necessity of local modification for deep learning algorithms to predict diabetic retinopathy [J]. *International Journal of Environmental Research and Public Health*, 2022, 19(3): 1204.
- [33] BHARDWAJ C, JAIN S, SOOD M. Diabetic retinopathy severity grading employing quadrant-based Inception-V3 convolution neural network architecture [J]. *International Journal of Imaging Systems and Technology*, 2021, 31(2): 592-608.
- [34] ZENG X L, CHEN H Q, LUO Y, *et al.* Automated diabetic retinopathy detection based on binocular siamese-like convolutional neural network [J]. *IEEE Access*, 2019, 7: 30744-30753.

作者简介:



王明智(1997—),男,山东滕州人,硕士研究生,2019年于临沂大学获得学士学位,主要从事深度学习、计算机视觉、医学影像处理等方面的研究。E-mail: wangmingzhi21@163.com



马志强(1980—),男,黑龙江哈尔滨人,硕士,工程师,2007年于东北林业大学获得硕士学位,主要从事人工智能、虚拟现实技术等方面的研究。E-mail: 1791105996@qq.com