

中國文化大學
資訊工程學系
資訊系統專題

糖尿病視網膜病變辨識系統

學 生：俞 華 鈴

李 馥 彤

林 永 泰

指導教授：林 世 崧

中 華 民 國 114 年 12 月

糖尿病視網膜病變辨識系統

專題學生：俞華鈴、李馥彤、林永泰

指導教授：林世崧 博士

中國文化大學 資訊工程學系

摘要

本系統以 APTOS 2019 Blindness Detection 公開資料集為基礎，進行影像資料的前處理與訓練。首先針對視網膜影像進行尺寸調整、亮度與對比度校正、雜訊去除與資料增強，以提升模型的泛化能力。採用 CNN、ResNet50、InceptionV3、EfficientNetB5 四種深度學習架構進行五分類訓練，分為 1 至 5 級，無病變、輕度、中度、重度及增殖性糖尿病視網膜病變，並比較各模型於準確率、F1-score 及混淆矩陣上的表現。最終選定效能最佳且參數量與精度兼具的 EfficientNetB5 作為本系統最終辨識模型。系統整合 PyQt5 圖形化介面，提供使用者可透過介面上傳視網膜影像，系統自動輸出辨識結果、疾病分級與對應病患資料，達到臨床輔助診斷與智慧醫療應用的目的，提升醫師初步判讀效率與準確度。

關鍵詞：糖尿病行視網膜病變、深度學習、卷積神經網路、影像辨識

指導教授_____ (簽名)

Diabetic Retinopathy Detection System

Student: Hua-Ling Yu, Fu-Tong Li, and Yung-Tai Lin

Advisor: Prof. Shih-Sung Lin

Department of Computer Science and Information Engineering

Chinese Culture University

ABSTRACT

This system is developed based on the publicly available APTOS 2019 Blindness Detection dataset, performing image preprocessing and model training for diabetic retinopathy classification. The preprocessing pipeline includes image resizing, brightness and contrast correction, noise reduction, and data augmentation to enhance the model's generalization capability. Four deep learning architectures CNN, ResNet50, InceptionV3, and EfficientNetB5—were adopted for a five-class classification task, levels 1-5: No_DR, Mild, Moderate, Severe, and Proliferative Diabetic Retinopathy). The models were compared in terms of accuracy, F1-score, and confusion matrix performance. After evaluation, EfficientNetB5 was selected as the final recognition model due to its optimal balance between parameter efficiency and classification accuracy. The system integrates a PyQt5 graphical user interface (GUI), allowing users to upload retinal images directly through the interface. The system then automatically outputs the predicted classification results, disease severity level, and corresponding patient information, achieving the goal of computer-aided diagnosis and smart healthcare applications. This design effectively enhances ophthalmologists' preliminary diagnostic efficiency and accuracy.

Keywords: Diabetic Retinopathy, Convolutional Neural Network, Image Classification, Deep Learning

目 錄

摘要.....	I
ABSTRACT	II
目 錄.....	III
表 目 錄	V
圖 目 錄	VI
第 1 章 研究動機與目的.....	1
1.1 研究動機	1
1.2 研究目的	1
1.3 研究流程	2
第 2 章 文獻探討	4
2.1 糖尿病介紹	4
2.1.1 糖尿病型視網膜病變	5
2.1.2 糖尿病視網膜病變公開資料集.....	8
2.2 模型架構.....	9
2.2.1 CNN.....	9
2.2.2 ResNet50.....	9
2.2.3 InceptionV3.....	10
2.2.4 EfficientNetB5	11
2.3 系統應用	12
第 3 章 研究內容與方法.....	14
3.1 模型訓練架構	15
3.2 模型研究流程	16
3.3 軟硬體資源規劃.....	18
3.4 模型訓練流程	19
3.4.1 影像前處理與增強方法	20
3.4.2 數據擴增.....	21

3.4.3 超參數設定	22
3.5 模型訓練過程	24
3.6 系統設計	34
3.6.1 系統需求分析	34
3.6.2 系統架構設計	43
3.6.3 系統流程設計	46
3.6.4 系統模組設計	48
3.6.5 辨識模型整合	51
3.6.6 資料庫設計	51
3.6.7 GUI 設計要點	54
3.6.8 GUI 畫面設計	56
第 4 章 成果展示	60
4.1 辨識成果	60
4.2 系統展示	61
4.2.1 系統流程設計	63
4.2.2 介面關聯圖	64
4.2.3 互動介面展示	65
第 5 章 結論	76
第 6 章 人力配置	77
參考文獻	78
附錄 A 開發工具介紹	80
A.1 軟體開發工具介紹	80
A.1.1 Visual Studio Code	80
A.1.2 TensorFlow	81
A.1.3 Colab	82
A.2 影像辨識電腦硬體	83

表 目 錄

表 2.1	視網膜病變眼底影像分級	7
表 2.2	各疾病分類圖片數量分布的統計資料.....	8
表 3.1	本研究實驗軟硬體環境	18
表 3.2	APTOS 2019 Blindness Detection 數據擴增後訓練集張數...	21
表 3.3	模型參數設定.....	23
表 3.4	他人研究模型效能比較	32
表 3.5	本研究模型訓練結果	33
表 3.6	前端功能性需求.....	35
表 3.7	前端非功能性需求.....	38
表 3.8	後端功能性需求.....	39
表 3.9	後端非功能性需求.....	41
表 6.1	參與本項研究之人員及工作內容.....	77
表 A.1	影像辨識電腦.....	83

圖 目 錄

圖 1.1	研究流程圖.....	2
圖 2.1	InceptionV3 卷積模組架構圖[7].....	10
圖 2.2	模型比較[8].....	11
圖 2.3	新冠採樣站示意圖	12
圖 3.1	系統架構圖.....	14
圖 3.2	糖尿病視網膜辨識系統架構	15
圖 3.3	研究流程	16
圖 3.4	模型流程圖.....	19
圖 3.5	視網膜影像前處理效果比較	20
圖 3.6	CNN 模型之 Loss Curve 圖.....	24
圖 3.7	CNN 模型之 Accuracy Curve 圖	25
圖 3.8	ResNet50 模型之 Loss Curve 圖	25
圖 3.9	ResNet50 模型之 Accuracy Curve 圖.....	26
圖 3.10	InceptionV3 模型之 Loss Curve 圖	27
圖 3.11	InceptionV3 模型之 Accuracy Curve 圖	27
圖 3.12	EfficientNetB5 模型之 Loss Curve 圖	28
圖 3.13	EfficientNetB5 模型之 Accuracy Curve 圖	29
圖 3.14	CNN 混淆矩陣	29
圖 3.15	ResNet50 混淆矩陣	30
圖 3.16	InceptionV3 混淆矩陣	31
圖 3.17	EfficientNetB5 混淆矩陣.....	31
圖 3.18	病患資料_資料表	52
圖 3.19	病患資料_資料表	52
圖 3.20	照片管理_資料表	53
圖 3.21	帳號管理_資料表	53
圖 3.22	權限操作紀錄_資料表	53

圖 3.23	登入畫面_設計圖	56
圖 3.24	主畫面_設計圖	57
圖 3.25	病患資料頁_設計圖	57
圖 3.26	功能視窗_設計圖	58
圖 3.27	預約管理系統_設計圖	58
圖 3.28	後台頁面_設計圖	59
圖 3.29	後台操作紀錄管理頁面_設計圖	59
圖 4.1	各模型評估指標比較圖	60
圖 4.2	運作流程圖	61
圖 4.3	系統流程設計圖	63
圖 4.4	UI 介面關聯圖	64
圖 4.5	登入畫面	65
圖 4.6	主畫面	66
圖 4.7	病患資料頁面	68
圖 4.8	有資料之病患資料頁面	69
圖 4.9	眼底詳情頁	70
圖 4.10	後台辨識分析結果	71
圖 4.11	回診單頁面	71
圖 4.12	預約管理系統	72
圖 4.13	後台管理	73
圖 4.14	權限操作紀錄	75
圖 A.1	Visual Studio Code	80
圖 A.2	TensorFlow	81
圖 A.3	Colab	82

第 1 章 研究動機與目的

1.1 研究動機

隨著全球糖尿病患者人數不斷攀升，糖尿病視網膜病變已成為成年人失明的主要原因之一。尤其在偏遠地區，受限於醫療資源不足與專業診斷人員匱乏，病患往往無法及時接受檢查與治療，導致視力不可逆損傷。

傳統眼底檢查需依賴專業醫師目視判讀，程序耗時且受限於設備與技術普及程度。隨著深度學習與醫療影像技術的進步，利用人工智慧協助糖尿病視網膜病變的早期偵測成為可行且迫切的需求。因此，本研究期望藉由科技手段縮短診斷流程，提升篩檢覆蓋率，減緩糖尿病引發的失明問題，改善偏鄉醫療可及性。

1.2 研究目的

本研究結合深度學習與醫學影像辨識技術，旨在開發一套高效、精準且易於部署的糖尿病視網膜病變（Diabetic Retinopathy, DR）自動辨識系統。系統以眼底影像為輸入，實現 DR 五級病變分級診斷，輔助醫療人員進行初步篩檢與臨床判讀。採用簡易框架設計出直覺且穩定的圖形介面，在基層醫療環境中，醫護人員亦能快速操作，可以達成早期診斷、降低視力損失風險，並促進偏鄉地區醫療資源普及與品質提升之目標。

1.3 研究流程

本研究架構如圖 1.1，介紹糖尿病視網膜病變的研究背景及相關議題，延伸的研究動機及為找出糖尿病視網膜病變檢測需要解決及改善的問題。




圖 1.1 研究流程圖

流程分為以下四部分：

(1) 於文獻部分

將由現有的糖尿病視網膜病變自動化流程相關文獻整理，並探討過去學者所提出的技術，在整理的文獻範圍內篩選並明確研究主題，接著建立本研究架構。

(2) 於研究部分

先對影像進行前處理，以提升畫面品質並統一大小與格式；之後利用影像分割技術將目標區域從背景中分離出來，再將這些區域送入分類模型中判斷其類別或病變程度，最後再透過多種評估指標檢驗整體辨識效果與準確性，以確認系統的實用性。

(3) 於實驗部分

則針對模型進行訓練與測試，獲得模型實驗結果後，使用多項指標進行綜合性評估，模型評估使用學習曲線、召回率、F1-score、精確率及混淆矩陣等數據，藉以全面觀察模型在不同面向的表現與穩定度。

(4) 系統開發部分

開發一套以 PyQt5 框架建置之圖形介面糖尿病視網膜病變輔助診斷系統，提供視覺化操作環境，協助臨床醫師快速且準確判讀視網膜影像之病變程度，期能促進早期發現與即時治療。

第 2 章 文獻探討

本章將探討建置糖尿病視網膜病變辨識系統所需之相關背景知識與技術文獻。首先針對糖尿病及其主要併發症——糖尿病視網膜病變 (Diabetic Retinopathy, DR) 之成因、病徵與臨床分級標準進行說明，並介紹本研究所採用之 APTOS 2019 Blindness Detection 公開資料集特性。接著，將深入探討本研究運用之深度學習模型架構，包含基礎卷積神經網路 (CNN)、ResNet50、InceptionV3 及 EfficientNetB5 之原理與脈絡，以作為後續模型選用之依據。最後，闡述本系統結合偏鄉醫療與防疫站點之場域應用概念，旨在建立本研究之理論基礎與實務設計方向。

2.1 糖尿病介紹

根據國際糖尿病聯盟 (International Diabetes Federation, 2025) [1] 的統計，到了 2025 年，全球糖尿病患者數量將突破 3 億人。糖尿病不僅造成血糖失控，更可能引發心血管、腎臟、神經系統及視覺系統等多重器官的併發症，從生活品質下降，到失明、洗腎甚至截肢，對患者個人、家庭乃至整個社會帶來沉重衝擊。

糖尿病是一種因血糖濃度過高、胰島素分泌不足或作用異常所引發的代謝性疾病。依據類型不同，糖尿病的併發症可分為急性與慢性兩大類[2]。急性併發症中最常見的是血糖控制不穩，特別是低血糖症，患者一旦出現症狀，需即時補充含糖食物以緩解危機。慢性併發症則影響更為深遠，涵蓋眼睛、腎臟、心血管以及神經系統等，長期發展下可能導致不可逆的器官損傷。

其中，糖尿病視網膜病變 (Diabetic Retinopathy, DR) 不僅涉及血管異常，如血管通透性增加、微血管阻塞及新生血管形成，也包含視

網膜神經細胞的功能障礙與退行性變化，且神經病變可能早於血管病變出現[3]。

2.1.1 糖尿病型視網膜病變

糖尿病型視網膜病變根據以下病變特徵進行嚴重等級分級，包含微動脈瘤、視網膜出血、硬性滲出物、軟性滲出物(Soft Exudates)、視網膜內微血管異常(IRMA)、視神經血管新生及任何地方血管新生等，視網膜病變主要分為以下兩類[4]：

(1) 非增值性 (Non-Proliferative Diabetic Retinopathy, NPDR)

非增值性視網膜病變特徵包含微血管瘤、棉絮一樣的斑點、硬性滲出物和出血的情況，根據這些病徵分為輕度、中度和重度三個階段。

(2) 增值性 (Proliferative Diabetic Retinopathy, PDR)

視網膜的血液供應不足導致視網膜內的微血管病變、滋生新的血管，過多的血管造成眼球出血、視網膜剝離的情形，嚴重會導致視力下降及失明的危險。

其詳細的特徵分類，根據病徵可以分為以下五個等級：

(1) 無視網膜病變 (No DR)

無明顯視網膜病變。

(2) 輕度非增殖性視網膜病變 (Mild NPDR)

僅有微動脈瘤。

(3) 中度非增殖性視網膜病變 (Moderate NPDR)

微動脈瘤和出血較多，以及棉絮狀斑、靜脈串珠。

(4) 重度非增殖性視網膜病變 (Server NPDR)




明顯的視網膜內微血管異常、靜脈串珠。

(5) 增值性視網膜病變 (PDR)

視網膜新生血管形成、玻璃體或視網膜前出血、纖維增生。

表 2.1 為各等級眼底影像示意圖。

表 2.1 視網膜病變眼底影像分級

DR 嚴重分級	DR 眼底影像
無視網膜病變 (No DR)	
輕度非增值性視網膜病變 (Mild NPDR)	
中度非增值性視網膜病變 (Moderate NPDR)	
重度增值性視網膜病變 (Sever NPDR)	
增值性視網膜病變 (PDR)	

2.1.2 糖尿病視網膜病變公開資料集

本研究採用 APTOS 2019 Blindness Detection 資料集[5]，該資料集由印度 Aravind 眼科醫院提供，收錄自印度農村地區之眼底影像，共計 5,590 張，其中 3,662 張具備標註資訊並作為訓練資料使用。每張影像皆由專業眼科醫師依據國際臨床糖尿病視網膜病變嚴重程度量表（International Clinical Diabetic Retinopathy Severity Scale, ICDRSS）進行分級與標註，依病變嚴重程度劃分為五個等級：1（無病變）、2（輕度）、3（中度）、4（重度）、5（增殖期病變）。在本研究中，資料集依比例切分為訓練集、驗證集與測試集，以進行模型訓練與效能評估。APTOS 2019 Blindness Detection 資料集各疾病分類圖片數量分布的統計資料，如表 2.2 所示。

表 2.2 各疾病分類圖片數量分布的統計資料

資料集	分級					數量總計
	1	2	3	4	5	
APTOS 2019	1,805	370	999	193	295	3,662

2.2 模型架構

為探討不同深度學習架構於糖尿病視網膜病變分類任務上的辨識能力，本研究選用四種於影像分類領域具有代表性的卷積神經網路進行比較分析，包括自建的基礎卷積神經網路（CNN）、殘差網路 ResNet50、InceptionV3 以及 EfficientNetB5。此四類模型分別體現了從淺層卷積堆疊、深層殘差學習、多尺度特徵融合至複合式縮放架構的技術演進脈絡，本研究將以此作為評估網路深度、特徵擷取能力與計算效率對醫學影像分類影響的重要基準。

2.2.1 CNN

基礎卷積神經網路（CNN）本研究建構之基礎 CNN 以堆疊卷積層（Convolutional Layer）與池化層（Pooling Layer）作為特徵擷取主軸。此架構雖具有良好的模型可解釋性與運算效率，適合作為實驗對照基準（Baseline），但在處理高複雜度的視網膜病灶特徵（如微血管瘤或細微出血點）時，其特徵表徵能力往往受限於架構深度，難以捕捉高層次的語義資訊。

2.2.2 ResNet50

ResNet50[6] 由 He 等人提出，透過殘差學習（Residual Learning）機制引入捷徑連接（Shortcut Connections/Skip Connections），允許梯度直接流向淺層網路。此設計有效緩解了深層網路於訓練過程中常見的梯度消失（Gradient Vanishing）與性能退化（Degradation）問題，使模型得以在此基礎上訓練更深層的特徵表徵，進而提升分類準確度。

2.2.3 InceptionV3

InceptionV3[7]是 Google 於 2015 年提出的卷積神經網路架構，為 Inception 系列的第三版改良版本。此模型引入了多項技術優化，包含分解大型卷積核（如 7×7 卷積因子化）、批次正規化（Batch Normalization）與標籤平滑（Label Smoothing），使得模型在降低參數數量的同時提升效能並降低過擬合風險。此外，InceptionV3 也採用 RMSProp 優化器來優化訓練過程，整體架構兼顧計算效率與準確度，廣泛應用於影像分類及轉移學習任務。圖 2.1 為 InceptionV3 中對 $n \times n$ 卷積的空間因式分解技術，將大尺寸卷積核拆分為一連串的 $1 \times n$ 及 $n \times 1$ 非對稱卷積，有效降低參數量及運算複雜度，同時提升特徵抽取效能。




圖 2.1 InceptionV3 卷積模組架構圖[7]

2.2.4 EfficientNetB5

EfficientNet[8]為 Google 於 2019 年提出的一種高效卷積神經網路架構，其核心概念為透過複合縮放（Compound Scaling）同時平衡模型的深度（Depth）、寬度（Width）與影像解析度（Resolution），在不額外增加運算資源的情況下達到最佳效能。研究者首先利用神經架構搜尋（Neural Architecture Search, NAS）找出基礎模型 EfficientNet-B0，再依比例同步放大三個維度，衍生出 B1 至 B7 等不同規模的模型版本。此方法能在相同參數量與運算量（FLOPs）下，取得比 ResNet、Inception、DenseNet 等傳統模型更高的準確率與效率。圖 2.2 顯示了 EfficientNet 與其他常見卷積模型的比較結果，可見其在參數量明顯較少的情況下，仍能維持極高的分類精確度。




圖 2.2 模型比較[8]

2.3 系統應用

本研究之系統構想萌生於新冠肺炎（COVID-19）疫情期間之檢疫站點設計經驗。當時為因應短時間內大量篩檢與個案分流之需求，實務上多採用具備動線明確、風險分級管理、可快速搭建與易於拆除等特性的臨時檢疫站。此類站點在疫情高峰時發揮了關鍵功能。

本研究之系統構想萌生於新冠肺炎（COVID-19）疫情期間之檢疫站點設計經驗。當時因為大量醫療資源短缺，沒辦法讓大眾前往打醫院作篩查，因此設立很多臨時抽檢站，將所有可能有病之患者先進行取樣後將樣本送回醫院做進一步檢驗，新冠採樣站示意圖如圖 2.3 所示。



圖 2.3 新冠採樣站示意圖

眼底鏡拍攝由於醫生及器械的稀缺性，同樣為醫療資源缺乏項目，因此本案嘗試以類似的方法設立巡迴式的臨時站點，前往醫療資源不足之地區收集樣本，以少量人力結合模型辨識做初步的篩查，以此解決醫療量能不足的問題。

「臨時站點」和「新冠快篩站」都是在特定地點快速部署的醫療服務點。臨時站點主要針對慢性疾病或特定檢查（例如眼底攝影、影像蒐集）設計，重點是為偏鄉或醫療資源不足地區建立病患的基本資料與檢查影像。病患到站後，由醫療人員利用眼底鏡等設備拍攝影像，透過電腦建檔並儲存，後續可再交由專科醫師判讀與追蹤，成為「健康篩檢與長期追蹤」的角色。

臨時站點的優點包括如下五點：

(1) 機動性高

可以依社區、偏鄉或活動彈性設置，縮短病患就醫路程。

(2) 提升可近性

把設備與醫療人員「帶到病人身邊」，讓原本不易到醫院的人也能完成基本檢查與建檔。

(3) 設備集中、流程簡化

在同一站點就能完成拍攝、資料輸入與儲存，減少多處奔波與等待時間。

(4) 利於後續追蹤

現場直接將影像與基本資料上傳系統，後端醫師可遠端判讀與追蹤，提高醫療資源使用效率。

(5) 可配合防疫與宣導

在檢查同時進行衛教說明或篩檢，強化民眾對疾病的認識與早期就醫意識。

臨時站點的設計重點在於不需仰賴大量醫療人力，只要搭設簡易的拍攝與檢查站，就能進行大規模篩檢，達到及早發現、盡早治療的效果。

第 3 章 研究內容與方法

本研究以糖尿病視網膜辨識為核心，開發一套簡易輔助診斷系統。此系統的主要功能包括患者資料管理、診斷結果儲存、風險分析及回診提醒通知，透過以上功能，醫師不僅能集中管理所有患者的檢查與診斷紀錄，還可即時掌握需要回診的對象，提升臨床效率與醫療品質。該系統提供醫師便利的操作介面，可透過介面上傳視網膜影像，系統將影像傳送至已訓練完成之辨識模型進行分類分析，模型可辨識病變等級。分析完成後，系統將辨識結果回傳並於介面上顯示對應之 DR 分級，協助臨床醫師快速判斷病變程度，作為診斷與後續治療決策之參考依據。整體架構如圖 3.1 所示。




圖 3.1 系統架構圖

3.1 模型訓練架構

透過資料分割與擴增提升模型泛化能力，並以四種不同模型作為訓練，分別為 CNN、ResNet50、InceptionV3 及 EfficientNetB5 進行糖尿病視網膜病變五分類訓練。最後以準確率、損失函數與混淆矩陣等指標評估模型效能與實用性，如圖 3.2 所示。




圖 3.2 糖尿病視網膜辨識系統架構

整理架構可分為以下三大主軸：

(1) 資料預處理

首先進行資料分割（如訓練集與驗證集的劃分），接著進行資料增強以平衡資料分布與提升模型泛化能力，最後針對影像進行處理（影像裁切、縮放、標準化等），以符合模型輸入需求。

(2) 模型訓練

本研究採用多種深度學習架構進行模型訓練與分類任務，包括基本的卷積神經網路 CNN、ResNet50、InceptionV3 及 EfficientNetB5 四種架構。糖尿病視網膜影像為輸入模型，輸出為五級糖尿病視網膜病變等級，包括 No DR、Mild NPDR、Moderate NPDR、Severe NPDR 與 Proliferative DR，完成病變等級之分類辨識。

(3) 模型評估

模型訓練完成後，將預測結果與真實標籤進行比對，並採用多項指標進行效能評估，包括準確率（Accuracy）、損失函數值（Loss）與混淆矩陣（Confusion Matrix）等。藉由評估結果，檢視模型效能與實用性。

3.2 模型研究流程

內容為研究流程圖，展示了糖尿病視網膜病變辨識系統的開發過程，如圖 3.3 所示。




圖 3.3 研究流程

流程說明分為以下六個步驟：

(1) 文獻探討

此階段主要探討糖尿病視網膜病變的背景、相關議題與自動化檢測的研究議題，並整理相關技術文獻，明確研究主題。

(2) 環境架設與安裝

建立開發環境，包括軟體資源規劃 Google Colab、TensorFlow、Visual Studio Code。

(3) 資料收集與前處理

使用公開資料集，進行影像標準化、資料增強等處理，以提升模型訓練效果。

(4) 模型訓練

採用深度學習技術（CNN、ResNet50、InceptionV3 及 EfficientNetB5）進行模型訓練，並透過遷移學習優化模型性能。

(5) 評估與優化

使用準確率、混淆矩陣等指標評估模型效能，並進行超參數調整以提升辨識準確率。

(6) 系統整合與部署

將訓練完成的模型整合至雲端平台，開發使用者介面，提供使用者便利的操作介面。

3.3 軟硬體資源規劃

電腦硬體方面，使用搭載 Intel Core i7-12700H 處理器、16GB 記憶體容量與 NVIDIA GeForce RTX 4050 GPU 的 Windows 11 筆記型電腦，作為本地測試與備援平台，提供穩定效能支援原型設計與開發。軟體配置方面：作業系統為 Windows 11 家用版、程式撰寫所使用的平台為 Visual Studio Code 1.100.1、所使用的程式語言為 Python 3.8.20、深度學習為 Tensorflow 2.3.0。如表 3.1 所示。

表 3.1 本研究實驗軟硬體環境

實驗環境配置	規格
作業系統	Windows 11 家用版
處理器	Intel(R) Core(TM) i7-12700H
外部顯卡	NVIDIA GeForce RTX 4050 laptop GPU
標準記憶體	16GB
程式撰寫平台	Visual Studio Code 1.100.1
程式語言	Python 3.8.20
深度學習框架	Tensorflow 2.3.0

3.4 模型訓練流程

在模型訓練前，本研究首先針對 APTOS 2019 Blindness Detection 資料集進行資料前處理與樣本平衡。影像部分採用 Gaussian Filter 去除噪點並強化視網膜結構，以提升特徵清晰度。為避免類別不平衡造成模型偏差，實作了資料平衡策略：當類別樣本數不足 800 張時，進行隨機重複抽取補足；若超過 2000 張，則採隨機下採樣，使各類別樣本數維持相近。資料集接著依比例劃分為訓練集 70%、驗證集 15%、測試集 15%，確保各類別在三個子集中的比例一致。為強化模型的泛化能力進行影像資料增強，包括水平與垂直翻轉、旋轉、平移、縮放、亮度與對比度隨機調整，以及對比度受限的自適應直方圖均衡化（CLAHE）藉此模擬不同拍攝條件與影像品質，提升模型對光照、角度與影像差異的適應性。模型流程圖如圖 3.4 所示。




圖 3.4 模型流程圖

3.4.1 影像前處理與增強方法

影像經過高斯濾波器（Gaussian Filter）平滑化處理後，可有效降低雜訊與光斑干擾，同時保留主要視網膜結構特徵。再以 CLAHE（Contrast Limited Adaptive Histogram Equalization）進行局部對比度增強，可在避免亮部過度提升的條件下突顯血管與病變區域，進而提高後續特徵萃取的辨識度。

為提升視網膜影像在分類任務中的品質，本研究針對 APTOS 2019 視網膜影像進行前處理。圖 3.5 為原始影像、經 Gaussian Filter 處理後影像，以及套用 CLAHE 後的結果。




圖 3.5 視網膜影像前處理效果比較

3.4.2 數據擴增

顯示 APTOS 2019 Blindness Detection 資料庫各個等級資料不平衡情形，為避免糖尿病視網膜病變 (DR) 影像資料中各類別樣本數差異過大導致模型訓練偏向多樣本類別，本研究採取資料平衡策略。針對每一病變等級，設定最少樣本數門檻 800 張與最多樣本數上限 2000 張。當某類別影像數量少於 800 張時，進行隨機重複抽取，以增加該類別樣本數；反之，若樣本數超過 2000 張，則採隨機下採樣，使各類別樣本數維持於合理範圍，如表 3.2 所示。

表 3.2 APTOS 2019 Blindness Detection 數據擴增後訓練集張數

DR 等級名稱	原始眼底影像	擴增後眼底影像
No DR	1,805	1,805
Mild NPDR	370	800
Moderate NPDR	999	999
Severe NPDR	193	800
Proliferate DR	295	800

3.4.3 超參數設定

採用兩階段式訓練流程以提升模型的穩定性與收斂效率。Warm-up 階段，凍結主幹網路的特徵提取層，僅訓練分類層，共進行 5 個 epoch，學習率設定為 1×10^{-3} ，使分類層權重能初步適應資料分布。接著進入 Fine-tuning 階段，解凍整個模型權重進行全參數微調，共訓練 150 個 epoch，並將學習率降低至 1×10^{-5} ，以避免權重更新過大導致性能下降。表 3.3 為本研究糖尿病型視網膜病變嚴重等級分類訓練模型相關超參數設定。

整體訓練過程使用 Categorical Crossentropy 作為損失函數，批次大小設為 16。為動態調整學習率，採用 ReduceLROnPlateau 策略，當驗證損失在連續 5 個週期內未改善時自動降低學習率（最低降至 1×10^{-8} ），以促進模型穩定收斂；同時搭配 EarlyStopping 機制，若驗證準確率在 10 個週期內未提升，則提前終止訓練，以防止過擬合並縮短訓練時間。

表 3.3 模型參數設定

項目	設定值
影像尺寸大小	224x224
Channel	3
批次大小(Batch Size)	16
損失函数(Loss function)	Categorical Crossentropy
學習率調整策略	ReduceLrOnPlateau (patience=5, 最小 LR = 1e-8)
Epoch	Warm-up 5
	Fine-tuning 150
學習率(Learning Rate)	Warm-up 階段 1×10^{-3}
	Fine-tuning 階段 1×10^{-5}
EarlyStopping	patience=10

3.5 模型訓練過程

本研究改良之 CNN 模型在訓練過程中整體呈現穩定收斂趨勢。訓練損失與驗證損失皆由初期約 2.2 逐步下降至約 0.7~0.75，雖然中間驗證損失存在一定波動，但兩條曲線始終相互貼近，未出現驗證損失明顯上升的情況，顯示模型並未產生嚴重過擬合，如圖 3.6 所示。




圖 3.6 CNN 模型之 Loss Curve 圖

訓練與驗證準確率由約 0.4 持續提升至接近 0.9，兩條曲線趨勢一致且差距不大，代表模型在訓練集與驗證集上皆具有良好的學習效果與泛化能力。綜合損失與準確率曲線可推論，搭配資料增強、L2 正則化及 Early Stopping 等設定後，CNN 模型能穩定學到有效特徵並達到合理的辨識效能，如圖 3.7 所示。




圖 3.7 CNN 模型之 Accuracy Curve 圖

ResNet50 的訓練與驗證曲線顯示模型具有良好的收斂特性。訓練損失由約 1.35 持續下降至約 0.55，而驗證損失亦同步由 1.10 左右下降，並在約第 20 epoch 後趨於平穩，維持在 0.68 至 0.72 的範圍內。雖然訓練損失持續下降、兩條曲線間逐漸出現差距，但沒有明顯驗證損失上升的情形，表示模型僅有輕微過擬合，整體泛化能力仍屬穩定，如圖 3.8 所示。




圖 3.8 ResNet50 模型之 Loss Curve 圖

訓練準確率由 0.55 快速提升，最終達到 0.93 以上，驗證準確率則提升至約 0.89，兩者差距保持在可接受範圍。此結果顯示 ResNet50 能有效學習視網膜病變的特徵分布，且在驗證集上仍能維持高準確率，如圖 3.9 所示。




圖 3.9 ResNet50 模型之 Accuracy Curve 圖

InceptionV3 的訓練與驗證曲線呈現穩定且一致的收斂趨勢。訓練損失由約 1.50 持續下降至約 0.63，驗證損失則從 1.20 降至約 0.72，兩條曲線在整個訓練期間走向相近，且驗證損失沒有明顯上升，顯示模型未出現過擬合問題。在訓練初期，損失的上下震盪屬於正常現象，反映模型正逐步學習多尺度特徵與穩定權重，如圖 3.10 所示。




圖 3.10 InceptionV3 模型之 Loss Curve 圖

Accuracy Curve 顯示訓練與驗證準確率由約 0.50 持續上升，最終分別達到約 0.90 與 0.91。驗證準確率在中段訓練期間長時間領先訓練準確率，代表模型在泛化能力上具有良好表現，並未對訓練資料產生過度擬合，如圖 3.11 所示。




圖 3.11 InceptionV3 模型之 Accuracy Curve 圖

EfficientNetB5 的訓練與驗證曲線顯示模型具有良好且平穩的收斂表現。訓練損失由約 1.35 持續下降至約 0.50，而驗證損失亦自約 1.10 降至約 0.62，兩條曲線的趨勢高度一致，且驗證損失並未出現明顯上升，顯示模型幾乎沒有過擬合情形。訓練前段雖有小幅震盪，但隨著 epoch 增加，損失逐漸趨於穩定，反映 EfficientNet 的複合縮放設計能有效學習多層次特徵，如圖 3.12 所示。




圖 3.12 EfficientNetB5 模型之 Loss Curve 圖

Accuracy Curve 訓練與驗證準確率皆由約 0.50 持續提升，最終分別達到約 0.96 與 0.90。兩者曲線貼近且差距始終維持在可接受範圍內，顯示模型具有良好的泛化能力，能有效辨識多種病變程度，如圖 3.13 所示。




圖 3.13 EfficientNetB5 模型之 Accuracy Curve 圖

為進一步分析各模型對不同病變程度的分類差異，本研究分別繪製四種架構之混淆矩陣。

CNN 模型雖能正確辨識大部分 No_DR，但在 Moderate 與 Severe 類別中仍出現明顯誤判，顯示其特徵提取能力有限，如圖 3.14 所示。




圖 3.14 CNN 混淆矩陣

ResNet50 模型透過殘差結構提升深層特徵學習效果，誤判情形較 CNN 減少，整體分類集中度明顯提升，如圖 3.15 所示。




圖 3.15 ResNet50 混淆矩陣

InceptionV3 模型利用多分支卷積架構同時擷取不同尺度特徵，於中度與重度病變的辨識上表現穩定，混淆矩陣之對角線分布更為集中，如圖 3.16 所示。




圖 3.16 InceptionV3 混淆矩陣

EfficientNetB5 模型呈現最明顯的對角集中現象，顯示其在各類別間具備最佳的一致性與區辨力，能有效降低病變誤判與漏判，如圖 3.17 所示。




圖 3.17 EfficientNetB5 混淆矩陣

為評估本研究所提出模型架構與前處理策略的有效性，將本研究模型訓練成果與其他同樣使用 APTOS 2019 Blindness Detection 資料集之研究進行比較，如表 3.4 與表 3.5 所示。

表 3.4 他人研究模型效能比較

評估指標 模型	Accuracy	Precision	Sensitivity	Specificity
CNN[9]	0.9980	0.9800	0.9800	0.9800
ResNet50[10]	0.9360	0.7600	0.8400	
InceptionV3[11]	0.9390	0.9309	0.9181	0.9532
EfficientNetB5[12]	0.9606	0.9597	0.9596	0.9902

表 3.5 本研究模型訓練結果

模型 \ 評估指標	Accuracy	Precision	Sensitivity	Specificity
CNN	0.9231	0.9152	0.9089	0.9807
ResNet50	0.9462	0.9420	0.9370	0.9864
InceptionV3	0.9372	0.9293	0.9232	0.9843
EfficientNetB5	0.9654	0.9602	0.9605	0.9915

四種模型在相同資料集上的整體表現具有一致趨勢，但本研究在多項指標上呈現更具穩定性的成果。以 EfficientNetB5 為例，其他研究於該資料集上的準確率約為 0.9606，而本研究則提升至 0.9654，同時在精確率、靈敏度與特異度上也均略高於其他研究結果，顯示前處理與訓練策略確實提升模型對不同病變程度的辨識能力。

另外，ResNet50 與 InceptionV3 的比較亦呈現相同趨勢。他人研究的 ResNet50 準確率為 0.9390，本研究提升至 0.9462；InceptionV3 的準確率雖在數值上略接近，但本研究在靈敏度與特異度的表現更為均衡，代表模型預測更能兼顧不同類別的正確率。在同一 APTOS 2019 資料集條件下，本研究模型於多數指標皆優於既有文獻，驗證所採用之資料前處理流程、資料增強策略與訓練設定能有效提升視網膜病變分類效能，並具備作為後續系統部署的可行性。

3.6 系統設計

本節說明本研究系統之完整設計，內容包含系統需求分析、架構規劃、功能模組流程、辨識模型整合方式、資料庫配置與介面設計原則等。前述章節已描述本研究的背景與方法，因此本節將著重於系統層面的具體實作構成。

本系統依臨床端操作需求進行模組化規劃，形成登入與權限管理、病患資料管理、眼底影像管理、回診管理、後台管理及 AI 分級模組等核心功能。各模組以統一的邏輯層與資料庫結構串接，維持整體架構的一致性與可維護性。系統以 Python 與 PyQt5 建構桌面應用程式，搭配 SQLite 作為本地資料存取，以符合診間環境對易部署、低維護成本與離線使用的需求。

在影像辨識方面，本系統整合事先訓練之糖尿病視網膜病變分級模型，透過前處理、推論與後處理流程取得五級分級結果，並回寫至資料庫。為兼顧系統實用性與資料安全，影像於匯入後即自動匿名化並統一管理檔案命名，分級結果亦可由醫師人工覆核與修正。

介面設計部分採用醫療資訊系統常見之易讀性與即時提示原則，並整合開發過程中確立的設計要點，例如分級色彩標示、垂直標題區、回診顏色狀態、病患大頭照與多視窗資料整合等。後續數節將依序說明需求、架構、流程模組、模型整合、資料庫結構與介面設計內容。

3.6.1 系統需求分析

本系統之前端功能性需求，從登入、病患資料搜尋與管理、影像上傳與 AI 分級、影像詳情之人工覆核、回診單建立與回診狀態管理，一直到後台帳號設定與系統提示訊息，涵蓋互動的完整流程。旨在確保醫護能以最少的操作步驟完成病患管理與影像辨識工作，並透過清楚的視覺提示與互動設計提升使用效率與準確性，如表 3.6 所示。

表 3.6 前端功能性需求

Front-end Functional Requirements	
FEFR1	使用者登入與角色切換
	系統需提供登入介面，支援： 1. 帳號密碼登入 2. 角色選擇（管理員／醫師／護士） 登入後依角色顯示不同功能與權限。
FEFR2	病患資料搜尋
	使用者可透過病患生日（八碼）或姓名搜尋資料。 搜尋結果以卡片方式呈現，支援同時顯示多名病患並點擊進入詳細頁。
FEFR3	病患資料建立與編輯
	於病患頁面可新增或編輯病患資料，內容包含： 1. 姓名、生日、性別、身分證字號 2. 聯絡方式與病史 3. 診斷結果與備註欄位 系統需提供格式檢查與必填提示。
FEFR4	眼底影像上傳與標記
	使用者可上傳眼底影像，系統需提供： 1. 左右眼選擇 2. 自動命名與檔案匿名化 3. 影像縮圖顯示 4. 拍攝日期呈現 影像應自動複製至系統資料夾並建立 index 編碼。

(待續)

表 3.6 前端功能性需求

FEFR5	AI 分級結果顯示
	系統需顯示 AI 辨識出的糖尿病視網膜病變等級，並以顏色提示： · 綠色：1 級 · 紅色：2-5 級 · 灰藍色：未分級／無效影像 前端需即時更新顯示結果。
FEFR6	影像詳情檢視與人工覆核
	進入影像詳情頁後，可檢視完整影像並進行： 1. 分級結果修改 2. 醫囑輸入/更新 3. 左右眼標記調整 4. 刪除影像資料 所有修改需同步更新資料庫。
FEFR7	回診單建立與管理
	使用者可新增或編輯回診單，內容包含： 1. 回診日期與時間 2. 回診原因 3. 指定醫師 4. 待定回診（未設定時間）機制 可從主畫面、病患頁或影像頁多入口新增。

(待續)

表 3.6 前端功能性需求

FEFR8	回診狀態顯示與報到流程
	主畫面右側需呈現回診列表，並以顏色代表狀態： · 黃：未設定時間 · 灰：尚未到時 · 紅：逾時未報到 · 綠：已報到（有效時間內） 使用者可直接點擊「報到」更新狀態。
FEFR9	後台帳號管理介面
	管理員可於後台 GUI 執行： 1. 新增帳號 2. 刪除帳號 3. 修改角色 並需提供操作確認與格式檢查。
FEFR10	提示訊息與錯誤通知
	系統前端需提供： 1. 必填欄位提醒 2. 生日與身分證格式檢查 3. 刪除資料前的確認視窗 4. 上傳影像失敗警示 以確保操作正確性與易用性。

前端非功能性需求主要描述介面在可用性、效能、視覺一致性與操作安全性方面所需達成的標準。由於系統主要使用者為臨床醫師與護理人員，其操作環境具有時間緊迫、資訊量大與需要快速辨識狀態等特性，因此前端介面的設計需特別著重於操作流暢度、資訊可視性與錯誤防範能力。表 3.7 彙整本系統之前端非功能性需求。

表 3.7 前端非功能性需求

Fornt—end non—functional requirement	
FENFR1	操作性 (Usability)
	介面需簡潔直觀，常用功能需以最少步驟完成，以符合醫療場域之快速操作需求。所有按鍵、欄位與提示文字需具備一致性與清晰性。
FENFR2	反應速度 (Responsiveness)
	資料更新 (影像上傳、回診狀態變更、病患資料修改等) 需即時反映於介面，不得產生明顯延遲，以避免造成臨床流程中斷。
FENFR3	可視性 (Visibility)
	介面需以顏色、圖示、區塊分群等方式協助使用者快速辨識影像分級、回診狀態與錯誤提示，避免資訊遺漏或誤判。
FENFR4	一致性 (Consistency)
	所有頁面需採用一致的排版、配色、字體大小與操作邏輯，使使用者可輕易理解並快速習慣操作。
FENFR5	錯誤防呆 (Error Prevention)
	對所有輸入欄位進行格式檢查 (如生日格式、身分證格式)，並在刪除或覆寫資料前提供彈出式確認提示，避免誤操作造成資料遺失。
FENFR6	資訊回饋 (Feedback)
	每項操作 (例如影像成功上傳、資料更新完成、回診報到成功) 皆需提供明確的提示訊息，讓使用者得知系統是否正確執行。

後端功能性需求主要描述系統在資料處理、邏輯運算、影像管理、AI 推論與權限控管等層面的必備能力。後端模組需能接收前端介面

送出的各項操作指令，並負責資料寫入、更新與查詢，同時確保影像匿名化、AI 分級流程正確執行，以及回診與帳號管理之資料一致性。

表 3.8 彙整本系統之後端功能性需求。

表 3.8 後端功能性需求

Back-end Functional Requirements	
BEFR1	病患資料管理 (CRUD)
	後端需提供統一 API 進行病患資料的新增、查詢、更新與刪除操作。需進行唯一性檢查（例如身分證字號與 patient_id），並確保更新後之資料能同步反映至前端顯示。
BEFR2	影像管理與匿名化處理
	後端需負責處理上傳影像之複製、重新命名、索引編號建立與資料庫寫入。影像檔名不可包含個資，並需統一儲存至系統管理目錄，確保檔案可追蹤且安全。
BEFR3	AI 模型推論流程
	整合已訓練之糖尿病視網膜病變分級模型，進行： 1. 影像前處理 2. 模型推論 3. 分級後處理 4. 結果寫回資料庫 需確保推論流程穩定，並可處理無效影像或錯誤情形

(待續)

表 3.8 後端功能性需求

BEFR4	影像詳情更新功能
	後端需支援前端傳入之影像資訊修改，包括： 1. 分級結果更新 2. 左右眼標記 3. 醫囑內容 4. 影像刪除（含檔案移除） 並需保持資料庫與檔案系統一致。
BEFR5	回診管理（新增／修改／刪除／報到）
	後端需提供回診單相關功能 API，包括： 1. 新增回診單（支援待定時間） 2. 回診資訊更新 3. 回診單刪除 4. 報到狀態切換 需確保回診資料可依日期查詢並供前端呈現。
BEFR6	使用者登入與權限控管
	後端需驗證帳號密碼，並依使用者角色（管理員／醫師／護士）限制可使用的 API。敏感操作（如刪除病患或影像）需僅限有權限之角色執行。
BEFR7	後台帳號管理
	後端需提供帳號新增、刪除與角色修改的 API。需檢查帳號是否重複，並正確寫入建立時間與角色資訊。

(待續)

表 3.8 後端功能性需求

BEFR8	操作紀錄 (Log) 寫入
	所有關鍵操作 (新增、刪除、編輯、登入) 需記錄於資料庫，包括： 1. 操作者 user_id 2. 操作時間 3. 動作類型 4. 目標資料與內容變更 以支援後續稽核與系統維護。
BEFR9	資料匯出與備份
	後端需支援資料庫與影像檔案的匯出與封裝，以便系統移轉與備份。需確保匯出內容完整且不洩漏個資。

後端非功能性需求主要描述系統在資料安全性、穩定性、一致性、效能與可擴充性等層面的要求。由於本系統需處理醫療影像、病患個資及回診紀錄等敏感資料，後端設計必須確保資料可靠、不遺失、不衝突，並能在離線環境下穩定運作。此外，系統應具備長期維護能力，支援功能新增與資料庫結構擴充。表 3.9 彙整本系統之後端非功能性需求。

表 3.9 後端非功能性需求

Back-end Non-Functional Requirements	
BENFR1	資料一致性 (Data Consistency)
	後端需確保資料庫更新操作具原子性與一致性，避免因同時操作造成資料衝突。所有前端修改 (影像、病患、回診) 需即時反映並保持資料正確性。

(待續)

表 3.9 後端非功能性需求

BENFR2	資料安全性 (Data Security)
	後端需避免影像與病患個資外洩，包括： 1. 影像檔名不可含個資 2. 系統自動管理影像路徑 3. 病患資料需以安全方式存放 同時限制僅有具權限的角色能執行敏感操作（如刪除病患）。
BENFR3	擴充性 (Scalability)
	後端架構需可支援後續新增模組（如更進階模型、排程系統、報表工具）以及資料庫欄位擴增，而不影響既有資料。
BENFR4	可維護性 (Maintainability)
	程式碼需具備清晰的模組化結構（如病患模組、影像模組、回診模組、log 模組），使功能能獨立維護。資料庫 schema 與 API 行為需具一致性，便於除錯與修改。
BENFR5	錯誤處理 (Error Handling)
	後端需具備完整的錯誤處理機制，例如： 1. 影像讀取失敗 2. 模型推論無效 3. 資料庫寫入錯誤 所有錯誤需回傳明確訊息供前端顯示，並避免影響其他模組運作。
BENFR6	離線可運作 (Offline Capability)
	系統需能在無網路環境下完全正常運作，包括資料讀寫、AI 推論與回診管理，後端不得依賴雲端 API 或外部伺服器。

3.6.2 系統架構設計

本系統採用本地端單機執行的形式，讓移動式站點單位即使在沒有網路的情況下也能正常使用。整體程式以 Python 為基礎，介面採用 PyQt5 建構為桌面應用程式，使用者可直接透過滑鼠操作介面完成所有功能。為了簡化安裝流程並避免伺服器架設，本系統的所有資料都儲存在本機的 SQLite 資料庫中，由 SQLAlchemy 負責管理資料表與物件映射，使後續資料維護更加方便。

啟動系統程式在開啟時會先載入影像辨識模型、建立資料庫連線 (Session)，並由 UIController 控制各個視窗的切換，例如登入畫面、主畫面、病患資料頁、影像詳情頁與後台管理等。所有資料處理動作 (新增、查詢、更新、刪除) 都透過邏輯層的函式來執行，避免介面層直接操作資料庫。

(1) 系統三層式架構設計

透過這種架構，系統可以維持良好的模組分工，介面程式不需要知道資料儲存的細節，AI 模型也能獨立運作，未來若要擴充功能或更換模型，也能在不影響整體架構的情況下進行更新。

1) 介面層 (UI Layer)

負責所有與使用者互動的視覺元件與操作邏輯，包含：

- A. 登入頁：ui/login.py
- B. 主畫面：ui/main.py
- C. 病患資料頁：ui/patients.py
- D. 眼底影像詳情頁：ui/image.py
- E. 回診編輯頁：ui/followUp.py

F. 預約管理頁：ui/reserve.py

G. 後台管理頁：ui/backstage.py、ui/logManage.py

2) 應用邏輯層 (Application Logic Layer)

統一處理系統邏輯，包括資料驗證、影像匿名化、回診判定、AI 推論等，主要模組為：

A. logic/db_access.py

封裝所有資料操作 (CRUD)，包含病患、影像、回診、帳號與操作紀錄等功能。

B. logic/db_config.py

資料庫 Engine、Session 配置。

C. assets/predict_dr.py

AI 分級模型推論介面，包括前處理、推論與結果整合。

3) 資料儲存層 (Data Layer)

管理病患資料、影像紀錄、回診資料及帳號權限等資料，並負責實際的儲存、查詢與更新。

A. Users：帳號、密碼與角色資訊

B. Patients：病患基本資料與頭貼 BLOB

C. Images：上傳影像的儲存路徑、分級、左右眼與醫囑

D. FollowUps：回診日期、原因、報到狀態、開立醫師

E. OperationLogs：記錄登入、修改、刪除等操作事件

(2) AI 辨識模組 (AI Inference Module)

AI 模組獨立於介面層與資料儲存層之外，由 `assets/predict_dr.py` 提供介面。模組的獨立性確保未來可替換或更新模型，而不須改動 UI 或資料庫結構。其功能包含以下四點：

- 1) 接收影像檔案路徑
- 2) 執行影像前處理
- 3) 呼叫糖尿病視網膜病變分級模型（五級分類）
- 4) 回傳等級並由邏輯層寫入資料庫

(3) 系統架構設計重點

- 1) 高模組化：介面、邏輯、資料三層分離，便於維護與擴充。
- 2) 低耦合性：UI 不直接操作資料庫而是透過邏輯層統一管理
- 3) 資料安全：影像匿名化處理與統一儲存路徑避免個資外洩
- 4) 可擴充性：AI 模組獨立設計，使模型可更換或升級。
- 5) 適用於臨床環境：採單機部署、離線運作、反應快速。

3.6.3 系統流程設計

本節介紹系統在實際運作時的主要流程，以及各功能模組之間的協作方式。與前一節的靜態不同，本節著重於在運行過程中所呈現的動態行為，包括使用者的操作流程、資料在不同模組間的流動方式，以及辨識模組與資料庫的交互過程。透過這些流程設計，使整個系統能以直覺、流暢且一致的方式協助醫療人員完成臨床作業。

(1) 整體運作流程概述

系統的主要操作流程大致可分為六個階段：

1) 登入與角色辨識

使用者輸入帳密後，系統確認角色（醫師／護士／管理員），並切換至相應介面。

2) 病患查詢與開啟資料

使用者可依生日或姓名搜尋病患，並於病患資料頁進行檢視、編輯或新增。

3) 影像上傳與分級流程

使用者於病患頁面新增眼底影像，系統完成匿名化存檔後呼叫 AI 模組進行自動分級。

4) 影像詳情與人工覆核

醫師可於詳情頁查看原圖、修正分級結果、補充醫囑，並更新資料庫。

5) 回診單建立與狀態更新

醫師或護士可新增回診單、設定時間，並於主畫面管理報到與逾時狀態。

6) 後台管理與操作紀錄

管理員可新增使用者帳號、設定角色並查詢系統操作紀錄。

(2) 代表性流程說明

1) 影像上傳與分級流程

此流程由前端與邏輯層共同完成：

- A. 選擇影像上傳(模擬眼底鏡拍攝效果) →
- B. 系統匿名化命名並保存 →
- C. 呼叫 AI 模組進行分級 →
- D. 分級結果寫入資料庫 →
- E. 前端更新影像列表與顏色標示。

此流程確保影像處理與資料更新一致，並提供清楚的視覺回饋，同時將資料去個人化保護病患隱私。

2) 回診單建立與報到流程

- A. 使用者於病患頁或主畫面按下「新增回診」。
- B. 查詢預約系統的空於時段
- C. 輸入回診資訊並存檔至資料庫。
- D. 主畫面自動顯示該日期的回診清單，並依狀態顯示不同顏色。
- E. 當病患報到時，使用者點擊「報到」，系統將狀態更新為已報到並重新整理清單。

(3) 流程設計重點

- 1) 以臨床實際操作順序為核心設計。
- 2) 影像處理與 AI 分級流程自動化，以降低人員操作負擔。
- 3) 各流程皆採即時更新（UI ↔ DB），確保資料一致性。
- 4) 回診流程採可視化呈現，提高可追蹤性。

3.6.4 系統模組設計

本系統以模組化思維設計各功能區塊，使每個模組各自負責明確的任務範圍，並透過邏輯層統一管理資料流程。此種設計方式不僅提升程式維護性，也使未來功能擴充更加容易。本節將從「設立目的與需求」與「實際執行辦法」兩個角度，說明系統核心模組的運作方式。

(1) 病患管理模組（Patient Module）

1) 設立目的與需求

整個系統的基礎資料來源，負責維護病患的基本資訊、醫療相關紀錄以及資料安全性。根據醫療場域需求，一位病患可能在多年內反覆就診，因此系統必須提供可靠、完整且可追溯的病患資料。而由於病患資料涉及高度個資，模組同時肩負資料安全與存取控管的責任。

2) 實際執行方式

模組透過邏輯層提供的資料庫操作介面進行資料新增、編輯與查詢。為避免欄位更新不一致，系統採動態欄位更新方式 setattr，確保資料完整性。此模組亦整合影像與回診模組，使使用者在瀏覽病患頁面時即可完整掌握其就診歷史。

(2) 影像管理與匿名化模組 (Image Module)

1) 設立目的與需求

眼底影像為本系統的核心資訊，其管理涉及檔案儲存、資料庫索引、匿名處理以及與 AI 模組的整合。由於影像通常來自不同裝置，其命名方式不一、來源格式不一致，若不統一管理，將難以追蹤與長期保存。另外，醫療影像具有個資風險，因此系統必須在上傳當下即完成匿名化。

2) 實際執行方式

影像匯入後，系統會立即將其複製到指定資料夾，並以病患編號與影像序號重新命名，使影像不含任何識別資訊。接著，將影像資訊寫入資料庫並生成影像編號，供後續查詢。所有影像路徑皆由系統統一管理，避免因外部搬移或刪除形成資料斷層。

(3) AI 分級模組 (AI Inference Module)

1) 設立目的與需求

本系統的最主要功能，提供使用者在沒有醫生的情況下快速獲得初步的結果，減少醫療量能的消耗。

2) 實際執行方式

系統啟動時即預先載入 AI 模型，減少多次推論的等待時間。當影像完成匿名化與儲存後，邏輯層將路徑傳入 AI 模組，執行前處理、推論與後處理，產生五級 DR 分級結果。若影像無法被辨識，系統會回傳特殊標記並提示使用者人工覆核。

(4) 回診管理模組 (Follow-Up Module)

1) 設立目的與需求

在糖尿病或慢性疾病的照護流程中，追蹤回診是一項重要任務。本模組旨在提供一套可視化的回診管理機制，使醫師與護理人員能立即掌握患者的回診狀態（如未到、逾時、已報到等）。同時，系統需支援「待定回診」，以反映真實診間中常見的暫緩安排情況。

2) 實際執行方式

使用者新增回診單後，系統將資料寫入資料庫，並於主畫面依日期載入回診清單。模組內部使用明確的狀態碼判斷是否逾時，並以不同顏色標示。在患者報到時，模組會更新狀態並記錄時間，使資料得以追溯。整體設計以快速辨識與低操作成本為優先。

3.6.5 辨識模型整合

本系統採用先前訓練完成的糖尿病視網膜病變（DR）五級分類模型，並透過獨立的 `predict_dr` 模組進行整合。此設計使模型推論流程與系統其他功能保持獨立，避免介面層與資料層直接接觸深度學習相關程式碼，也便於日後替換或更新模型版本。

系統啟動時即預先載入模型，以減少每次推論時重新載入造成的延遲。當使用者於病患頁上傳影像後，影像管理模組會完成匿名化命名與儲存，並將影像路徑傳入 `predict_dr`。該模組會負責影像前處理、模型推論與結果轉換，最終回傳 1~5 級的分級結果。

辨識流程完成後，系統會即時將分級結果回傳前端介面，以顏色標示於影像縮圖上，讓醫師能立即辨識影像可能的異常程度。影像詳情頁也保留人工調整分級與紀錄醫囑的功能，使 AI 可作為輔助，而非取代醫師判讀。

3.6.6 資料庫設計

本系統採用 SQLite 進行本地端資料儲存，並以 SQLAlchemy 建立映射，使資料表結構能以物件形式進行操作，提升開發與維護的效率。資料庫設計以「清楚分工、關聯明確、可擴充性高」為核心原則，並依照系統功能需求將資料區分為病患資料、影像資料、回診紀錄、使用者帳號以及操作紀錄五大類如圖 3.18~3.22。

在資料結構規劃上，各資料表皆以主鍵作為唯一識別，同時利用外鍵連結病患、影像與回診等資訊，使不同模組間的資料能正確對應。例如影像表與回診表皆以病患編號作為關聯，使系統能快速查詢病患相關歷史紀錄。

為滿足系統安全性需求，使用者資料以角色區分權限，並透過 Log Table 記錄關鍵操作，使資料修改與使用情形皆可追蹤。此設計不僅提升資料完整性，也符合作業稽核與醫療資訊管理之需求。整體資料庫結構簡潔且具彈性，後續若需擴充欄位或新增模組，亦可在不影響既有資料的前提下進行調整。

病患資料 - Patients Table

欄位名稱	資料型態	說明
-----	-----	-----
patient_id	Integer	病歷號(唯一)
name	String	姓名
birthday	Date	生日
gender	String	性別
national_id	String	身分證(唯一)
visit_date	Date	就診日期紀錄
contact_info	String	聯絡方式
history	Text	其他病史
diagnosis_result	Text	記錄診斷結果 (包含你辨識的結果)
created_at	DateTime	資料建立時間

圖 3.18 病患資料_資料表

回診紀錄表 - FollowUp Table

欄位名稱	資料型態	說明
-----	-----	-----
followup_id	Integer	回診單ID(唯一)
patient_id	Integer	病患ID (外鍵，對應 patients.id)
doctor_id	Integer	開立醫生ID (外鍵)
followup_date	Date	回診時間
reason	Text	回診原因／備註
checked	Boolean	是否已回診 (True/False)

圖 3.19 病患資料_資料表

照片管理 - Image Table

欄位名稱	資料型態	說明
image_id	Integer	自動遞增 (唯一)
patient_id	Integer	所屬病患ID (外鍵)
index_id	Integer	該病患照片編號
image_path	String	圖片儲存路徑
grade_result	Integer	分級結果 (AI或醫師結果)
eyes_type	String	左右眼
advice	Text	醫囑
created_at	DateTime	上傳時間

圖 3.20 照片管理_資料表

帳號管理 - User Table

欄位名稱	資料型態	說明
user_id	Integer	主鍵(唯一)
username	String	使用者帳號
password	String	密碼
role	String	使用者角色 (admin/doctor/nurse)
created_at	DateTime	建立時間

圖 3.21 帳號管理_資料表

操作紀錄 - Log Table

欄位名稱	資料型態	說明
id	Integer	主鍵，自動遞增
user_id	Integer	操作者 (對應 User.id)
timestamp	DateTime	操作時間
action_type	String	操作類型: view / create / edit / delete / login
target_type	String	操作對象類型: patient / image / user
target_id	Integer	操作對象的主鍵ID (例如 patients.id)
detail	JSON/Text	{ "field": "advice", "old": "A", "new": "B" }

圖 3.22 權限操作紀錄_資料表

3.6.7 GUI 設計要點

本系統之圖形使用者介面（GUI）設計以臨床實務需求為核心，強調操作效率、資訊可視化與一致性的互動體驗。由於醫療場域具備操作時間有限、使用者專注度高與資訊量密集等特性，介面需在有限時間內協助醫療人員做出正確判斷，因此 GUI 的設計並非僅是視覺呈現，而是系統功能流程的重要延伸。本節說明系統在設計介面時所依循的原則與考量。

(1) 醫療使用情境下的設計考量

本系統的介面設計首先考量醫療場域的即時性需求。在診間環境中，醫師與護理人員必須在極短時間內完成病患查詢、影像判讀與回診安排等任務，因此介面需能協助使用者迅速辨識資訊並進行無負擔的操作。系統因此採取簡潔且具高辨識度的視覺呈現方式，使關鍵資訊如影像分級與回診狀態能在不需額外操作的情況下立即被使用者注意到。此外，整體互動流程亦以降低學習成本為目標，讓首次接觸系統的使用者也能快速理解操作方式並無縫銜接診療節奏。

(2) 界面結構與版面配置

為了使資訊呈現更具層次並減少使用者視線移動負擔，本系統採用固定且一致的版面配置原則。主畫面以左右分區方式呈現，其中左側用於病患搜尋與資料顯示，右側則專責回診清單與狀態管理，使主要資訊可同時被掌握而不互相干擾。病患資料頁、影像列表與影像詳情頁也沿用類似的布局方式，使使用者在不同頁面間切換時保持熟悉感。這種一致性的版面設計使操作動線更自然，並能有效減少醫療流程中的停頓時間。

(3) 色彩運用與資訊可視化

系統在色彩運用上強調狀態辨識的清晰性，特別是在影像分級與回診管理中。結果以由綠至紅的色調呈現，反映病變程度的輕重，並避免使用過度複雜的視覺元素。回診狀態也以醒目的色彩標示，能透過顏色迅速得知病患是否未到、已報到或已逾時。可視化設計符合醫療作業需求，使重要資訊能在第一眼即被捕捉。

(4) 操作一致性與流暢性

本系統在所有頁面中使用一致的互動邏輯與操作位置，以維持流暢的使用體驗。主要操作按鈕均置於頁面右側或右下角，使使用者不需重新適應不同介面中的操作位置；影像放大、詳情檢視與回覆按鍵也維持相同的觸發方式，避免因互動不一致而增加操作負擔。此外，介面切換採由中央控制器統一管理，使各功能頁面之間過渡自然、無延遲或不必要的重載。整體設計強調使用者操作的連續性，提升臨床使用時的效率與可靠性。

(5) 錯誤防呆與即時回饋

醫療資料對準確性與完整性要求極高，因此系統在介面中整合了多項防呆設計。所有重要欄位在送出前皆會進行格式檢查，如生日格式、身分證字號與必填欄位等，以避免使用者因疏忽造成錯誤資料寫入。此外，可能造成資料遺失的操作如刪除影像或刪除病患資料時，系統會主動跳出確認視窗，確保使用者判斷無誤。使使用者明確知道操作已成功執行。

整體而言本系統的整體視覺風格以簡潔、穩定為主軸。色彩與字體均力求一致，避免多餘裝飾，使介面不僅具有專業形象，也能降低視覺干擾。所有功能模組的呈現方式皆採模組化的資訊區塊，使介面結構清楚、內容層級分明。透過這些設計原則，系統得以在提升臨床操作效率的同時，也維持高度一致性與友善的使用者體驗。

3.6.8 GUI 畫面設計

本節展示本系統依據前述設計原則所構成的實際介面呈現。為了在開發前先確立視覺風格、版面配置與資訊層級，本研究以 PPT 製作一套完整的 1:1 介面模擬稿，涵蓋登入畫面、主畫面、病患管理頁面、影像列表與詳情頁、回診單編輯畫面以及後台管理等各功能模組。此模擬稿作為介面開發的基準，使團隊能在正式實作前即明確掌握版面佈局、空間比例、內容分區與色彩規範，並確保最終成品能忠實反映設計需求。後續各圖即為本研究系統主要介面的視覺呈現，展示各頁面在實際運作時的使用情境與資訊配置。

此模擬稿作為 UI 開發的標準基準，使介面在正式實作前便已確立視覺層級、空間結構與色彩規範，並確保最終成品能忠實反映設計理念。後續各圖即為本研究主要介面的視覺展示，模擬系統在實際運作時的使用情境與資訊配置如圖 3.23~3.29。(註：此為設計稿不代表最終畫面)



圖 3.23 登入畫面_設計圖




圖 3.24 主畫面_設計圖




圖 3.25 病患資料頁_設計圖




圖 3.26 功能視窗_設計圖




圖 3.27 預約管理系統_設計圖



圖 3.28 後台頁面_設計圖



圖 3.29 後台操作紀錄管理頁面_設計圖

第 4 章 成果展示

本研究開發出一套以 EfficientNetB5 為核心的糖尿病視網膜病變自動辨識系統，整合深度學習模型、影像前處理與 PyQt5 圖形介面，於五級病變分類任務中達到 96.54% 的準確率，並展現高靈敏度與特異度。使用者可在介面中完成病患資料建檔、眼底影像上傳與自動辨識分級，系統即時顯示病變等級與簡易結果資訊等。透過此等視覺優化之 UI 設計，使醫護人員能以直覺方式操作，提高檢查效率並方便於臨床實際應用。

4.1 辨識成果

本研究針對 CNN、ResNet50、InceptionV3 與 EfficientNetB5 四種深度學習架構進行實驗對比。四種模型在準確率（Accuracy）、精確率（Precision）、靈敏度（Sensitivity）及特異度（Specificity）等四項關鍵評估指標上的效能比較結果，如圖 4.1 所示。




圖 4.1 各模型評估指標比較圖

EfficientNetB5 為綠色長條在所有評估指標上均顯著高於其他三種模型（CNN、ResNet50、InceptionV3）。EfficientNetB5 不僅在準確率上表現最佳，更在與臨床篩檢高度相關的靈敏度（Sensitivity）與特異度（Specificity）上展現了極高的穩定性。這顯示該模型能有效平衡特徵提取的深度與廣度，在精準識別病變的同時，也能大幅降低誤判率，適合應用於糖尿病視網膜病變的輔助診斷任務。

基於上述實驗結果，本研究最終選定 EfficientNetB5 作為本系統的核心影像辨識模型。為了將訓練成果實際部署至應用端，我們將訓練完成且具備最佳權重的 EfficientNetB5 模型轉換並儲存為 .h5 格式檔案。此格式能完整封裝模型的架構、權重參數與優化器狀態，使其能順利整合至後續開發的 PyQt5 視窗介面系統中，執行即時的眼底影像分析。

4.2 系統展示

運作流程初想，主要分為「臨時站點」與「醫院」兩大區塊，流程圖如圖 4.2。




圖 4.2 運作流程圖

首先，病患於臨時站點由醫護人員協助建立基本資料，並透過眼底鏡拍攝眼底影像。拍攝完成後，影像與病患資料會儲存在站點電腦中，作為後續辨識與追蹤的依據。

接著臨時站點電腦會將整理好的病患資料與眼底影像傳送至醫院端。醫院端部署視網膜病變辨識模型，接收影像後自動進行模型辨識，產生初步的分級結果與風險評估。辨識結果會呈現給醫師進一步確認，醫師可依臨床經驗調整判讀、下達診斷與後續建議。完成確認後，將結果與醫囑寫入醫院資料庫中，供未來查詢與長期追蹤使用。

最後系統會根據資料庫中的最新結果，回傳至臨時站點，讓現場醫護人員能即時向病患說明目前眼底檢查狀況與後續就醫建議。同時，病患亦可透過 LineBot 進行結果查詢與回診預約，LineBot 會向資料庫發送請求，取得辨識與醫師確認結果後，以圖文方式回覆病患。藉由臨時站點、醫院主機、資料庫及 LineBot 之整合，本系統建立起從影像採集、雲端辨識、醫師審閱到病患查詢與預約的一條龍服務流程。

透過人工智慧輔助，醫護人員能快速判讀影像並遠端傳送結果供醫師確認，提升診斷效率並減少延誤治療的情況。雖然目前仍屬研究階段，但系統的開源性與彈性設計具有推廣價值，未來可結合在地臨床資料與醫師回饋進行優化，提升準確率並推動 AI 醫療普及化，實現改善偏鄉醫療資源不足的目標。

4.2.1 系統流程設計

當患者就醫時，詢問病情後由醫師為患者拍攝視網膜照片，將眼底影像上傳至辨識系統，醫生將系統分析輸出的結果結合自身經驗給出最後診斷報告，將診斷內容及患者資料存入資料庫中，回診時間到時會提醒繪者回診。流程如圖 4.3。




圖 4.3 系統流程設計圖

4.2.2 介面關聯圖

本系統之 UI 介面主要由「登入畫面」、「主畫面」、「病患資料詳情頁」、「眼底鏡頁面」、「預約管理頁面」、「回診單與就診紀錄」與「後台管理」等模組構成，如圖 4.4 所示。




圖 4.4 UI 介面關聯圖

彼此以按鈕切換與資料傳遞方式形成完整的操作流程。使用者首先於登入畫面選擇身分並輸入帳號與密碼，驗證通過後進入主畫面。主畫面提供病患搜尋、新增病患、回診管理及預約管理等功能，是各子頁面的入口。

使用者從主畫面選擇特定病患後，會進入「病患資料詳情頁」，可編輯與瀏覽病患基本資料、就診紀錄及上傳眼底鏡照片等，並可連結到「眼底鏡頁面」，查看眼底影像之分級結果、下拉選單切換左右眼與輸入醫囑。同時，主畫面也可直接連至「預約管理系統頁面」，讓醫護人員查看預約清單、確認病患之預約狀況及進行日期選擇；已完成之預約會紀錄於「回診單／就診紀錄」頁面，提供日期設定與瀏覽看診紀錄，形成完整的門診流程追蹤。系統另設「後台管理」功能，包含帳號管理、操作紀錄管理與版本控制，用於維護使用者權限與系統運作狀態，確保整體系統在臨床使用上安全且可追溯。

4.2.3 互動介面展示

本節將展示本研究最終完成之系統介面成果。以章節 3.6.8 中所建立之 1:1 視覺介面設計模板為基底，結合實際使用後的數個版本優化，在 PyQt5 之上搭建最終系統。

下面將依系統主要功能區塊逐一展示，包括登入頁面、主畫面、病患管理介面、影像瀏覽與詳情頁、回診管理頁面以及後台操作畫面等，並呈現其在實際運作中的資訊配置與視覺效果與各區塊功能說明，可更清楚觀察系統從設計概念到具體介面之間的轉化，也能驗證本研究在介面規劃與互動設計上的整體成果。

(1) 登入畫面(LoginWindow)

進入視網膜病變系統的起始登入介面，如圖 4.5 所示。



圖 4.5 登入畫面

此畫面採簡潔設計，背景融合了醫療科技元素，主要的登入功能集中在右側，內容包含以下三點：

1) 系統識別

標示系統名稱及版本號 (V1.0.0)。

2) 角色選擇

允許使用者選擇登入角色，包括醫生、護士或管理員，依使用者更改權限。

3) 身份驗證

供使用者輸入帳號與密碼以進行身份驗證，以進入系統操作。

(2) 主畫面與快速功能區(MainWindow)

此畫面為系統的主要操作介面，提供病患管理回診排程及兩大核心功能，如圖 4.6 所示。



圖 4.6 主畫面

具體區塊配置與重點功能說明如下三點：

1) 使用者資訊與時間（上側，如橘色方框所示）

頁面頂部顯示當前使用者身份（例如：fufu(管理員)）、現在時間，及登出按鈕。

2) 病患管理區（左側，如紅色方框所示）

A. 搜尋區

上方欄位供使用者輸入病患生日（YYMMDD）進行快速搜尋。

B. 快速新增

設置新增病患按鈕，方便快捷地建立新病患資料。

3) 回診管理區（右側，如藍色方框所示）

A. 回診清單

依序顯示預約回診的病患清單（顯示姓名和預約時間），依顏色區分可辨識過號及。

B. 快速操作

清單中每筆資料皆提供資料、詳情和報到等快速連結按鈕，以便管理和更新回診狀態。

C. 預約系統入口

下方設有進入預約管理系統按鈕，引導使用者進入更完整的預約排程介面，方便管理及查看。

(3) 病患資料頁面(PatientWindow)

此介面用於管理及檢視單一病患所有相關資料的綜合介面(如圖 4.7 所示)。畫面劃分為三大區塊，提供完整的病歷資訊：

The screenshot shows a web application window titled '病患資料頁面'. It features a sidebar on the left with two main categories: '基本資料' (Basic Information) and '就診紀錄' (Medical History). The '基本資料' section is highlighted with an orange border and contains a form with fields for 'D: 11', '姓名', '生日', '性別', '身分證', '聯絡電話', '其他病史', and '備註'. To the right of these fields are buttons for '大頭照', '匯出報告', and '儲存/更新'. The '就診紀錄' section is highlighted with a red border and contains a table with a header '尚無回診紀錄' and a '新增回診' button. The right side of the page is a large area for '眼底鏡照片' (Eye Examination Photos), highlighted with a blue border, containing a large empty space labeled '(3)' and an '上傳照片' button at the bottom.

圖 4.7 病患資料頁面

1) 基本資料區（左上，如橘色方框所示）

包含病患的 ID、姓名、生日、性別、身份證號、聯絡電話、其他病史及備註等欄位。

設有匯出報告、儲存與更新以及大頭照等功能按鈕，用於資料維護及報告產出。

2) 就診紀錄區（左下，如紅色方框所示）

提供歷史就診與未來預約回診之紀錄顯示區，並設有新增加紀錄按鈕，方便醫護人員隨時補充或調閱病患的看診歷程。

3) 眼底鏡照片區（右側，如藍色方框所示）

此區塊用於展示病患歷次的檢查眼底鏡照片紀錄，方便輔助醫生進行視覺化追蹤與比對。

底部設有上傳照片之按鈕，用於將新的眼底影像資料匯入系統。

顯示基本資料、就診紀錄、眼底照片紀錄等，如圖 4.7 所示。

此頁面整合了病患就醫時的完整處理流程，旨在輸入資料、進行影像分析、記錄就診情況並排程下次預約。當病患就醫，將病患資料輸入後，傳入眼底鏡照片進行辨識，最後依照顯示結果完成就診紀錄登記與預約下次回診時間，完整呈現病患的資料詳情頁面如圖 4.8 所示。

病患資料頁面

基本資料

ID: 14

姓名: 花媽

生日: 1966/09/09

性別: 女

身分證: H556933652

聯絡電話: 0930221456

其他病史: 無

備註:

就診紀錄

2025/10/09 10:40:00 詳情 報到

2000/01/01 00:00:00 詳情 報到

新增回診

眼底鏡照片

編號: 001
日期: 2025/10/07
左右眼: 左
辨識結果: 1級
詳情

編號: 002
日期: 2025/10/07
左右眼: 右
辨識結果: 5級
詳情

上傳照片

圖 4.8 有資料之病患資料頁面

(4) 辨識功能之眼底詳情頁(ImageDialog)

此頁面為影像辨識功能的核心介面，用於展示、確認及管理眼底影像的詳細資料與分析結果，如圖 4.9 所示。



眼底詳情頁

照片編號： 001 病患ID： 10

上傳時間： 2025/11/30 03:02

分級結果： 5 左右眼： 右

醫囑：

視網膜纖維增生情況，嚴重恐失明

刪除 儲存/更新

圖 4.9 眼底詳情頁

其主要功能和組成介紹如下兩點：

1) 影像顯示與等級標示

影像邊框會依據分級結果自動變換顏色作為區分，提供直覺式的警示與辨識等級提示；提供左右眼的下拉式選單，用於指定或確認該影像屬於左眼或右眼。

2) 醫囑輸入與資料管理

提供醫囑欄位，供醫護人員記錄病情診斷或建議；設有刪除和儲存與更新按鈕，用於資料的維護與更新操作。

當眼底鏡照片傳入後，經模型辨識後計算機率分布，照分析數據結算預測等級，後台顯示結果如圖 4.10 所示。

```

✓ 預測等級：1 (No_DR)
📊 機率分布：
等級 1 (No_DR): 69.01%
等級 2 (Mild): 5.36%
等級 3 (Moderate): 4.47%
等級 4 (Severe): 5.05%
等級 5 (Proliferate_DR): 16.10%
✓ 預測等級：5 (Proliferate_DR)
📊 機率分布：
等級 1 (No_DR): 5.44%
等級 2 (Mild): 2.66%
等級 3 (Moderate): 21.37%
等級 4 (Severe): 13.99%
等級 5 (Proliferate_DR): 56.54%

```

圖 4.10 後台辨識分析結果

(5) 回診管理與報到(FollowUpDialog)

此對話框用於回診的排程管理與報到作業，頁面呈現病患的詳細回診資訊(如圖 4:11 所示)，包括以下三點：

The screenshot shows a window titled '回診單 / 就診紀錄' (Follow-up / Visit Record). It contains the following fields and controls:

- 診單編號:** 80
- 病患ID:** 9
- 開立醫生:** fufuLee
- 姓名:** 源靜香
- 回診時間:** 2025/11/18 09:40 (with a dropdown arrow)
- 選擇時段:** (button)
- 報到:** 是
- 就診原因:** 眼底病變評估
- 看診紀錄:** (empty text area)

On the right side, there are two buttons: '刪除' (Delete) and '儲存/更新' (Save/Update).

圖 4.11 回診單頁面

1) 基本資料

顯示本次回診單編號、病患 ID、姓名，以及負責開立的醫生。

2) 排程與狀態

記錄回診時間、選擇回診時段，以及當前的報到狀態。

3) 看診內容

記錄本次就診原因或看診紀錄。

此外，畫面右側提供了刪除和儲存與更新的功能按鈕，以便管理人員對回診資料進行維護與更新，如圖 4.11 所示。

(6) 預約管理系統

預約管理系統提供門診時段的視覺化排程介面，協助醫護人員快速掌握病患回診與門診負荷情形。使用者可在左側以年份、月份與週次設定欲查詢的區間，按下「查看」後，頁面即顯示該週的門診時段。每一小時細分為三個可預約單位，可於介面上利用顏色查看可預約時段：綠色為可預約時段，不可預約或已被預約的時段則以紅色顯示，午休與休診時段則會以「休診」區塊標示，方便一眼辨識可用門診量，如圖 4.12 所示。

Retinal System

預約管理系統

9/1 18:20~18:40

可預約

年 2025

月 9

週 1

查看

取消

確認

	一 9/1	二 9/2	三 9/3	四 9/4	五 9/5	六 9/6	日 9/7
8:00							休診
9:00							
10:00							
11:00							
12:00							
休診							
15:00							休診
16:00							
17:00							
18:00							
19:00							

圖 4.12 預約管理系統

當醫護人員點選表格中的綠色格子時，左側會同步顯示選取的日期與時間，確認無誤後按下「確認」即可完成該病患之回診預約；若需調整或刪除既有預約，可選取原有時段並點擊「取消」，系統會自動釋出該時段供其他病患使用。透過此預約管理介面，醫護人員能有效避免重複預約與超量掛號，並能依實際診間狀況彈性規劃門診與追蹤安排，提升門診流程之效率與病患就醫體驗。

(7) 後台管理系統(BackstageWindow)

帳號管理、新增/刪除帳號、修改權限及版本選擇等功能，如圖 4.13 所示。




圖 4.13 後台管理

只有擁有管理員權限之使用者才可進入此系統進入調閱或修改等動作。

(8) 帳號操作管理(OperationLog)

此頁面用於詳實記錄所有使用者的操作行為。以結構化的表格形式，呈現每一筆的操作時間、執行者、操作類別及變動細節。

表格主要欄位包括以下五點：

1) 時間

記錄操作的準確時間。

2) 使用者 ID

標示進行操作的使用者識別碼。

3) 動作

說明執行的操作類別，例如 `user.update_role`（更新使用者角色）、`user.delete`（刪除使用者）或 `user.create`（建立使用者）。

4) 物件

指明操作所影響的目標物件類型(例如：`user`)。

5) 細節

提供操作的具體變動內容，例如角色變更後的數值 (`"new_role": "nurse"`)或被更動的使用者名稱 (`"username": "Ziiii"`)。

此外，頁面頂部設有關鍵字搜尋欄位，讓管理人員可以依據動作、物件或細節等條件，快速篩選和查找特定的操作紀錄，如圖 4.14 所示。

操作紀錄					
關鍵字： 動作 / 物件 / 細節					
	時間(UTC)	使用者ID	動作	物件	細節
1	2025-08-24 21:42:12	8	user.update_role	user	{"new_role": "nurse"}
2	2025-08-24 21:42:09	8	user.update_role	user	{"new_role": "doctor"}
3	2025-08-24 21:41:00	8	user.delete	user	{"username": "ziii"}
4	2025-08-24 21:40:56	8	user.delete	user	{"username": "uuuui"}
5	2025-08-24 21:40:53	8	user.reset_password	user	{"username": "uuuui"}
6	2025-08-24 21:40:28	8	user.update_role	user	{"new_role": "nurse"}
7	2025-08-24 21:40:26	8	user.update_role	user	{"new_role": "admin"}
8	2025-08-24 21:40:22	8	user.create	user	{"username": "uuuui", "role": "nurse"}
9	2025-08-24 20:52:08	8	user.reset_password	user	{"username": "ziii"}
10	2025-08-24 20:51:50	8	user.update_role	user	{"new_role": "doctor"}
11	2025-08-24 20:51:47	8	user.update_role	user	{"new_role": "nurse"}
12	2025-08-24 20:51:42	8	user.create	user	{"username": "ziii", "role": "doctor"}
13	2025-08-24 20:51:25	8	user.delete	user	{"username": "ziii"}
14	2025-08-24 20:50:14	8	user.create	user	{"username": "ziii", "role": "nurse"}

圖 4.14 權限操作紀錄

第 5 章 結論

本研究以 APTOS 2019 Blindness Detection 資料集為基底，經由高斯濾波、CLAHE 等影像前處理及資料平衡與增強策略，有效提升了影像品質與模型泛化能力。實驗中分別比較 CNN、ResNet50、InceptionV3 與 EfficientNetB5 四種深度學習架構在糖尿病視網膜病變五級分類任務上的表現。最終選定準確率、靈敏度與特異度等指標皆優於其他模型的 EfficientNetB5 作為本案模型，其整體分類準確率約 96.54%，顯示本研究所建置之模型具備穩定且可靠的辨識效能。

在此基礎上，本研究進一步優化 EfficientNetB5 模型，並結合影像前處理流程與 PyQt5 圖形介面，開發出一套糖尿病視網膜病變自動辨識系統。系統可協助基層醫療單位快速完成大量眼底影像之初步篩檢，提升篩檢與診斷效率，尤其對醫療資源較匱乏的偏鄉地區，更能縮短病患就醫與轉診時間，強化早期發現與早期治療之可行性。

未來研究方向可從系統效能、臨床應用與跨平台整合三個面向持續延伸。首先，可持續改善模型結構，並嘗試加入能強調影像重點區域的判讀方式，讓使用者更容易捕捉早期病變的細微變化，同時讓模型的判斷理由能以更直觀的方式呈現，提升 AI 在臨床使用上的可信度。其次，系統可擴充與眼底攝影設備之連接能力，導入即時影像擷取與自動化資料管理流程，以提升在實際醫療現場的運作效率。此外，亦可串接 LineBot 與行動裝置平台，使病患能即時取得回診提醒或檢查建議，形成從影像取得、分析到回饋的完整服務鏈。透過以上方向的推進，本系統可望在未來演變為更全面的智慧眼科輔助工具，強化科技在醫療照護中的整合價值。

第 6 章 人力配置

參與本研究之工作人員工作內容如表 6.1 所示。

表 6.1 參與本項研究之人員及工作內容

姓名	工作內容
俞華鈴	資料蒐集、模型訓練與優化、資料整理與報告統整
李馥彤	專案規劃、系統架構設計、程式主體製作、報告製作
林永泰	資料蒐集與整理、網頁開發製作、美術設計報告編排

參考文獻

- [1] International Diabetes Federation. (2025). IDF Diabetes Atlas (11th ed., pp. 41–42). Brussels, Belgium: International Diabetes Federation. Retrieved from <https://diabetesatlas.org/resources/idf-diabetes-atlas-2025/>
- [2] C. Steele, D. Steel, and C. Waine, Editors (2008), “5 - Acute And Chronic Complications Of Diabetes Mellitus And Living With The Disease,” *Diabetes and the Eye*, pp. 51-58, DOI: 10.1016/B978-0-08-045307-1.50010-1.
- [3] D. S. W. Ting, G. C. M. Cheung, and T. Y. Wong (2016), “Diabetic Retinopathy: Global Prevalence, Major Risk Factors, Screening Practices And Public Health Challenges: A Review,” *Clinical & Experimental Ophthalmology*, Vol. 44, No. 4, pp. 260-277, DOI: 10.1111/ceo.12696.
- [4] K. Viswanath, and D. D. M. McGavin (2003). “Diabetic Retinopathy: Clinical Findings And Management,” *Community eye health*. Vol. 16, No. 46, pp. 21-24.
- [5] APTOS 2019 Blindness Detection – Kaggle: <https://www.kaggle.com/c/aptos2019-blindness-detection>
- [6] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.
- [7] (InceptionV3) Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the inception architecture for computer vision. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2818–2826. <https://doi.org/10.1109/CVPR.2016.308>
- [8] Akhtar, S., & Aftab, S. (2024). A framework for diabetic retinopathy detection using transfer learning and data fusion. *I.J. Information Technology and Computer Science*, (6), 61–73. <https://doi.org/10.5815/ijitcs.2024.06.07>
- [9] Alwakid, G., Gouda, W., Humayun, M., & Jhanjhi, N. Z. (2023). Enhancing diabetic retinopathy classification using deep learning. *Digital Health*, 9, 20552076231203676. <https://doi.org/10.1177/20552076231203676>
- [10] Abbood, S. H., Hamed, H. N. A., Rahim, M. S. M., & Rehman, A. (2022). Hybrid retinal image enhancement algorithm for diabetic retinopathy diagnostic using deep learning model. *IEEE Access*, 10, 73079–73086. <https://doi.org/10.1109/ACCESS.2022.3189374>
- [11] El-Ateif, S., & Idri, A. (2022). Single-modality and joint fusion deep learning for diabetic retinopathy diagnosis. *Scientific African*, 17, e01280. <https://doi.org/10.1016/j.sciaf.2022.e01280>

- [12] Akhtar, S., & Aftab, S. (2024). A framework for diabetic retinopathy detection using transfer learning and data fusion. *I.J. Information Technology and Computer Science*, 6, 61–73. <https://doi.org/10.5815/ijitcs.2024.06.05>

附錄 A 開發工具介紹

A.1 軟體開發工具介紹

本專題使用 python 架構撰寫，並在 colab 平台上使用 TensorFlow 類神經網路架構來訓練模型，並在 Visual Studio Code 上設計主要程式架構。

A.1.1 Visual Studio Code

Visual Studio Code (VS Code) 是微軟於 2015 年推出的免費、開源且跨平台編輯器，基於 Electron 架構，兼具輕量啟動與高效能。內建語法高亮、智慧提示、程式片段、整合終端與強大除錯功能，並透過 Language Server Protocol 支援多種語言的自動補全與語意分析。使用者可從擴充市場安裝數千款外掛，如 Python、JavaScript、C#、Docker 與 Kubernetes 支援，以及 ESLint、Prettier、GitLens 等工具，實現代碼格式化與版本控制。VS Code 原生整合 Git，提供側邊欄差異檢視、提交與分支管理。VS Code 已成為全端工程師、資料科學家與 DevOps 團隊的首選開發利器。如圖 A.1。




圖 A.1 Visual Studio Code

A.1.2 TensorFlow

TensorFlow 是 Google Brain 團隊於 2015 年開源推出的機器學習平台，採用計算圖機制與優化執行時引擎，可高效執行張量運算。它整合 Keras 高階 API，提供模型定義、訓練與評估一體化接口，同時支援 Eager Execution 增強開發靈活性。借助 tf.data 可構建高效數據管道，結合混合精度和 tf.distribute 分散式策略，實現多 GPU 與 TPU 集群擴展訓練。內建 TensorBoard 用於可視化指標、網絡結構及超參數調優；訓練完成後，可導出 SavedModel，並透過 TensorFlow Lite、TensorFlow.js 與 TensorFlow Serving 在行動端、瀏覽器與服務端實現一站式部署。豐富生態與跨平台支持，使其成為從原型開發到大規模生產部署的理想選擇，如圖 A.2。



圖 A.2 TensorFlow

A.1.3 Colab

Colab，全名 Google Colaboratory，是由 Google 提供的一款免費且免安裝配置的雲端 Python 開發環境，專為數據科學和機器學習任務而設計。它基於 Jupyter Notebook，允許用戶在瀏覽器中直接撰寫並執行 Python 代碼，並預裝了 NumPy、Pandas、Matplotlib、Scikit-learn、TensorFlow、PyTorch 等主流科學計算與深度學習庫。使用者只需擁有 Google 帳戶，即可一鍵啟動運算環境，並在「執行階段設定」中選擇 NVIDIA GPU 或 Google TPU 加速器，以滿足各種高性能訓練需求。Colab 無縫整合了 Google Drive，讓用戶能方便地讀寫和備份資料集，並支援與 GitHub 的協同操作，以便於版本控制與團隊協作。此外，多人可同時在線編輯同一份 Notebook，並透過分享連結或導出為.ipynb、HTML、PDF 等格式，輕鬆分發研究成果或教學內容。由於免除了本地環境配置的複雜性並提供了強大的雲端計算資源，Colab 成為初學者快速入門以及專業人士進行原型驗證和模型部署的首選平臺，如圖 A.3。



圖 A.3 Colab

A.2 影像辨識電腦硬體

影像辨識電腦硬體說明如表 A.1。

表 A.1 影像辨識電腦

作業系統	Windows 11 家用版
處理器	Intel(R) Core(TM) i7-12700H
晶片組型號	Intel HM670 PCH
標準記憶體	16GB
記憶體	DDR5-4800
外部顯卡	NVIDIA GeForce RTX 4050 laptop GPU